

2024 年度 修士論文

微分可能・非凸な適応的ブロックスパース正則化と
その応用

Differentiable and Nonconvex Adaptive Block-Sparse
Regularization and Its Applications

指導教員

横田 達也 准教授

名古屋工業大学大学院
工学研究科博士前期課程
工学専攻

2023 年度入学 35414099 番

古橋 敬信

目次

第 1 章 序論	2
1.1 観測モデルと最適化に基づくパラメータ推定	4
1.2 スパース正則化	5
1.3 ブロックスパース正則化	9
1.4 適応的ブロックスパース正則化	12
1.5 非凸スパース正則化	13
1.6 本研究の目的	18
1.7 本論文の構成	20
第 2 章 凸緩和された適応的ブロックスパース正則化	22
2.1 Latent Optimally Partitioned ℓ_2/ℓ_1 (LOP- ℓ_2/ℓ_1)	22
2.2 最適化アルゴリズム	26
2.3 LOP- ℓ_2/ℓ_1 の問題点	28
第 3 章 任意の線形変換における凸適応的ブロックスパース正則化	30
3.1 任意の線形変換における LOP- ℓ_2/ℓ_1	30
3.2 最適解への収束条件	32
第 4 章 非凸関数を用いたブロックスパース正則化	35
4.1 対数関数を用いた LOP- ℓ_2/ℓ_1 のバイアス低減	35
4.2 一般化逆順序重み付き損失 (GROWL)	42
第 5 章 微分可能な適応的ブロックスパース正則化	45
5.1 微分可能なスパース正則化	45
5.2 微分可能な非凸スパース正則化	46
5.3 微分可能なブロックスパース正則化	46
5.4 平滑化による真のブロック構造推定	47

5.5 深層学習への応用	49
第 6 章 テンソル分解への応用	50
6.1 テンソル分解	50
6.2 多層スパース CP 分解 (MLSCP)	52
6.3 多層ブロックスパース性を利用した MLSCP	55
6.4 外れ値テンソルのブロック構造を利用した TRPCA	56
第 7 章 数値実験	61
7.1 時系列信号のノイズ除去	61
7.2 画像ノイズ除去	64
7.3 テンソル補完	69
7.4 MNIST における 3 層 MLP の枝刈り	73
7.5 最適解収束条件の検証	74
第 8 章 まとめ	76
付録 A 最適化アルゴリズム	78
A.1 近接写像の定義	78
A.2 近接写像の単調減少性	78
A.3 線形拡張ラグランジュ法	79
A.4 交互方向乗数法	80

記法	意味
$\mathbb{R}$	実数全体の集合
$\mathbb{R}_+$	正の実数全体の集合
$\mathbb{R}_{\geq 0}$	非負の実数全体の集合
$\mathbf{a}, \mathbf{b}, \mathbf{c}$	ベクトル
$\mathbf{A}, \mathbf{B}, \mathbf{C}$	行列
$\mathcal{A}, \mathcal{B}, \mathcal{C}$	テンソル
$ S $	集合 S の濃度
$ x $	実数 x の絶対値
$\text{sign}(x)$	実数 x の符号
$(x_n)_{n=1}^N$	列ベクトル $(x_1, x_2, \dots, x_N)^\top$
$\mathbf{x}_{\mathcal{B}}$	$(x_n)_{n \in \mathcal{B}}$ で定義される部分ベクトル
$(\mathbf{x}_{\mathcal{B}_k})_{k=1}^K$	部分列ベクトルを縦方向に並べた列ベクトル $(\mathbf{x}_{\mathcal{B}_1}^\top, \mathbf{x}_{\mathcal{B}_2}^\top, \dots, \mathbf{x}_{\mathcal{B}_K}^\top)^\top$
$\mathbf{A}^\top$	行列 $\mathbf{A}$ の転置行列
$\rho(\mathbf{A})$	行列 $\mathbf{A}$ の最大固有値
$\ \mathbf{A}\ _{\text{op}}$	行列 $\mathbf{A}$ の作用素ノルム ($:= \max_{\ \mathbf{x}\ _2=1} \ \mathbf{A}\mathbf{x}\ _2$)
$\text{rank}(\mathbf{A})$	行列 $\mathbf{A}$ のランク
$\mathcal{N}(\mathbf{A})$	行列 $\mathbf{A}$ の零空間
$\mathbf{0}$	零ベクトル
$\mathbf{I}$	単位行列
$\mathbf{O}$	零行列
$\mathbf{D}$	微分作用素 (例: (1.6))
$\text{prox}_f(\mathbf{x})$	関数 f の近接写像 (A.1)
$\mathbf{I}(x \neq 0)$	実数 x が 0 のとき 0, それ以外るとき 1 を返す関数
$\boxtimes$	アダマール積 (テンソルの要素ごとの積)
$\otimes$	クロネッカー積

第 1 章

序論

信号処理，画像処理，機械学習の諸分野では，不完全または断片的な観測データから，その背後にある真の情報を正確に理解することが重要な研究課題となっている．例えば，劣化した音声信号から元の音声を復元する，ノイズの多いセンサーデータから正確な測定値を推定するといった実際の課題が，この研究テーマに該当する．これらの分野では，観測信号から真の信号を復元する際に，多くの場合，不良設定問題に直面する．不良設定問題の特徴として，以下の 2 つが挙げられる：1. 解の一意性が保証されない，2. 解が観測データの微小な変動に対して不安定である．この問題に対処するため，正則化に基づく最適化手法が広く研究されてきた [1–3]．スパース正則化は，不良設定問題に対処するための有力な手法である．この方法は，観測データに潜むスパース性を利用し，その本質的な情報を取り出す．時系列信号の周波数空間に現れるスパース性を，三角関数の線形和を例にして図 1.1 に示す．

機械学習の文脈では，スパース正則化は特徴選択と密接に関連し，モデルの複雑さを制御しながら，最も重要な特徴のみ選択することを可能にする [4, 5]．特に，高次元データにおける特徴選択の重要性が注目されている [6–11]．現代のデータ解析では，数百から数千にお




図 1.1: 周波数空間におけるスパース性の例．三角関数 $x(t) = \cos(2\pi \times 97t) + \cos(2\pi \times 777t)$ (左) の周波数スペクトルは，2 つのピークのみを持つスパースな信号である (右)．




図 1.2: 画像（ピクセル）空間の広大さ [32, Figure 3.3]. 自然画像に特有のエッジやテクスチャは、画像空間のごく一部にしか存在しない。

よぶ特徴量を持つデータセットが珍しくない。このような高次元データから、最も重要な特徴を選択することは、モデルの性能と解釈性を大きく改善する鍵となる。

画像復元分野においても、スパース正則化は貢献している [12–31]。デジタル画像は、しばしばノイズ、ぼけ、圧縮アーティファクト、不完全な撮影条件など、様々な劣化要因に晒される。スパース正則化に基づく画像復元手法は、これらの劣化を最小限に抑え、元の高品質な画像を推定することを可能にする。特に、自然画像の持つスパース性を活用することで、従来の復元手法を大きく上回る性能を実現している。図 1.2 のように、画像はピクセル空間において非常に高次元であるものの、自然画像に特有のエッジやテクスチャは、画像空間のごく一部にしか存在しない。それ以外の領域は、画像はランダムなノイズなどで構成されている。スパース正則化は、このような画像の性質を活用して、高品質な画像復元を実現する。

圧縮センシングは、スパース正則化の応用の 1 つである。従来のサンプリング理論では、情報を完全に再構成するためには、ナイキスト-シャノンのサンプリング定理に従い、信号の最大周波数の 2 倍以上のサンプリングレートが必要とされてきた。しかし、圧縮センシングは、スパース性を仮定することで、この理論的限界を大幅に突破する。つまり、信号がスパースであれば、従来よりもはるかに少ないサンプル数で元の信号を正確に再構成できる [33–38]。医療画像、レーダー観測、通信システムなど、様々な分野でこのアプローチが応用されている [26, 27, 38–40]。

しかし、従来のスパース正則化手法は、個々のパラメータを独立して扱い、スパース性を評価する。実際の信号処理においては、多くのパラメータが相互に関連し、構造的な意味を持つことが一般的である。この従来のアプローチは、信号の本質的な構造的特性を十分に捉




図 1.3: 自然画像の前景が持つブロックスパース性 ([41, Fig.1] を一部引用)

えきれないという課題を抱えている。ブロックスパース正則化は、この課題に対する解決策を与える。この正則化は、関連するパラメータ群（ブロック成分）を同時に考慮し、その全体的なスパース性を評価する。これにより、個々のパラメータではなく、意味のあるブロックの選択や除外が可能となる。例えば 図 1.3 のように、画像の前景は隣接するピクセル間で強い相関を持つため、ブロックスパース正則化は前景の構造的特性を捉えるのに有効である。

1.1 観測モデルと最適化に基づくパラメータ推定

観測モデルは、実世界の様々な現象を数理的に表現するための基本的な枠組みであり、特に信号復元、圧縮センシングにおいて重要な役割を果たす。観測モデルを適切に構築することで、観測データから未知のパラメータや信号を推定することが可能となる。例えば、線形観測モデルは、未知ベクトルを $\mathbf{x} \in \mathbb{R}^N$ 、観測ベクトルを $\mathbf{y} \in \mathbb{R}^J$ 、観測行列を $\mathbf{L} \in \mathbb{R}^{J \times N}$ 、観測誤差を $\boldsymbol{\varepsilon} \in \mathbb{R}^N$ とおくと、 $\mathbf{y} = \mathbf{L}\mathbf{x} + \boldsymbol{\varepsilon}$ で表される。

次に、観測ベクトル $\mathbf{y}$ および観測行列 $\mathbf{L}$ から未知ベクトル $\mathbf{x}$ を推定するタスクを考える。このタスクを解くことで、不完全な観測データから、信号の本質的な情報を取り出すことができる。例えば、医療画像再構成において、 $\mathbf{x}$ は元の画像、 $\mathbf{y}$ は CT スキャンなどの観測データ、 $\mathbf{L}$ は投影行列を表す。この場合、観測モデルは CT スキャンから元の画像を再構成するために用いられる。また、圧縮センシングにおいて、 $\mathbf{x}$ はスパースな信号、 $\mathbf{y}$ は圧縮された観測データ、 $\mathbf{L}$ はランダムな測定行列を表す。このとき、観測モデルは少ないサンプルから元のスパース信号を再構成するために用いられる。線形重回帰での特徴選択において、 $\mathbf{x}$ は特徴量の重み（回帰係数）、 $\mathbf{y}$ は観測データ（目的変数）、 $\mathbf{L}$ は特徴量行列（説明変数）を表す。この場合、観測モデルは観測データから重要な特徴量を選択するために用いられる。

れる。

この問題は、観測ベクトル $\mathbf{y}$ と $\mathbf{L}\mathbf{x}$ の非類似度を表す関数 $f: \mathbb{R}^J \rightarrow \mathbb{R}_{\geq 0}$ ^{*1} を用いて、次の最適化問題として表される：

$$\min_{\mathbf{x} \in \mathbb{R}^N} f(\mathbf{L}\mathbf{x}). \quad (1.1)$$

本論文では $f(\mathbf{L}\mathbf{x})$ を損失項と呼ぶことにする。損失項は観測モデルの条件がどれだけ満たされているかを評価する。二乗誤差 $f(\mathbf{u}) = \frac{1}{2}\|\mathbf{y} - \mathbf{u}\|_2^2$ ，絶対誤差 $f(\mathbf{u}) = \|\mathbf{y} - \mathbf{u}\|_1$ は、最適化計算の容易さから損失項としてしばしば用いられる。また、これらの損失項は、観測誤差 ε の統計的性質からも導出できる。

不良設定問題 いま、(1.1) のある最適解を $\mathbf{x}^*$ とすると、 $\mathbf{L}$ の零空間 $\mathcal{N}(\mathbf{L}) = \{\mathbf{z} \mid \mathbf{L}\mathbf{z} = \mathbf{0}\}$ の任意の元 $\mathbf{z}$ に対して、 $\mathbf{L}(\mathbf{x}^* + \mathbf{z}) = \mathbf{L}\mathbf{x}^*$ が成り立つ。ゆえに、 $\mathbf{x}^* + \mathbf{z}$ も (1.1) の最適解である。加えて、 $\text{rank}(\mathbf{L}) < N$ ならば、 $\mathcal{N}(\mathbf{L})$ は $\{\mathbf{0}\}$ を真に含むため、 $\mathbf{L}$ が横長行列である場合や $\mathbf{L}$ がランク落ちしている場合に、(1.1) の最適解は一意でない。解が一意でない最適化問題を不良設定問題という。このような問題に対処するため、正則化を用いて、複数ある最適解の中から望ましい解を選択する手法が広く研究されている。

正則化は、最適化問題の損失項に正則化項を足し合わせ、与えられた問題の解へ制約を加える手法である。観測モデル $\mathbf{y} = \mathbf{L}\mathbf{x} + \varepsilon$ における、正則化を用いた最適化は、 $\mathbf{L} \in \mathbb{R}^{J \times N}$ ， $\mathbf{R} \in \mathbb{R}^{K \times N}$ ， $f: \mathbb{R}^J \rightarrow \mathbb{R}_{\geq 0}$ ， $h: \mathbb{R}^K \rightarrow \mathbb{R}_{\geq 0}$ を用いて

$$\min_{\mathbf{x} \in \mathbb{R}^N} f(\mathbf{L}\mathbf{x}) + h(\mathbf{R}\mathbf{x}) \quad (1.2)$$

のように表す。 $f(\mathbf{L}\mathbf{x})$ を損失項， $h(\mathbf{R}\mathbf{x})$ を正則化項と呼ぶ。正則化項は、解が望ましい性質を持つときに小さな値を取るよう設計することが重要である。

1.2 スパース正則化

スパース性は我々が扱う多くの信号が持つ重要な性質である。これは、実際の環境において、信号が何らかの意味でスパースであることが多いためである。スパース性とは、信号の非ゼロ成分が少数であることを意味する。スパース性を利用することで、信号の圧縮、ノイズ除去、信号復元、特徴選択などが可能となる。例えば、画像や音声データを圧縮する際には、スパース性を活用することで、データ量を大幅に削減した $\mathbf{y}$ から、元の信号 $\mathbf{x}$ を高精度に再現することができる。これにより、データの保存や伝送が効率化される。また、スパース性はノイズ除去や信号復元においても有用である。信号のスパース性を仮定すること

^{*1} 距離関数やダイバージェンスなど




図 1.4: 非スパース信号 (左) とスパース信号 (右) の比較. 左の信号は 6 つの非ゼロ成分 ($\|\mathbf{x}\|_0 = 1 + 1 + 1 + 1 + 1 + 1 = 6$) を持つが, 右の信号は非ゼロ成分が 2 つ ($\|\mathbf{x}\|_0 = 1 + 0 + 0 + 0 + 1 + 0 = 2$) と少数である.

で, 観測データ $\mathbf{y}$ からノイズを効果的に除去し, 元の信号 $\mathbf{x}$ を高精度に復元することができる. さらに, スパース性は特徴選択にも役立つ. 高次元データにおいて, スパース性を利用することで, 少数の重要な特徴量のみを選択し, モデルの複雑さを制御することができる. これにより, モデルの解釈性が向上し, 過学習を防ぐことで汎化性能も向上する.

ベクトル $\mathbf{x} = (x_n)_{n=1}^N \in \mathbb{R}^N$ のスパース性は ℓ_0 ノルム (非ゼロ成分の数) によって評価される. $\mathbf{x} \in \mathbb{R}^N$ の ℓ_0 ノルムは, 次のように定義される:

$$\|\mathbf{x}\|_0 := \sum_{n=1}^N \mathbf{I}(x_n \neq 0).$$

図 1.4 が示すように, ℓ_0 ノルムはベクトルがスパースであればあるほど小さな値を取る. スパース正則化は, 正則化項を ℓ_0 ノルムとすることでスパースな解を誘導する. 例えば, ℓ_0 ノルムの近接写像はハード閾値関数として知られる.

定理 1.1. ℓ_0 ノルムの近接写像は次のように表される:

$$\text{prox}_{\lambda\|\cdot\|_0}(x) = \text{hard}_{\sqrt{2\lambda}}(x) = \begin{cases} 0 & \text{if } x^2 < 2\lambda \\ \{x, 0\} & \text{if } x^2 = 2\lambda \\ x & \text{otherwise} \end{cases}, \quad (1.3)$$

$$\text{prox}_{\lambda\|\cdot\|_0}(\mathbf{x}) = (\text{prox}_{\lambda\|\cdot\|_0}(x_n))_{n=1}^N.$$

□

Proof. $\hat{\mathbf{u}} = \text{argmin}_{\mathbf{u}} \frac{1}{2}\|\mathbf{u} - \mathbf{x}\|_2^2 + \lambda\|\mathbf{u}\|_0$ の値を求めることを考える. $\frac{1}{2}\|\mathbf{u} - \mathbf{x}\|_2^2$ と $\lambda\|\mathbf{u}\|_0$ は要素ごとの関数の和であるため, $\mathbf{u}$ の n 番目の要素 u_n に対して独立に解くことができる. その最小解 $\hat{u}_n$ は x_n か 0 のどちらかである. $\hat{u}_n = x_n$ のときの損失は λ であり, $\hat{u}_n = 0$ のときの損失は $\frac{1}{2}x_n^2$ である. したがって, x_n^2 の値が 2λ より高い場合, $\hat{u}_n$ の値は x_n に等しい. また, x_n^2 の値が 2λ より低い場合, $\hat{u}_n$ の値は 0 に等しい. そして, x_n^2 の値が 2λ に等しい場合, $\hat{u}_n$ の値は x_n か 0 のどちらでもよい. □




図 1.5: ソフト閾値関数 $\text{soft}_\lambda(x)$

しかし，その不連続性と非凸性のため， ℓ_0 ノルムを代入した (1.2) を厳密に解くことは一般に NP 困難である [42]．そこで，代わりに凸関数である ℓ_1 ノルム

$$\|\mathbf{x}\|_1 := \sum_{n=1}^N |x_n|$$

を用いる方法が提案されている [43]． ℓ_1 ノルムは ℓ_0 ノルムと同様にスパースな解を誘導する．例えば，損失項に二乗誤差 $f(\mathbf{u}) = \frac{1}{2} \|\mathbf{x} - \mathbf{u}\|_2^2$ を用いる場合， $\min_{\mathbf{u} \in \mathbb{R}^N} \frac{1}{2} \|\mathbf{x} - \mathbf{u}\|_2^2 + \lambda \|\mathbf{u}\|_1$ の最適解は近接写像 (A.1) の表記を用いて，

$$\text{prox}_{\lambda \|\cdot\|_1}(\mathbf{x}) = \text{soft}_\lambda(\mathbf{x}) = \left(\left(1 - \frac{\lambda}{\max\{|x_n|, \lambda\}} \right) x_n \right)_{n=1}^N \quad (1.4)$$

とソフト閾値処理 (図 1.5) の形で表される．また，スパースな解を誘導するノルムである ℓ_p ($0 \leq p \leq 1$) ノルムの中で唯一の凸関数であり，凸最適化の枠組みで最適解を求められる．凸最適化問題は，局所最適解が大域的最適解に等しく，非凸最適化と比べて容易に大域的最適解を求められる．

スパース正則化の主な例として Lasso [44] と TV 正則化 [45] が存在する．Lasso は観測モデルの特徴選択などに用いられる．TV 正則化は，信号の微分値に対して ℓ_1 正則化を行う方法である．滑らかな信号を復元できるため，信号の平滑化や補間などに用いられる [14, 45–62]．

例 1.1 (Lasso による特徴選択). $\mathbf{R} = \mathbf{I}$, $h = \lambda \|\cdot\|_1$ ($\lambda \geq 0$) を (1.2) へ代入して

$$\min_{\mathbf{x} \in \mathbb{R}^N} f(\mathbf{L}\mathbf{x}) + \lambda \|\mathbf{x}\|_1$$

と表す． λ は正則化の大きさを調整する係数（正則化係数）である．また，Lasso において，観測ベクトル $\mathbf{y}$ は線形重回帰モデル $\mathbf{y} = \mathbf{L}\mathbf{x} + \boldsymbol{\varepsilon} = \sum_{n=1}^N x_n \boldsymbol{\ell}_n + \boldsymbol{\varepsilon}$ で表せると仮定する． $\mathbf{x} = (x_1, \dots, x_N)^\top$ を回帰係数ベクトル， $\mathbf{L} = [\boldsymbol{\ell}_1, \dots, \boldsymbol{\ell}_N]$ ($\forall i \in \{1, \dots, N\}, \boldsymbol{\ell}_i \in \mathbb{R}^J$) を基底（特徴）行列， $\boldsymbol{\varepsilon}$ を予測誤差という．

Lasso の推定結果を $\hat{\mathbf{x}}$ とする．このとき， $\mathbf{y}$ は $\hat{\mathbf{x}}$ の非ゼロ成分 $\hat{x}_k$ のインデックス k に対応する基底（特徴） $\boldsymbol{\ell}_k$ のみで $\mathbf{L}\hat{\mathbf{x}} = \sum_{n=1}^N \hat{x}_n \boldsymbol{\ell}_n = \sum_{k \in \{n \mid \hat{x}_n \neq 0\}} \hat{x}_k \boldsymbol{\ell}_k$ と表される．Lasso で得られる $\hat{\mathbf{x}}$ はスパースであり， $\mathbf{y}$ を線形重回帰モデルで説明するために必要な基底（特徴） $\boldsymbol{\ell}_k$ を，Lasso によって選択することができる．□

例 1.2 (Elastic net による特徴選択)．Lasso は予測への寄与が等しい特徴が 2 つある場合にいずれか 1 つのみを選択する傾向にある．この傾向を緩和するために，Lasso と Ridge 回帰を組み合わせた Elastic net [63] が提案されている．Elastic net は正則化項を ℓ_1 ノルムと ℓ_2 ノルムの和として

$$\min_{\mathbf{x} \in \mathbb{R}^N} f(\mathbf{L}\mathbf{x}) + \lambda_1 \|\mathbf{x}\|_1 + \lambda_2 \|\mathbf{x}\|_2$$

と表される． $\lambda_1 \in \mathbb{R}_{\geq 0}$ は ℓ_1 ノルムの正則化係数， $\lambda_2 \in \mathbb{R}_{\geq 0}$ は ℓ_2 ノルムの正則化係数である．また，Elastic net の近接写像は，次のように表される：

$$\text{prox}_{\lambda_1 \|\cdot\|_1 + \lambda_2 \|\cdot\|_2}(\mathbf{x}) = \left(\frac{1}{1 + 2\lambda_2} \text{soft}_{\lambda_1}(x_n) \right)_{n=1}^N.$$

□

例 1.3 (TV 正則化による信号再構成)． $h = \lambda \|\cdot\|_1$ ($\lambda \geq 0$) と， $\mathbf{R}$ として微分作用素 $\mathbf{D}$ を (1.2) へ代入して

$$\min_{\mathbf{x} \in \mathbb{R}^N} f(\mathbf{L}\mathbf{x}) + \lambda \|\mathbf{D}\mathbf{x}\|_1 \quad (1.5)$$

と表す． $\mathbf{D}$ は例えば次のように定義される微分作用素である：

$$\mathbf{D} = \begin{pmatrix} -1 & 1 & 0 & \cdots & 0 \\ 0 & \ddots & \ddots & \ddots & 0 \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ 0 & \cdots & 0 & -1 & 1 \end{pmatrix} \in \mathbb{R}^{(N-1) \times N}. \quad (1.6)$$

この $\mathbf{D}$ は 1 次元信号における隣接要素間の差分を計算する行列であり，信号がテンソルやグラフの場合には，それぞれに対応する微分作用素を用いる． $\|\mathbf{x}\|_{\text{TV}} := \|\mathbf{D}\mathbf{x}\|_1$ を TV ノルムという．TV ノルムは $\mathbf{x}$ の滑らかさ (TV が低いほど滑らか) を表す指標である．これを正則化項として用いることで，滑らかな復元結果 $\hat{\mathbf{x}}$ を得られる．また， $\mathbf{L} = \mathbf{I}$ の場合，

(1.5) はノイズ除去問題を解くことに対応する．ただし，TV 正則化は信号を過剰に平滑化し，エッジ情報を失うことがある．これを緩和する方法の 1 つとして，逆順序重み付き ℓ_1 ノルムが提案されている（例 1.4）．□

TV 正則化（例 1.3）のように (1.2) における $\mathbf{R}$ を単位行列でない行列とすることで，特徴空間における正則化（注意 1.1）を行える．

注意 1.1 (特徴空間における正則化)． $\mathbf{R}$ を微分作用素，フーリエ変換，ウェーブレット変換，フレームレット変換，ラドン変換，遅延埋め込み，グラフラプリアン，などの線形作用素とすることで特徴空間における正則化を行える．例えば，微分作用素（例 1.3）を用いると滑らかさによる正則化（TV 正則化），フーリエ変換を用いると周波数成分による正則化を行える．実際に文献 [40] では後者を用いてフェーズドアレイ気象レーダの信号を復元している．更に，低ランク正則化の文脈においても，線形変換を用いたアプローチが近年提案されている．例えば，[64] では，遅延埋め込みを用いたテンソル分解が提案されている．また，[65, 66] では，フレームレットを用いて，テンソル核ノルム正則化を行っている．加えて，[67, 68] では，線形変換を利用した低ランク行列補完が提案されている．□

更に， ℓ_1 ノルムなどの凸関数を用いた正則化だけでなく，非凸関数を用いた正則化も提案されている [55, 56, 62, 69, 70]．非凸性を導入することで， ℓ_0 ノルムにより近い形でスパース性を評価できる．その代わり，非凸最適化では初期値依存性や局所最適解の存在が問題となる．非凸なスパース正則化については，1.5 節で詳しく説明する．

1.3 ブロックスパース正則化

ベクトル上で定義される関連するパラメータ群（ブロック成分）ごとのスパース性をブロックスパース性と呼ぶ．この性質は，推定の対象とする個々のパラメータが相互に関連し，かつスパースな場合に有用である [40, 71–77]．例えば，フェーズドアレイ気象レーダの観測信号は，周波数領域で局所的な非ゼロ成分を持つ（図 1.6）．また，画像の前景成分（図 1.3）やエッジ成分（図 1.7）は局所的な非ゼロ成分を持つ．

ブロックスパース性は混合 ℓ_2/ℓ_0 ノルム (1.7) で評価できる：

$$\|\mathbf{x}\|_{2,0}^{(\mathcal{B}_k)_{k=1}^j} := \sum_{k=1}^j \sqrt{|\mathcal{B}_k|} \cdot \mathbf{I}(\|\mathbf{x}_{\mathcal{B}_k}\|_2 \neq 0). \quad (1.7)$$

ここで， $\mathcal{B}_1, \dots, \mathcal{B}_j \subset \{1, \dots, N\}$ をブロックとし， $|\mathcal{B}_k|$ はブロック $\mathcal{B}_k$ の要素数を表す．(1.7) より混合 ℓ_2/ℓ_0 ノルムは，ベクトル上の非ゼロブロックのブロック長に応じた重み付き和として与えられることが分かる． ℓ_0 ノルムはベクトル上の非ゼロ要素に注目している




図 1.6: フェーズドアレイ気象レーダーのパワースペクトル (単位は dB) [40, Fig.8 (a)]. フェーズドアレイ気象レーダーの観測信号は周波数領域でブロックスパース性を持つ.



図 1.7: エッジ成分におけるブロックスパース性の例. 左: 元の画像. 右: 元の画像のエッジ成分. エッジ成分では, 元の画像のごく一部のピクセルが局所的に非ゼロとなる.

のに対して, 混合 l_2/l_0 ノルムはベクトル上の非ゼロブロックに注目している点異なる. ブロックスパースな信号とそうでない信号における混合 l_2/l_0 ノルムの比較を図 1.8 に示す. ブロックスパースな信号は, 非ゼロ成分がブロックごとにまとまって現れるため, 混合 l_2/l_0 ノルムが小さな値を取る. 対して, ブロックスパースでない信号は, 混合 l_2/l_0 ノル




図 1.8: 非ブロックスパース信号 (左) とブロックスパース信号 (右) の比較. $\mathcal{B}_1 = \{1, 2\}$, $\mathcal{B}_2 = \{3, 4\}$, $\mathcal{B}_3 = \{5, 6\}$ は, 右の信号における重複のない真のブロック構造である. 左の信号は 3 つの非ゼロなブロック成分 ($\|\mathbf{x}\|_{2,0}^{(\mathcal{B}_k)_{k=1}^3} = \sqrt{2} \cdot 1 + \sqrt{2} \cdot 1 + \sqrt{2} \cdot 1 = 3\sqrt{2}$) を持つ. 右の信号は 2 つの非ゼロなブロック成分 ($\|\mathbf{x}\|_{2,0}^{(\mathcal{B}_k)_{k=1}^3} = \sqrt{2} \cdot 1 + \sqrt{2} \cdot 0 + \sqrt{2} \cdot 1 = 2\sqrt{2}$) を持つ.

ムが大きな値を取る. また, 混合 ℓ_2/ℓ_0 ノルム $\|\mathbf{x}\|_{2,0}^{(\mathcal{B}_k)_{k=1}^j}$ を最小にする $\{\mathcal{B}_1, \dots, \mathcal{B}_j\}$ を $\mathbf{x}$ の真のブロック構造と呼ぶ. 加えて, このノルムを最小にする, 排他的な $\{\mathcal{B}_1, \dots, \mathcal{B}_j\}$ を重複のない真のブロック構造と呼ぶ. 重複のないブロック構造の厳密な定義は定義 2.1 で与える.

しかし, 混合 ℓ_2/ℓ_0 ノルムは ℓ_0 ノルムと同様に不連続かつ非凸であるため, 最適化問題を解くことは困難である. そこで, 凸関数である混合 ℓ_2/ℓ_1 ノルム

$$\|\mathbf{x}\|_{2,1}^{(\mathcal{B}_k)_{k=1}^j} := \sum_{k=1}^j \sqrt{|\mathcal{B}_k|} \cdot \|\mathbf{x}_{\mathcal{B}_k}\|_2 \quad (1.8)$$

を用いて, ブロックスパース性を近似的に評価することを考える.

混合 ℓ_2/ℓ_1 ノルムと ℓ_1 ノルムの比較 混合 ℓ_2/ℓ_1 ノルムを用いたブロックスパース正則化は, 信号のブロックスパース性を近似的に評価し, ブロックスパースな解を誘導する. ブロックスパース性を利用することで, スパース正則化と比べてより優れた正則化を行える場合があると理論的に知られている [36, 78]. また, 混合 ℓ_2/ℓ_1 ノルムの近接写像を ℓ_1 ノルムのものと比較することで, ブロックスパース正則化の特徴を説明する. ℓ_1 ノルム (スパース性) の近接写像はソフト閾値処理 (1.4) である. 一方, 混合 ℓ_2/ℓ_1 ノルム (ブロックスパース性) の近接写像は, 次のように表される:

$$\text{prox}_{\lambda \|\cdot\|_{2,1}^{(\mathcal{B}_k)_{k=1}^j}}(\mathbf{x}) = \left(\left(1 - \frac{\lambda}{\max \{ \|\mathbf{x}_{\mathcal{B}_k}\|_2 / \sqrt{|\mathcal{B}_k|}, \lambda \}} \right) \mathbf{x}_{\mathcal{B}_k} \right)_{k=1}^j$$

この近接写像はソフト閾値処理 (1.4) に類似する. ただし, 混合 ℓ_2/ℓ_1 ノルムでは, 成分の絶対値の代わりにブロック成分の ℓ_2 ノルムで閾値を決定するため, ブロック内に非ゼロ成分が含まれていても, ブロック全体がスパースと判定された場合, 閾値処理によりブロック




図 1.9: 2つの異なるブロック構造 (左: $\mathcal{B}_1 = \{1, 2, 3\}$, $\mathcal{B}_2 = \{4, 5, 6\}$, 右: $\mathcal{B}_1 = \{1, 2\}$, $\mathcal{B}_2 = \{3, 4\}$, $\mathcal{B}_3 = \{5, 6\}$) を用いた際のブロックスパース正則化の挙動の比較. 上段が正則化前の信号, 下段がブロックスパース正則化後の信号である. この正則化はブロック全体をスパースとみなした場合に, その中の成分をゼロにする.

成分がゼロになる. また, ブロック内にゼロに近い成分が含まれていても, ブロック全体がスパースでなければ, ブロック成分はそのまま保持される. 図 1.9 に, 2つの異なるブロック構造を用いたブロックスパース正則化の例を示す. よって, ブロックスパース正則化は, ブロック内の相互関係を考慮してスパース性を評価するため, スパース正則化よりも信号の構造をより適切に捉えることができる.

1.4 適応的ブロックスパース正則化

真のブロック構造が不明な場合, ブロックスパース正則化を正しく行うことはできない. これは, 図 1.9 に示すように, ブロックスパース正則化によってブロック内の成分全体が一律でゼロになるためである. 誤ったブロック構造を用いてブロックスパース正則化を行うと, 真のブロック構造において非ゼロであるようなブロック成分がゼロになり, 本来の信号の情報を損なうリスクがある.

それにもかかわらず, 真のブロック構造が未知な信号は我々の周りに多く存在する. 例えば, フェーズドアレイ気象レーダは周波数領域でブロックスパース性を持つ (図 1.6) が, そのブロック構造は未知である [40]. 自然画像のエッジ画像も同様である (図 1.7). ゆえに, 真のブロック構造を与えられたベクトルから推定することは, ブロックスパース正則化の適用対象を広げる上で重要である.

適応的ブロックスパース正則化 (Adaptive Block Sparse Regularization, ABSR) は, 真

手法	計算量	凸性	ブロックの重複
貪欲法, ベイズ的手法	$\mathcal{O}(N^3)$	非凸	可能
Latent Group Lasso	$\mathcal{O}(N^3)^{*2}$	凸	可能
LOP- ℓ_2/ℓ_1	$\mathcal{O}(JN)$	凸	不可能

表 1.1: 既存の適応的ブロックスパース正則化の比較.




図 1.10: 特徴空間における適応的ブロックスパース正則化の例. (左上) 滑らかな入力ベクトル x . (右上) ブロック構造が未知な x の微分 v . (左下) 推定された v のブロック構造 $\tilde{B}_1, \tilde{B}_2$. (右下) 推定されたブロック構造に基づく混合 ℓ_2/ℓ_1 ノルムの計算.

のブロック構造を推定した上でブロックスパース正則化を行う手法である. 非凸最適化ベースの方法としては貪欲法 [36, 79] やベイズ的手法 [80–82], 凸最適化としては Latent Group Lasso [83, 84], LOP- ℓ_2/ℓ_1 [40] などが提案されている (表 1.1). 貪欲法やベイズ的手法などの従来の適応的ブロックスパース正則化は, 逆行列計算の影響で計算量が大きいため, 高次元データへの適用が難しい. また, Latent Group Lasso は候補となるブロック構造をすべて用いる場合の計算量が大きく, 計算量を削減するためにはブロックのサイズを固定する必要がある. その一方, LOP- ℓ_2/ℓ_1 は逆行列計算を用いないため計算量が少なく, 高次元データへの適用が容易である. 加えて, LOP- ℓ_2/ℓ_1 正則化は, 信号の構造に対応する微分作用素を用いることで, ベクトルだけでなくテンソルやグラフ信号のブロックスパース推定に適用できる [85].

1.5 非凸スパース正則化

ℓ_1 ノルムは各成分の絶対値の和 $\sum_{n=1}^N |x_n|$ で表される凸関数であるため, 最適化の容易さからスパース正則化に従来用いられてきた. しかし, その値は線形に増加するため, 信号

*2 候補のブロック構造をすべて用いる場合の計算量. ブロックのサイズを B に固定する場合は $\mathcal{O}(BN)$.




図 1.11: 凸スパース正則化項 (ℓ_1 ノルム) と非凸スパース正則化項 (ℓ_1 ノルム以外) の比較

の大きさを過小評価する (振幅を過度に抑制する) 傾向にあり, スパース性の評価に不適切である. 本章では, この問題を解決するために用いられる, いくつかの非凸スパース正則化の技法を導入する. これらの正則化項は非凸関数 g を用いて $\sum_{n=1}^N g(|x_n|)$ の形で表される.

次に, 非凸スパース正則化の例をいくつか紹介する. 図 1.11 に, 導入する非凸スパース正則化項の等高線図をそれぞれ示す.

例 1.4 (逆順序重み付き ℓ_1 ノルム (ROWL)). 逆順序重み付き ℓ_1 ノルム (Reverse Ordered Weighted ℓ_1 -Norm, ROWL, [31]) は, 絶対値の大きい成分に対して小さな重みを割り当てることでスパース性の過小評価を解決する, 非凸スパース正則化の 1 つである. ROWL は

$$\Omega_{\mathbf{w}}(\mathbf{x}) := \sum_{n=1}^N w_n(|\mathbf{x}|_{\downarrow})_n = \langle \mathbf{w}, |\mathbf{x}|_{\downarrow} \rangle \quad (1.9)$$

によって定義される. ここで, $|\mathbf{x}|_{\downarrow} = \mathbf{P}(|\mathbf{x}|)|\mathbf{x}|$ は, $\mathbf{x}$ の各成分の絶対値を並べたベクトル $|\mathbf{x}| := (|x_n|)_{n=1}^N$ の要素を降順に並べ替えたベクトル^{*3}である. $\mathbf{P}(|\mathbf{x}|)$ は $|\mathbf{x}|$ を降順にソー

^{*3} 例えば, $\mathbf{x} = (1, -5, 4, 2, -3)^{\top}$ のとき, $|\mathbf{x}|_{\downarrow} = (5, 4, 3, 2, 1)^{\top}$

トする置換行列である。また、 $\mathbf{w}$ は非負の重みベクトルで、 $w_1 \leq w_2 \leq \dots \leq w_N$ を満たす。

ROWL は、絶対値の大きいパラメータ群に対して小さな重み、小さい場合は大きい重みを割り当てるという意味で、信号の大域的な構造を利用したブロックスパース正則化の一種と解釈できる。このノルムを用いたスパース正則化は、例えばノイズ付きの画像をエッジを保持しながら復元したい場合に有効である [31]。ROWL の近接写像は

$$\text{prox}_{\Omega_{\mathbf{w}}}(\mathbf{x}) = \text{sign}(\mathbf{x}) \boxtimes \left(\mathbf{P}(|\mathbf{x}|)^\top \text{prox}_{\mathbf{w} \boxtimes \|\cdot\|_1}(|\mathbf{x}|_\downarrow) \right)$$

の形で与えられる [31]。ここで、 $\mathbf{w} \boxtimes \|\cdot\|_1$ は重みを掛けた各成分の絶対値の和を出力する関数、すなわち $(\mathbf{w} \boxtimes \|\cdot\|_1)(\mathbf{x}) := \sum_{n=1}^N w_n |x_n|$ である。□

例 1.5 (再重み付き ℓ_1 ノルム (RWL1)). 再重み付き ℓ_1 ノルム (Reweighted ℓ_1 norm, RWL1) は、 ℓ_1 ノルムのバイアスを低減するために提案された非凸スパース正則化の 1 つである。まず、その成り立ちを説明するために、重み付き ℓ_1 ノルムを正則化項として加えた最適化問題

$$\min_{\mathbf{x}} \sum_{n=1}^N w_n |x_n| \quad \text{s.t.} \quad \mathbf{y} = \mathbf{L}\mathbf{x}$$

を解くことを考える。ROWL と同じ発想で、絶対値の大きい成分に対して小さな重みを割り当てることで、スパース性の過小評価を解決することを目指す。例えば、真の信号 $\mathbf{x}^*$ の絶対値を用いて、重みを $w_n = |x_n^*|^{-1}$ とすることで、逆順序重み付き ℓ_1 ノルム (ROWL) と同様の効果が得られる。しかし、真の信号の絶対値を事前に知ることは不可能である。そこで、次のような手続きにより、重み $w_n = |x_n^*|^{-1}$ を推定することを考える。

1. 初期値 $w_n^{(0)} = 1, \forall n = 1, \dots, N$ を設定する。
2. 重み付き ℓ_1 ノルムの最適化問題を解く

$$\mathbf{x}^{(k+1)} = \arg \min_{\mathbf{x}} \sum_{n=1}^N w_n^{(k)} |x_n| \quad \text{s.t.} \quad \mathbf{y} = \mathbf{L}\mathbf{x}$$

3. 推定した $\mathbf{x}^{(k+1)}$ に基づいて、重みを $w_n^{(k+1)} = \left(|x_n^{(k+1)}| + \epsilon \right)^{-1}$ に更新する。
4. 収束するまで 2. と 3. を繰り返す。

$\epsilon > 0$ は重みの安定性を保つための定数である。このアルゴリズムの有効性は、[69] の数値実験において経験的に示されている。実は、この手続きは再重み付け ℓ_1 ノルム (Reweighted ℓ_1 norm, RWL1) の最適化問題

$$\min_{\mathbf{x}} \sum_{n=1}^N \log(|x_n| + \epsilon) \quad \text{s.t.} \quad \mathbf{y} = \mathbf{L}\mathbf{x} \tag{1.10}$$




図 1.12: 再重み付き ℓ_1 ノルムの近接写像 [86, Fig.2]. (a) は $(\lambda, \epsilon) = (2, 3)$, つまり $\sqrt{\lambda} \leq \epsilon$ のときの近接写像, (b) は $(\lambda, \epsilon) = (3, 1)$, つまり $\sqrt{\lambda} > \epsilon$ のときの近接写像である. 点線は恒等写像を表す.

の最適解を MM アルゴリズム (Majorization-Minimization Algorithm) で求めることに相当する [69]. 凸最適化の反復によって, 非凸最適化アルゴリズムを解く点, RWL1 の特徴と言える.

再重み付き ℓ_1 ノルムは, 絶対値の対数を取ることで, ℓ_1 ノルムが信号の大きさを過小評価する問題を解決する. ここでは, 再重み付き ℓ_1 ノルムが負になることを防ぐために, [86] に倣って (1.10) の $|x_n| + \epsilon$ を $\frac{|x_n|}{\epsilon} + 1$ に置き換える. つまり, 再重み付き ℓ_1 ノルムを

$$\|\mathbf{x}\|_{w,1} = \sum_{n=1}^N \log \left(\frac{|x_n|}{\epsilon} + 1 \right). \quad (1.11)$$

と定義する. $\epsilon > 0$ は正則化の安定性を保つための小さな定数である. $\log \left(\frac{|x_n|}{\epsilon} + 1 \right) = \log(|x_n| + \epsilon) - \log(\epsilon)$ であるため, 先の置き換えは (1.10) の大域的最適解に影響を与えない.

また, RWL1 の近接写像のグラフを図 1.12 に示す. 図中の $\lambda > 0$ は正則化パラメータである. この図から, この近接写像は $\sqrt{\lambda} \leq \epsilon$ のときソフト閾値関数, $\sqrt{\lambda} > \epsilon$ のときハード閾値関数に近い振る舞いを示すことが分かる. 実際, RWL1 の近接写像は次の形で表される.

定理 1.2 (RWL1 の近接写像). $\sqrt{\lambda} \leq \epsilon$ のとき, 任意の $x \in \mathbb{R}$ に対して RWL1 の近接写

像は

$$\text{prox}_{\lambda\|\cdot\|_{w,1}}(x) = \begin{cases} 0 & \text{if } |x| \leq \lambda/\epsilon \\ \text{sign}(x)r_2(|x|) & \text{otherwise} \end{cases}$$

と表される．ここで， $r_2(x)$ は次で定義される．

$$r_2(x) = \frac{1}{2}(x - \epsilon) + \sqrt{\frac{1}{4}(x + \epsilon)^2 - \lambda}$$

また， $\sqrt{\lambda} > \epsilon$ のときの近接写像は次で与えられる．

$$\text{prox}_{\lambda\|\cdot\|_{w,1}}(x) = \begin{cases} 0 & \text{if } |x| \leq x_* \\ \{0, \text{sign}(x)r_2(x_*)\} & \text{if } |x| = x_* \\ \text{sign}(x)r_2(|x|) & \text{otherwise} \end{cases}$$

ここで， x_* は関数 $r(x) = q_{\lambda,x}(r_2(x)) - q_{\lambda,x}(0)$ の根であり，関数 $q_{\lambda,x}(z)$ は

$$q_{\lambda,x}(y) = \frac{1}{2\lambda}(y - x)^2 + \log\left(\frac{y}{\epsilon} + 1\right)$$

と定義される． x_* は二分法 (bisection method) によって容易に計算できる．これは， z_* が閉区間 $[2\sqrt{\lambda} - \epsilon, \frac{\lambda}{\epsilon}]$ に存在し，また $r(2\sqrt{\lambda} - \epsilon) > 0$ かつ $r(\frac{\lambda}{\epsilon}) < 0$ が成り立つためである [86, Proposition 2]. $\square$

再重み付き ℓ_1 ノルムは，絶対値の対数を取ることで信号の大きさを過小評価する問題を解決する．また，RWL1 は MM アルゴリズムの観点から見ると，重み付き ℓ_1 ノルムの適切な重みを推定する方法としても解釈できる．そして，RWL1 の近接写像は，ソフト閾値関数とハード閾値関数の中間的な振る舞いを示す． $\square$

例 1.6 (指数ノルム)．対数関数の代わりに，指数関数を正則化項に用いることを考える．指数ノルムでは，絶対値の指数関数を用いて，信号の大きさを過小評価する問題を解決する．指数ノルムは上限が N ($\forall n, x_n \rightarrow \infty$ のとき) であるため，無限大に発散する再重み付き ℓ_1 ノルムよりも過小評価によるバイアスが小さい．指数ノルムは

$$\|\mathbf{x}\|_{\sigma,e} = \sum_{n=1}^N 1 - \exp(-|x_n|/\sigma)$$

と定義される． $\sigma > 0$ は指数ノルムのスケールを調整する定数である．また，指数ノルムの近接写像のグラフを図 1.13 に示す．指数ノルムの近接写像は， σ が小さいときはソフト閾値関数，ある程度大きな σ に対してはハード閾値関数のように振る舞う． $\square$

例 1.7 (キャップ付き ℓ_1 ノルム)． ℓ_1 ノルムに上限を設けることで， ℓ_1 ノルムのバイアスを解消するアプローチを考える．指数ノルムと同様に，キャップ付き ℓ_1 ノルムは上限値を持




図 1.13: $\lambda = 1$ のときの指数ノルムの近接写像 [87, Fig.3].

つため、過小評価のバイアスが再重み付き ℓ_1 ノルムよりも小さい。キャップ付き ℓ_1 ノルムは、

$$\|\mathbf{x}\|_{\text{cap},1} = \sum_{n=1}^N \min(\theta|x_n|, 1)$$

のように定義される。ここで、 $\theta > 0$ はキャップの大きさを調整する定数である。キャップ付き ℓ_1 ノルムの近接写像は $x \in \mathbb{R}$ に対して

$$\text{prox}_{\lambda\|\cdot\|_{\text{cap},1}}(x) = \begin{cases} x \cdot \mathbf{I}(|x| > \sqrt{2\lambda}) + \{0, x\} \cdot \mathbf{I}(|x| = \sqrt{2\lambda}) & \text{if } \lambda\theta^2 \geq 2 \\ \text{sign}(x)(|x| - \lambda\theta) \cdot \mathbf{I}\left(\lambda\theta < |x| < \frac{1}{\theta} + \frac{\lambda\theta}{2}\right) & \text{if } \lambda\theta^2 < 2 \\ + x \cdot \mathbf{I}\left(|x| \geq \frac{1}{\theta} + \frac{\lambda\theta}{2}\right) & \end{cases}$$

と表される [88]。ここで、集合と実数の積は、その集合の要素に対して実数を掛ける演算を表す。つまり、実数 a と集合 X に対して、 $A \cdot a = \{ax \mid x \in X\}$ である。□

1.6 本研究の目的

LOP- ℓ_2/ℓ_1 の応用先の拡大 LOP- ℓ_2/ℓ_1 は、信号 $\mathbf{x}$ のブロックスパース性を評価することができるものの、 $\mathbf{x}$ の特徴量のブロックスパース性を評価するための数学的な枠組みと実用性の両方において、未解決の課題がある。特徴量のブロックスパース性を評価する手順を図 1.10 に示す。まず、信号 $\mathbf{x}$ を特徴量 $\mathbf{v}$ に変換する。次に、特徴量 $\mathbf{v}$ のブロック構造を推定する。最後に、推定したブロック構造を用いて、特徴量 $\mathbf{v}$ のブロックスパース性を評価す

る．特徴量のブロックスパース性評価に関する課題を解決するために、まず、 $\mathbf{x}$ の特徴量を入力とした $\text{LOP-}\ell_2/\ell_1$ 正則化項を提案し、その最適化アルゴリズムと収束条件の解析、その有効性の検証を行う．

更に、 $\text{LOP-}\ell_2/\ell_1$ は、観測モデルとして線形 (重回帰) モデルを仮定しているため、ニューラルネットワークなどの非線形モデルには適用できない．これは、 $\text{LOP-}\ell_2/\ell_1$ の最適化アルゴリズムが線形モデルに特化しており、かつ $\text{LOP-}\ell_2/\ell_1$ 正則化項が微分可能でないためである．この課題を解決するために、微分可能なブロックスパース正則化をもとにした、微分可能な $\text{LOP-}\ell_2/\ell_1$ 正則化項を提案する．また、この正則化項を導出する過程で得られる、 $\text{LOP-}\ell_2/\ell_1$ 正則化項の新たな定式化は、ADMM などの交互最適化アルゴリズムとの相性がより優れている．これにより、 $\text{LOP-}\ell_2/\ell_1$ を他の正則化 (例えば、TV 正則化や低ランク正則化) と組み合わせる際の、最適化アルゴリズムの効率化が実現される．

加えて、高次元データの 1 つであるテンソル (多次元配列) のデータ処理に対して、適応的ブロックスパース正則化を応用する研究は発展の途上である．これは、テンソルデータの多く (動画やハイパースペクトル画像など) が高次元であり、貪欲法やベイズ的手法などの従来の適応的ブロックスパース正則化を適用することが、計算量の観点で難しかったためだと予想される．テンソルにおいては、エッジ成分や多層スパース行列、外れ値テンソルなどがブロック構造を持つ．そのため、適応的ブロックスパース正則化を用いることで、テンソル補完やノイズ除去の性能向上が期待される．そこで、これらの特徴量に対して適応的ブロックスパース正則化を利用する手法を提案し、テンソル補完における有効性を検証する．

LOP- ℓ_2/ℓ_1 と ROWL の性能向上 $\text{LOP-}\ell_2/\ell_1$ は、真のブロック構造における混合 ℓ_2/ℓ_0 ノルムを、凸緩和により近似しているため、推定結果にバイアスが生じる．この課題は、非凸なスパース正則化項を用いて $\text{LOP-}\ell_2/\ell_1$ のバイアスを低減し、より混合 ℓ_2/ℓ_0 ノルムに近いスパース推定を行うことで解決する．スパース正則化においては、再重み付き ℓ_1 ノルムのように、対数関数により ℓ_1 ノルムを ℓ_0 ノルムに近似する手法が提案されている．ただし、このようなアプローチを $\text{LOP-}\ell_2/\ell_1$ へ同様に適用することは、その関数形 (2.9) のため容易でない．また、ROWL は元々非凸スパース正則化であるものの、その計算に絶対値関数を含むため ℓ_1 ノルムと同様の推定バイアスが生じる．この課題は、非凸なスパース正則化項を用いて ROWL のバイアスを低減することで解決できる．

本研究では、 $\text{LOP-}\ell_2/\ell_1$ に対して、対数関数を用いた非凸な適応的ブロックスパース正則化項を定式化し、その性質を調査する．また、線形モデルに対するこの正則化項の最適化アルゴリズムを提案する．さらに、対数関数や指数関数などの非凸関数を用いた ROWL の一般化手法を提案し、ROWL の推定バイアスを低減する．また、一般化した ROWL の近接




図 1.14: 本研究の貢献と先行研究との関連性

写像が緩い仮定のもとで解析的に導出できることも示す。

以上の目的を達成するアプローチをまとめると、次のようになる：

本研究の貢献
- 線形変換で得られる特徴量の LOP-ℓ_2/ℓ_1 を評価するための、最適化アルゴリズムの提案と収束条件の解析 (第 3 章). - 微分可能な LOP-ℓ_2/ℓ_1 の提案 (第 5 章). - 多層スパース行列や外れ値テンソルに現れるブロック構造を利用したテンソル分解手法の提案 (第 6 章). - 対数関数を用いた非凸な LOP-ℓ_2/ℓ_1 の提案 (第 4 章). - 非凸関数を用いた ROWL の一般化手法の提案と近接写像の導出 (第 4 章).

また、本研究の貢献と先行研究との関連性を 図 1.14 にまとめる。

1.7 本論文の構成

第 2 章において、提案手法の基礎である LOP- ℓ_2/ℓ_1 とその最適化アルゴリズムを導入す

る. 次に, 第 3 章では, 特徴空間でのブロックスパース性を評価するために $\text{LOP-}\ell_2/\ell_1\text{ALT}$ とその最適化アルゴリズムと最適解収束条件を提案する. 第 4 章では, 非凸関数を用いた適応的ブロックスパース正則化のアプローチを導入する. この方法を用いることで, $\text{LOP-}\ell_2/\ell_1$ が, 真のブロック構造における混合 ℓ_2/ℓ_0 ノルムにより近いブロックスパース性を評価できるようになる. また, 非凸関数を用いて ROWL の推定バイアスを低減する手法を提案する. 第 5 章では, 微分可能な非凸スパース正則化項を新たに提案し, その性質を調査する. 加えて, この正則化項に基づき, 微分可能な適応的ブロックスパース正則化項を提案する. 更に, 第 6 章において, テンソルの多層スパース性に現れるブロック構造を利用した CP 分解とその最適化アルゴリズムを提案する. 加えて, 外れ値テンソルに現れるブロックスパース性を利用して, 外れ値に頑健なテンソル分解 (テンソルロバスト主成分分析) をより効果的に行う手法を提案する. 第 7 章において, 提案した手法の性能を画像復元や分類のタスクによって評価した結果を示す. 最後に, 第 8 章で本論文のまとめと今後の展望を述べる.

第 2 章

凸緩和された適応的ブロックスパース正則化

2.1 Latent Optimally Partitioned ℓ_2/ℓ_1 (LOP- ℓ_2/ℓ_1)

LOP- ℓ_2/ℓ_1 [40] は LOP- ℓ_2/ℓ_1 正則化項という凸な正則化項を用いて、重複のない真のブロックの構造を推定することで、適応的ブロックスパース正則化を行う手法である。

まず、重複のないブロック構造の族は定義 2.1 によって定義される。これ以降、断りがなければ、ブロック構造は重複のないものとする。この性質は、ブロックの推定を容易にするために重要である。

定義 2.1 (重複のないブロック構造の族). 重複のない濃度 j のブロック構造の族 $\mathcal{P}_j$ は

$$\begin{aligned}
 (\mathcal{B}_k)_{k=1}^j &\in \mathcal{P}_j \\
 \iff \begin{cases} \bigcup_{k=1}^j \mathcal{B}_k = \{1, \dots, N\}, \\ \mathcal{B}_k \neq \emptyset \quad (k = 1, \dots, j), \\ \mathcal{B}_k \cap \mathcal{B}_{k'} = \emptyset \quad (k \neq k'), \\ \mathcal{B}_k = \{n \in \{1, \dots, N\} \mid n_k \leq n \leq m_k\} \\ \text{for some } n_k, m_k \in \{1, \dots, N\} \quad (k = 1, \dots, j) \end{cases}
 \end{aligned} \tag{2.1}$$

を満たす集合族である。1つ目の条件は、全ての要素がいずれかのブロックに含まれることを示す。2つ目の条件は、全てのブロックが空でないことを示す。3つ目の条件は、全てのブロックが互いに重ならないことを示す。4つ目の条件は、全てのブロックが連なっていることを示す。つまり、全ての $k = 1, \dots, j$ に対して $\mathcal{B}_k = \{n_k, n_k + 1, n_k + 2, \dots, m_k - 2, m_k - 1, m_k\}$ が成り立つ。□

続いて、与えられた $\mathbf{x} \in \mathbb{R}^N$ に対して、その混合 ℓ_2/ℓ_1 ノルムを最小化する重複のない

K 個以下のブロック集合

$$(\hat{\mathcal{B}}_k)_{k \leq K} = \arg \min_{(\mathcal{B}_k)_{k \leq K}} \|\mathbf{x}\|_{2,1}^{(\mathcal{B}_k)_k}$$

を LOP- ℓ_2/ℓ_1 におけるブロック構造の推定結果とする．そして，推定されたブロック構造に基づいて評価される混合 ℓ_2/ℓ_1 ノルムを

$$\psi_K(\mathbf{x}) := \min_{j \in \{1, \dots, K\}} \left[\min_{(\mathcal{B}_k)_{k=1}^j \in \mathcal{P}_j} \|\mathbf{x}\|_{2,1}^{(\mathcal{B}_k)_{k=1}^j} \right] = \min_{j \in \{1, \dots, K\}} \left[\min_{(\mathcal{B}_k)_{k=1}^j \in \mathcal{P}_j} \sum_{k=1}^j \sqrt{|\mathcal{B}_k|} \|\mathbf{x}_{\mathcal{B}_k}\|_2 \right] \quad (2.2)$$

と定義する．混合 ℓ_2/ℓ_1 ノルムを最小化するブロック構造（ブロック数は K 以下）を選ぶことで，ゼロ成分と非ゼロ成分の両方からなる，真でない不適切なブロック構造の推定を避けることができる．つまり， K を真のブロック数 K^* に等しく設定することで， $\psi_K(\mathbf{x})$ の最小化は真のブロック構造を推定する．

例 2.1 (不適切なブロック構造が混合 ℓ_2/ℓ_1 ノルムの値を増加させる例). 不適切なブロック構造の簡単な例を図 2.1 に示す．ここでは，このような場合に混合 ℓ_2/ℓ_1 ノルムの値が増加することを，より一般的に証明する． $N > 0$, $\ell \in \{1, \dots, N\}$ とおいて， $\mathcal{B}_1^* = \{1, \dots, N - \ell\}$, $\mathcal{B}_2^* = \{N - \ell + 1, \dots, N\}$ かつ

$$|x_n| = \begin{cases} 1 & (n \in \mathcal{B}_1^*) \\ 0 & (n \in \mathcal{B}_2^*) \end{cases}$$

を満たすベクトル $\mathbf{x}$ を考える． $\mathcal{B}_1^*, \mathcal{B}_2^*$ は真のブロック構造で

$$\begin{aligned} \|\mathbf{x}\|_{2,1}^{(\mathcal{B}_1^*, \mathcal{B}_2^*)} &= \sqrt{N - \ell} \|\mathbf{x}\|_{\mathcal{B}_1^*} + \sqrt{\ell} \|\mathbf{x}\|_{\mathcal{B}_2^*} \\ &= \sqrt{N - \ell} \cdot \sqrt{N - \ell} + \sqrt{\ell} \cdot 0 \\ &= N - \ell \end{aligned}$$

である．ここで $d \in \{\ell - N + 1, \dots, -1\} \cup \{1, \dots, \ell\}$ を任意に選び，不適切なブロック構造として $\tilde{\mathcal{B}}_1 = \{1, \dots, N - \ell + d\}$, $\tilde{\mathcal{B}}_2 = \{N - \ell + d + 1, \dots, N\}$ を与える． $\tilde{\mathcal{B}}_1, \tilde{\mathcal{B}}_2$ は真のブロック構造 $\mathcal{B}_1^*, \mathcal{B}_2^*$ を d だけずらしたものである．右にずらす場合，つまり $d > 0$ ならば

$$\begin{aligned} \|\mathbf{x}\|_{2,1}^{(\tilde{\mathcal{B}}_1, \tilde{\mathcal{B}}_2)} &= \sqrt{N - \ell + d} \|\mathbf{x}\|_{\tilde{\mathcal{B}}_1} + \sqrt{\ell - d} \|\mathbf{x}\|_{\tilde{\mathcal{B}}_2} \\ &= \sqrt{N - \ell + d} \cdot \sqrt{N - \ell} + \sqrt{\ell - d} \cdot 0 \\ &> N - \ell = \|\mathbf{x}\|_{2,1}^{(\mathcal{B}_1^*, \mathcal{B}_2^*)} \end{aligned}$$

が成り立つ．同様に左にずらす場合，つまり $d < 0$ ならば

$$\|\mathbf{x}\|_{2,1}^{(\tilde{\mathcal{B}}_1, \tilde{\mathcal{B}}_2)} = \sqrt{N - \ell + d} \cdot \sqrt{N - \ell + d} + \sqrt{\ell - d} \cdot \sqrt{d}$$




図 2.1: (左) ベクトル $\mathbf{x}$ を適切な 2 つのブロック $\mathcal{B}_1^*$ と $\mathcal{B}_2^*$ で分割したもの. (右) 不適切な 2 つのブロック $\tilde{\mathcal{B}}_1$ と $\tilde{\mathcal{B}}_2$ で分割したもの.

$$\begin{aligned}
 &= \sqrt{(N - \ell)^2 + d(2N - \ell)} \\
 &> N - \ell = \|\mathbf{x}\|_{2,1}^{(\mathcal{B}_1^*, \mathcal{B}_2^*)}
 \end{aligned}$$

が成り立つ. したがって, $\|\mathbf{x}\|_{2,1}^{(\tilde{\mathcal{B}}_1, \tilde{\mathcal{B}}_2)} > \|\mathbf{x}\|_{2,1}^{(\mathcal{B}_1^*, \mathcal{B}_2^*)}$ であるから, 不適切なブロック構造 $\tilde{\mathcal{B}}_1, \tilde{\mathcal{B}}_2$ は混合 ℓ_2/ℓ_1 ノルムの値を増加させる. $\square$

注意 2.1 (混合 ℓ_2/ℓ_1 ノルムの重みの妥当性). 混合 ℓ_2/ℓ_1 ノルム (1.8) の重み $\sqrt{|\mathcal{B}_k|}$ は, ブロック推定 (2.2) の自明な解を避けるために導入される. (1.8) に $\sqrt{|\mathcal{B}_k|}$ がない場合, (2.2) の推定結果はただ一つのブロック, つまり $j = 1$ となる. これは, 任意の $\mathcal{B} \subset \{1, \dots, N\}$ と, $\mathcal{B}$ を分解したブロック構造 $\mathcal{B} = \mathcal{B}' \cup \mathcal{B}''$ ($\mathcal{B}' \neq \emptyset, \mathcal{B}'' \neq \emptyset$) に対して, 三角不等式から導かれる不等式

$$\|\mathbf{x}_{\mathcal{B}}\|_2 \leq \|\mathbf{x}_{\mathcal{B}'}\|_2 + \|\mathbf{x}_{\mathcal{B}''}\|_2$$

が成り立つためである. よって, 大きいブロックに対して, 小さなブロックよりも大きなペナルティを与える必要がある. 混合 ℓ_2/ℓ_1 ノルムの重み $\sqrt{|\mathcal{B}_k|}$ は, このような性質を持つ. 先程と同様に, ブロック $\mathcal{B}$ が分解できる場合を考える. 加えて, $\mathbf{x}_{\mathcal{B}'} \neq \mathbf{0}$ かつ $\mathbf{x}_{\mathcal{B}''} = \mathbf{0}$ であると仮定する. このとき, $|\mathcal{B}| > |\mathcal{B}'|$, そして $\|\mathbf{x}_{\mathcal{B}}\|_2 = \|\mathbf{x}_{\mathcal{B}'}\|_2 \neq 0, \|\mathbf{x}_{\mathcal{B}''}\|_2 = 0$ であるから,

$$\sqrt{|\mathcal{B}|}\|\mathbf{x}_{\mathcal{B}}\|_2 > \sqrt{|\mathcal{B}'|}\|\mathbf{x}_{\mathcal{B}'}\|_2 + \sqrt{|\mathcal{B}''|}\|\mathbf{x}_{\mathcal{B}''}\|_2.$$

この不等式は, (2.2) の目的関数が $\mathbf{x}_{\mathcal{B}}$ を, その非ゼロ成分のブロック $\mathbf{x}_{\mathcal{B}'}$ とゼロ成分のブロック $\mathbf{x}_{\mathcal{B}''}$ に分解することを促す. したがって, 混合 ℓ_2/ℓ_1 ノルムの重み $\sqrt{|\mathcal{B}_k|}$ は, ブロック推定の自明な解を避けるために妥当である. $\square$

LOP- ℓ_2/ℓ_1 正則化項の導出 (2.2) は, ブロック構造の選択肢が組合せ爆発するために, 厳密に計算することは NP 困難である. これを解消するため, 最初に ℓ_2 ノルムの変分表現 (2.3) を導入し, 混合 ℓ_2/ℓ_1 ノルムを別の形で表す.

補題 2.1 (ℓ_2 ノルムの変分表現を用いた混合 ℓ_2/ℓ_1 ノルムの置換え). ℓ_2 ノルムの変分表現 $\phi: \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}_+ \cup \{\infty\}$ を

$$\phi(x, \tau) := \begin{cases} \frac{|x|^2}{2\tau} + \frac{\tau}{2} & \text{if } \tau > 0 \\ 0 & \text{if } x = 0 \text{ and } \tau = 0 \\ \infty & \text{otherwise} \end{cases} \quad (2.3)$$

と定義する. $\phi(x, \tau)$ は x, τ について凸である. すると, $|x| = \min_{\tau \in \mathbb{R}} \phi(x, \tau)$ であり, 任意のブロック $\mathcal{B} \subset \{1, \dots, N\}$ に対して

$$\sqrt{|\mathcal{B}|} \|\mathbf{x}_{\mathcal{B}}\|_2 = \min_{\tau \in \mathbb{R}} \sum_{n \in \mathcal{B}} \phi(x_n, \tau) \quad (2.4)$$

を満たす [40, Appendix B]. □

(2.4) を (2.2) へ代入すると, $\psi_K(\mathbf{x})$ は次のように表される:

$$\psi_K(\mathbf{x}) = \min_{j \in \{1, \dots, K\}} \left[\min_{\substack{\tau \in \mathbb{R}^j \\ (\mathcal{B}_k)_{k=1}^j \in \mathcal{P}_j}} \sum_{k=1}^j \sum_{n \in \mathcal{B}_k} \phi(x_n, \tau_k) \right]. \quad (2.5)$$

次に $\sigma_n = \tau_k$ ($n \in \mathcal{B}_k$ for $k = 1, \dots, j$) を満たす潜在ベクトル $\boldsymbol{\sigma} = (\sigma_1, \dots, \sigma_N)^\top \in \mathbb{R}^N$ を導入する. (2.5) の $\mathcal{B}_k$ ($k = 1, \dots, j$) は重なりのないブロックであるから, 微分作用素 $\mathbf{D} \in \mathbb{R}^{(N-1) \times N}$ によって, $\boldsymbol{\sigma}$ は次の条件を満たす:

$$\|\mathbf{D}\boldsymbol{\sigma}\|_0 \leq j - 1. \quad (2.6)$$

また, (2.1) より, $\bigcup_{k=1}^j \mathcal{B}_k = \{1, \dots, N\}$ かつ $\mathcal{B}_k \cap \mathcal{B}_{k'} = \emptyset$ ($k \neq k'$) であるから

$$\sum_{k=1}^j \sum_{n \in \mathcal{B}_k} \phi(x_n, \tau_k) = \sum_{n=1}^N \phi(x_n, \sigma_n) \quad (2.7)$$

が成り立つ. ゆえに, $\psi_K(\mathbf{x})$ は (2.6), (2.7) より

$$\psi_K(\mathbf{x}) = \min_{j \in \{1, \dots, K\}} \left[\min_{\substack{\boldsymbol{\sigma} \in \mathbb{R}^N \\ \|\mathbf{D}\boldsymbol{\sigma}\|_0 \leq j-1}} \sum_{n=1}^N \phi(x_n, \sigma_n) \right] = \min_{\substack{\boldsymbol{\sigma} \in \mathbb{R}^N \\ \|\mathbf{D}\boldsymbol{\sigma}\|_0 \leq K-1}} \sum_{n=1}^N \phi(x_n, \sigma_n) \quad (2.8)$$

と表される. $\phi(x, \sigma)$ は凸関数であるものの, (2.8) は非凸制約 $\|\mathbf{D}\boldsymbol{\sigma}\|_0 \leq K - 1$ を含む. そこで, この制約を $\|\mathbf{D}\boldsymbol{\sigma}\|_1 \leq \alpha$ へ凸緩和して $\psi_K(\mathbf{x})$ を凸関数で近似する. このようにして得られた凸関数

$$\Psi_\alpha(\mathbf{x}) := \min_{\substack{\boldsymbol{\sigma} \in \mathbb{R}^N \\ \|\mathbf{D}\boldsymbol{\sigma}\|_1 \leq \alpha}} \sum_{n=1}^N \phi(x_n, \sigma_n) \quad (2.9)$$

を LOP- ℓ_2/ℓ_1 正則化項という．ここで， α は推定されるブロック数を制御するハイパーパラメータである． α が大きいほど，推定されるブロックの数は増加する．例えば， $\alpha = 0$ ならば， $\|\mathbf{D}\boldsymbol{\sigma}\|_1 = 0$ となり，ブロック数は 1 である．すなわち， $\alpha = 0$ のとき $\Psi_0(\mathbf{x})$ は ℓ_2 ノルムを評価する．一方， $\alpha \rightarrow \infty$ ならば， $\|\mathbf{D}\boldsymbol{\sigma}\|_1 \leq \alpha$ は常に満たされるため，ブロック数は $N - 1$ である．したがって， $\alpha \rightarrow \infty$ のとき $\Psi_\infty(\mathbf{x})$ は ℓ_1 ノルムを評価する． α の適切な選び方は [40, Remark 3] で議論されている．

(1.2) において $h = \Psi_\alpha$ ， $\mathbf{R} = \mathbf{I}$ とおいた最適化問題

$$\min_{\mathbf{x} \in \mathbb{R}^N} f(\mathbf{L}\mathbf{x}) + \Psi_\alpha(\mathbf{x}) \quad (2.10)$$

を解くことで，真のブロック構造と混合 ℓ_2/ℓ_1 ノルムに基づく適応的ブロックスパース正則化：LOP- ℓ_2/ℓ_1 正則化を行う．LOP- ℓ_2/ℓ_1 正則化項は凸関数である [40, Theorem 1] ため， f が二乗誤差や絶対誤差などの凸関数であれば，(2.10) は凸最適化問題となり容易に解くことができる．

2.2 最適化アルゴリズム

LOP- ℓ_2/ℓ_1 正則化 (2.10) は， $\min_{\mathbf{w} \in \mathbb{R}^N} G(\mathbf{w})$ s.t. $\mathbf{H}\mathbf{w} = \mathbf{0}$ の形式に変換できる：

$$\begin{aligned} & \min_{\substack{(\mathbf{x}, \boldsymbol{\sigma}) \in \mathbb{R}^N \times \mathbb{R}^N \\ (\mathbf{u}, \boldsymbol{\eta}) \in \mathbb{R}^J \times \mathbb{R}^{N-1}}} \underbrace{f(\mathbf{u}) + \varphi(\mathbf{x}, \boldsymbol{\sigma}) + \iota_{B_1^\alpha}(\boldsymbol{\eta})}_{=: G(\mathbf{w})} \\ & \text{s.t. } \underbrace{\begin{bmatrix} \mu_1 \mathbf{L} & \mathbf{O} & -\mu_1 \mathbf{I} & \mathbf{O} \\ \mathbf{O} & \mu_2 \mathbf{D} & \mathbf{O} & -\mu_2 \mathbf{I} \end{bmatrix}}_{=: \mathbf{H}} \underbrace{\begin{bmatrix} \mathbf{x} \\ \boldsymbol{\sigma} \\ \mathbf{u} \\ \boldsymbol{\eta} \end{bmatrix}}_{=: \mathbf{w}} = \mathbf{0}. \end{aligned} \quad (2.11)$$

まず，関数 $\varphi : \mathbb{R}^N \times \mathbb{R}^N \rightarrow \mathbb{R}_{\geq 0}$ を関数 $\phi(x, \sigma)$ の和として定義する：

$$\varphi(\mathbf{x}, \boldsymbol{\sigma}) = \sum_{n=1}^N \phi(x_n, \sigma_n). \quad (2.12)$$

次に，等式制約 $\mathbf{u} = \mathbf{L}\mathbf{x}$ ， $\boldsymbol{\eta} = \mathbf{D}\boldsymbol{\sigma}$ を与え，これらの制約に対応する行列 $\mathbf{H}$ とベクトル $\mathbf{w}$ を定義する． $\mathbf{H}$ に現れる μ_1, μ_2 は，最適化アルゴリズムの収束性を保証するためのパラメータである．また，不等式制約 $\|\mathbf{D}\boldsymbol{\sigma}\|_1 \leq \alpha$ を ℓ_p 球の指示関数

$$\iota_{B_p^\alpha}(\boldsymbol{\eta}) := \begin{cases} 0 & \text{if } \|\boldsymbol{\eta}\|_p \leq \alpha \\ \infty & \text{otherwise} \end{cases} \quad (2.13)$$

アルゴリズム 1 Solver for LOP- ℓ_2/ℓ_1

1: **Input:** $\gamma > 0$, $0 < \mu_1 \leq \frac{1}{\sqrt{\|\mathbf{L}\|_{\text{op}}^2 + 1}}$, $0 < \mu_2 \leq \frac{1}{\sqrt{\|\mathbf{D}\|_{\text{op}}^2 + 1}}$,
 and $\mathbf{x}^0 \in \mathbb{R}^N$, $\boldsymbol{\sigma}^0 \in \mathbb{R}^N$, $\mathbf{u}^0 \in \mathbb{R}^J$, $\boldsymbol{\eta}^0 \in \mathbb{R}^{N-1}$, $\mathbf{r}_1^0 \in \mathbb{R}^J$, $\mathbf{r}_2^0 \in \mathbb{R}^{N-1}$.

2: **for** $i = 0, 1, 2, \dots, L$ **do**

3: $\tilde{\mathbf{x}}^{i+1} = \mathbf{x}^i + \mu_1 \mathbf{L}^\top (\mathbf{r}_1^i - \mu_1 (\mathbf{L} \mathbf{x}^i - \mathbf{u}^i))$

4: $\tilde{\boldsymbol{\sigma}}^{i+1} = \boldsymbol{\sigma}^i + \mu_2 \mathbf{D}^\top (\mathbf{r}_2^i - \mu_2 (\mathbf{D} \boldsymbol{\sigma}^i - \boldsymbol{\eta}^i))$

5: $\tilde{\mathbf{u}}^{i+1} = \mathbf{u}^i - \mu_1 (\mathbf{r}_1^i - \mu_1 (\mathbf{L} \mathbf{x}^i - \mathbf{u}^i))$

6: $\tilde{\boldsymbol{\eta}}^{i+1} = \boldsymbol{\eta}^i - \mu_2 (\mathbf{r}_2^i - \mu_2 (\mathbf{D} \boldsymbol{\sigma}^i - \boldsymbol{\eta}^i))$

7: $(\mathbf{x}^{i+1}, \boldsymbol{\sigma}^{i+1}) = \text{prox}_{\gamma \lambda \varphi}(\tilde{\mathbf{x}}^{i+1}, \tilde{\boldsymbol{\sigma}}^{i+1})$

8: $\mathbf{u}^{i+1} = \text{prox}_{\gamma f}(\tilde{\mathbf{u}}^{i+1})$

9: $\boldsymbol{\eta}^{i+1} = P_{B_1^\alpha}(\tilde{\boldsymbol{\eta}}^{i+1})$

10: $\mathbf{r}_1^{i+1} = \mathbf{r}_1^i - \mu_1 (\mathbf{L} \mathbf{x}^{i+1} - \mathbf{u}^{i+1})$

11: $\mathbf{r}_2^{i+1} = \mathbf{r}_2^i - \mu_2 (\mathbf{D} \boldsymbol{\sigma}^{i+1} - \boldsymbol{\eta}^{i+1})$

Output: $\mathbf{x}^{L+1} \in \mathbb{R}^N$, $\boldsymbol{\sigma}^{L+1} \in \mathbb{R}^K$

の $p = 1$ の場合を用いて表す. よって, LOP- ℓ_2/ℓ_1 正則化は, (2.11) の形式に対応し, 線形拡張ラグランジュ法 (A.3) と呼ばれる方法によって解くことができる. LOP- ℓ_2/ℓ_1 正則化の最適化アルゴリズム [40, Algorithm 1] をアルゴリズム 1 に示す. ここで, 半径 α の ℓ_1 ノルム球への射影を $a_k := \max \left\{ |\eta_k| - \frac{1}{K} \left(\sum_{t=1}^T \rho_t - \alpha \right), 0 \right\}$ を用いて

$$P_{B_1^\alpha}(\boldsymbol{\eta}) := \begin{cases} \boldsymbol{\eta} & \text{if } \|\boldsymbol{\eta}\|_1 \leq \alpha \\ (a_k \text{sign}(\eta_k))_{k=1}^{K-1} & \text{otherwise} \end{cases} \quad (2.14)$$

と定義する. $\rho_1, \dots, \rho_{K-1}$ は $|\eta_1|, \dots, |\eta_{K-1}|$ を降順にソートしたもので, $T := \max \left\{ t \in \{1, \dots, K-1\} \mid \frac{1}{t} \left(\sum_{n=1}^t \rho_n - \alpha \right) < \rho_t \right\}$ とする.

定理 2.1 (LOP- ℓ_2/ℓ_1 の最適解への収束). LOP- ℓ_2/ℓ_1 正則化の最適化アルゴリズム (アルゴリズム 1) は, 次の条件を満たすとき最適解へ収束する:

$$\begin{cases} 0 < \mu_1 \leq \frac{1}{\sqrt{\|\mathbf{L}\|_{\text{op}}^2 + 1}}, \\ 0 < \mu_2 \leq \frac{1}{\sqrt{\|\mathbf{D}\|_{\text{op}}^2 + 1}}. \end{cases}$$

本定理の証明は, 線形拡張ラグランジュ法の収束条件を LOP- ℓ_2/ℓ_1 正則化に適用することで得られる [40, Lemma 2]. □

つまり、 L, D の作用素ノルムを計算し、 μ_1, μ_2 を適切に選ぶことで、LOP- ℓ_2/ℓ_1 ((2.10)) の最適解への収束が保証される。また、アルゴリズム 1 を用いる場合の、LOP- ℓ_2/ℓ_1 正則化の計算量は次のとおりである [40, Remark 5].

注意 2.2 (LOP- ℓ_2/ℓ_1 の計算量). $\tau > 0$ のとき、 $\text{prox}_{\tau f}(\mathbf{u})$ が $\mathcal{O}(J)$ で計算できるとする。このとき、(2.10) の計算はアルゴリズム 1 を用いて $\mathcal{O}(JN)$ で行える。特に二乗誤差 $f(\mathbf{u}) = \frac{1}{2}\|\mathbf{y} - \mathbf{u}\|_2^2$ の場合は $\text{prox}_{\gamma f}(\mathbf{u}) = \frac{\gamma\mathbf{y} + \mathbf{u}}{\gamma + 1}$ 、絶対誤差 $f(\mathbf{u}) = \|\mathbf{y} - \mathbf{u}\|_1$ の場合は $\text{prox}_{\gamma f}(\mathbf{u}) = \left(u_j + \frac{\gamma}{\max\{|y_j - u_j|, \gamma\}}(y_j - u_j)\right)_{j=1}^J$ であり、これらは $\mathcal{O}(J)$ で計算できる。□

2.3 LOP- ℓ_2/ℓ_1 の問題点

LOP- ℓ_2/ℓ_1 正則化は、適応的ブロックスパース正則化を行うための、凸で計算量の少ない優れた方法である。しかし、いくつかの問題点がある。

1. 線形変換 $\mathbf{R}$ で得られる任意の特徴量 $\mathbf{R}\mathbf{x}$ のブロックスパース性を評価できない。
2. 凸緩和の影響で、推定結果にバイアスが生じる。
3. 微分不可能であり、勾配法を用いた最適化が難しい、または不可能である。

まず、問題点 1 について詳しく説明する。LOP- ℓ_2/ℓ_1 正則化の入力 $\mathbf{x}$ を、その線形変換された特徴量 $\mathbf{R}\mathbf{x}$ で評価する。 $\mathbf{R} \in \mathbb{R}^{K \times N}$ は線形変換である。つまり、

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x} \in \mathbb{R}^N} f(\mathbf{L}\mathbf{x}) + \Psi_\alpha(\mathbf{R}\mathbf{x}) \quad (2.15)$$

の最適解を求めることを考える。もし $\mathbf{R}$ が正則ならば、 $\mathbf{R}$ は逆行列 $\mathbf{R}^{-1}$ を持ち、(2.15) は次のように変形できる：

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x} \in \mathbb{R}^N} f(\mathbf{L}\mathbf{x}) + \Psi_\alpha(\mathbf{R}\mathbf{x}) = \arg \min_{\mathbf{x} \in \mathbb{R}^N} f(\mathbf{L}\mathbf{R}^{-1}\mathbf{R}\mathbf{x}) + \Psi_\alpha(\mathbf{R}\mathbf{x}). \quad (2.16)$$

よって、 $\mathbf{z} = \mathbf{R}\mathbf{x} \in \mathbb{R}^K$ 、 $\tilde{\mathbf{L}} = \mathbf{L}\mathbf{R}^{-1}$ とおくと、(2.16) は、

$$\hat{\mathbf{z}} = \arg \min_{\mathbf{z} \in \mathbb{R}^K} f(\tilde{\mathbf{L}}\mathbf{z}) + \Psi_\alpha(\mathbf{z}) \quad (2.17)$$

と $\hat{\mathbf{z}}$ を推定する問題となり、 $\hat{\mathbf{x}} = \mathbf{R}^{-1}\hat{\mathbf{z}}$ を計算することで (2.15) の最適解を求められる。よって、 $\mathbf{R}$ が正則ならば、 $\mathbf{R}$ で変換された特徴量 $\mathbf{R}\mathbf{x}$ のブロックスパース性を LOP- ℓ_2/ℓ_1 で評価することができる。しかし、 $\mathbf{R}$ が正則でない場合、(2.15) を (2.17) の形に変換することはできず、LOP- ℓ_2/ℓ_1 正則化は $\mathbf{R}\mathbf{x}$ のブロックスパース性を評価できない。

次に、問題点 2 について説明する。LOP- ℓ_2/ℓ_1 正則化は、真のブロック構造を推定したうえで混合 ℓ_2/ℓ_1 ノルムを評価する。しかし、混合 ℓ_2/ℓ_1 ノルムは凸であり、その値が信号の振幅の大きさに伴い増加するため、推定結果にバイアスが生じる。

最後に、問題点 3 について説明する。LOP- ℓ_2/ℓ_1 正則化項は、関数 $\phi(x, \tau)$ (2.3) とハード制約 $\|\mathbf{D}\boldsymbol{\sigma}\|_1 \leq \alpha$ を含む。この不連続性により、LOP- ℓ_2/ℓ_1 正則化は微分不可能である。

そこで、問題点 1 を解決するために、LOP- ℓ_2/ℓ_1 正則化項の入力を任意の線形特徴量へ拡張した、LOP- ℓ_2/ℓ_1 ALT 正則化を提案する (第 3 章)。また、問題点 2 を解決するために、対数関数を用いた LOP- ℓ_2/ℓ_1 の非凸化を行う (第 4 章)。問題点 3 を解決するために、LOP- ℓ_2/ℓ_1 を微分可能な関数で近似する方法を提案する (第 5 章)。

第 3 章

任意の線形変換における凸適応的ブロック スパース正則化

前章で導入した $\text{LOP-}\ell_2/\ell_1$ は、信号 $\mathbf{x}$ あるいは正則な線形変換 $\mathbf{R}\mathbf{x}$ のみに適用可能である。よって、微分などの非正則な線形変換には適用できない。これでは、信号のエッジ成分のような潜在的なブロックスパース信号を利用した正則化を行えない。本章では、 $\text{LOP-}\ell_2/\ell_1$ の入力を任意の線形変換に拡張する手法を提案することで、この問題を解決する。自然画像の微分はブロック構造を持つため、提案手法は自然画像の復元に有効であることが期待される。その有効性は数値実験によって示される (7.2 節)。

3.1 任意の線形変換における $\text{LOP-}\ell_2/\ell_1$

$\text{LOP-}\ell_2/\ell_1$ under Arbitrary Linear Transform ($\text{LOP-}\ell_2/\ell_1\text{ALT}$) は $\text{LOP-}\ell_2/\ell_1$ 正則化項 $\Psi_\alpha(\mathbf{x})$ の入力 $\mathbf{x}$ を線形特徴量 $\mathbf{R}\mathbf{x}$ へ拡張した手法である。 $\text{LOP-}\ell_2/\ell_1\text{ALT}$ による最適化問題は、(2.15) を再び用いて

$$\min_{\mathbf{x} \in \mathbb{R}^N} f(\mathbf{L}\mathbf{x}) + \Psi_\alpha(\mathbf{R}\mathbf{x}). \quad (3.1)$$

と表される。 $\text{LOP-}\ell_2/\ell_1\text{ALT}$ を用いることで $\text{LOP-}\ell_2/\ell_1$ では成し得なかった、任意の線形特徴量に対する適応的ブロックスパース正則化を行える。本正則化が有効な例として、本正則化を用いて画像のノイズ除去を行う様子を図 3.1 に示す。 $\text{LOP-}\ell_2/\ell_1\text{ALT}$ によって、エッジ画像 $\mathbf{R}\mathbf{x}$ に対する最適なブロック構造 σ の推定と、 $\mathbf{R}\mathbf{x}$ の混合 ℓ_2/ℓ_1 ノルムによるブロックスパース正則化を同時に行える。

次に $\text{LOP-}\ell_2/\ell_1\text{ALT}$ の最適化アルゴリズムを導出する。(3.1) は (2.9) を代入し、(2.12)




図 3.1: LOP- ℓ_2/ℓ_1 ALT を用いた画像のノイズ除去の流れ. $\|\mathbf{y} - \mathbf{x}\|$ は元画像 $\mathbf{y}$ と復元画像 $\mathbf{x}$ の近さを表し, ノイズの統計的性質に応じて ℓ_1 ノルムや ℓ_2 ノルムなどが用いられる.

の $\varphi(\mathbf{R}\mathbf{x}, \boldsymbol{\sigma})$ を用いることで

$$\min_{(\mathbf{x}, \boldsymbol{\sigma}) \in \mathbb{R}^N \times \mathbb{R}^K} f(\mathbf{L}\mathbf{x}) + \varphi(\mathbf{R}\mathbf{x}, \boldsymbol{\sigma}) \quad \text{s.t. } \|\mathbf{D}\boldsymbol{\sigma}\|_1 \leq \alpha \quad (3.2)$$

と書き換えられる. $\boldsymbol{\sigma} \in \mathbb{R}^K$ は $\mathbf{R}\mathbf{x}$ のブロック構造を推定するための変数である. 加えて, 等式制約 $\mathbf{u} = \mathbf{L}\mathbf{x}$, $\mathbf{v} = \mathbf{R}\mathbf{x}$, $\boldsymbol{\eta} = \mathbf{D}\boldsymbol{\sigma}$ を (3.2) へ適用し, 不等式制約 $\|\mathbf{D}\boldsymbol{\sigma}\|_1 \leq \alpha$ を ℓ_1 ノルム球の指示関数 $\iota_{B_1^\alpha}(\boldsymbol{\eta})$ (2.13) で置き換えると

$$\begin{aligned} & \min_{\substack{(\mathbf{x}, \boldsymbol{\sigma}) \in \mathbb{R}^N \times \mathbb{R}^K \\ (\mathbf{u}, \mathbf{v}, \boldsymbol{\eta}) \in \mathbb{R}^J \times \mathbb{R}^K \times \mathbb{R}^{K-1}}} \underbrace{f(\mathbf{u}) + \varphi(\mathbf{v}, \boldsymbol{\sigma}) + \iota_{B_1^\alpha}(\boldsymbol{\eta})}_{=: G(\mathbf{w})} \\ & \text{s.t. } \underbrace{\begin{bmatrix} \mu_1 \mathbf{L} & \mathbf{O} & -\mu_1 \mathbf{I} & \mathbf{O} & \mathbf{O} \\ \mu_2 \mathbf{R} & \mathbf{O} & \mathbf{O} & -\mu_2 \mathbf{I} & \mathbf{O} \\ \mathbf{O} & \mu_3 \mathbf{D} & \mathbf{O} & \mathbf{O} & -\mu_3 \mathbf{I} \end{bmatrix}}_{=: \mathbf{H}} \underbrace{\begin{bmatrix} \mathbf{x} \\ \boldsymbol{\sigma} \\ \mathbf{u} \\ \mathbf{v} \\ \boldsymbol{\eta} \end{bmatrix}}_{=: \mathbf{w}} = \mathbf{0} \end{aligned} \quad (3.3)$$

と書き換えられる. (3.3) を線形拡張ラグランジュ法 (アルゴリズム 6) に当てはめて解くと, LOP- ℓ_2/ℓ_1 ALT の最適化アルゴリズム (アルゴリズム 2) を得る.

注意 3.1 (LOP- ℓ_2/ℓ_1 ALT の計算量). $\gamma > 0$ において $\text{prox}_{\gamma f}(\mathbf{u})$ が $\mathcal{O}(J)$ で計算でき

アルゴリズム 2 LOP- ℓ_2/ℓ_1 ALT

Input: $\gamma, \mu_1, \mu_2, \mu_3 > 0$, $\mathbf{x}^0 \in \mathbb{R}^N$, $\boldsymbol{\sigma}^0 \in \mathbb{R}^K$, $\mathbf{u}^0 \in \mathbb{R}^J$, $\mathbf{v}^0 \in \mathbb{R}^K$, $\boldsymbol{\eta}^0 \in \mathbb{R}^{K-1}$, $\mathbf{r}_1^0 \in \mathbb{R}^J$, $\mathbf{r}_2^0 \in \mathbb{R}^K$, $\mathbf{r}_3^0 \in \mathbb{R}^{K-1}$, $\Delta \mathbf{r}_1^0 \in \mathbb{R}^J$, $\Delta \mathbf{r}_2^0 \in \mathbb{R}^K$, $\Delta \mathbf{r}_3^0 \in \mathbb{R}^{K-1}$

for $i = 0, 1, 2, \dots, L$ **do**

$$\begin{aligned}
 \tilde{\mathbf{x}}^{i+1} &= \mathbf{x}^i + \mu_1 \mathbf{L}^\top (\mathbf{r}_1^i - \Delta \mathbf{r}_1^i) + \mu_2 \mathbf{R}^\top (\mathbf{r}_2^i - \Delta \mathbf{r}_2^i) \\
 \tilde{\boldsymbol{\sigma}}^{i+1} &= \boldsymbol{\sigma}^i + \mu_3 \mathbf{D}^\top (\mathbf{r}_3^i - \Delta \mathbf{r}_3^i) \\
 \tilde{\mathbf{u}}^{i+1} &= \mathbf{u}^i + \mu_1 (\mathbf{r}_1^i - \Delta \mathbf{r}_1^i) \\
 \tilde{\mathbf{v}}^{i+1} &= \mathbf{v}^i + \mu_2 (\mathbf{r}_2^i - \Delta \mathbf{r}_2^i) \\
 \tilde{\boldsymbol{\eta}}^{i+1} &= \boldsymbol{\eta}^i + \mu_3 (\mathbf{r}_3^i - \Delta \mathbf{r}_3^i) \\
 \mathbf{x}^{i+1} &= \tilde{\mathbf{x}}^{i+1} \\
 \mathbf{u}^{i+1} &= \text{prox}_{\gamma f}(\tilde{\mathbf{u}}^{i+1}) \\
 (\mathbf{v}^{i+1}, \boldsymbol{\sigma}^{i+1}) &= \text{prox}_{\gamma \lambda \varphi}(\tilde{\mathbf{v}}^{i+1}, \tilde{\boldsymbol{\sigma}}^{i+1}) \\
 \boldsymbol{\eta}^{i+1} &= \text{prox}_{\gamma \iota_{B_1^\alpha}}(\tilde{\boldsymbol{\eta}}^{i+1}) = P_{B_1^\alpha}(\tilde{\boldsymbol{\eta}}^{i+1}) \\
 \Delta \mathbf{r}_1^{i+1} &= \mu_1 (\mathbf{L} \mathbf{x}^i - \mathbf{u}^i); \Delta \mathbf{r}_2^{i+1} = \mu_2 (\mathbf{R} \mathbf{x}^i - \mathbf{v}^i); \Delta \mathbf{r}_3^{i+1} = \mu_3 (\mathbf{D} \boldsymbol{\sigma}^i - \boldsymbol{\eta}^i) \\
 \mathbf{r}_1^{i+1} &= \mathbf{r}_1^i - \Delta \mathbf{r}_1^{i+1}; \mathbf{r}_2^{i+1} = \mathbf{r}_2^i - \Delta \mathbf{r}_2^{i+1}; \mathbf{r}_3^{i+1} = \mathbf{r}_3^i - \Delta \mathbf{r}_3^{i+1}
 \end{aligned}$$

Output: $\mathbf{x}^{L+1} \in \mathbb{R}^N, \boldsymbol{\sigma}^{L+1} \in \mathbb{R}^K$

とする。このとき、アルゴリズム 2 の計算は $\mathcal{O}((J+K)N)$ で行える。特に二乗誤差 $f(\mathbf{u}) = \frac{1}{2} \|\mathbf{y} - \mathbf{u}\|_2^2$ 、絶対誤差 $f(\mathbf{u}) = \|\mathbf{y} - \mathbf{u}\|_1$ はこの仮定を満たす。

アルゴリズム 2 における各変数の計算量を述べる。 $\tilde{\mathbf{x}}^{(i+1)}$ は $\mathbf{L}, \mathbf{R}$ との行列積から $\mathcal{O}((J+K)N)$ で計算される。 $\tilde{\mathbf{u}}^{(i+1)}, \mathbf{r}_1^{(i+1)}$ は $\mathbf{L}$ との行列積から $\mathcal{O}(JN)$ で計算される。 $\tilde{\mathbf{v}}^{(i+1)}, \mathbf{r}_2^{(i+1)}$ は $\mathbf{R}$ との行列積から $\mathcal{O}(KN)$ で計算される。 $\tilde{\boldsymbol{\sigma}}^{(i+1)}, \tilde{\boldsymbol{\eta}}^{(i+1)}, \mathbf{r}_3^{(i+1)}$ は $2(K-1)$ 個の非ゼロ成分を持つ $\mathbf{D}$ との行列積から $\mathcal{O}(K)$ で計算される。また、 $\text{prox}_{\gamma \lambda \varphi}$ は $\mathcal{O}(K)$ で計算される [40, Remark 5]。 $P_{B_1^\alpha}$ は $\mathcal{O}(K)$ で計算される [89]。 $\square$

3.2 最適解への収束条件

LOP- ℓ_2/ℓ_1 (定理 2.1) と同様に、LOP- ℓ_2/ℓ_1 ALT に関して最適解への収束条件を導出し、 μ_1, μ_2, μ_3 の選択について議論する。そのためには、 $\mathbf{H}$ の最大特異値 $\|\mathbf{H}\|_{\text{op}}$ を求める必要がある。まず、(3.3) より、LOP- ℓ_2/ℓ_1 ALT において

$$\mathbf{H} = \begin{bmatrix} \mu_1 \mathbf{L} & \mathbf{O} & -\mu_1 \mathbf{I} & \mathbf{O} & \mathbf{O} \\ \mu_2 \mathbf{R} & \mathbf{O} & \mathbf{O} & -\mu_2 \mathbf{I} & \mathbf{O} \\ \mathbf{O} & \mu_3 \mathbf{D} & \mathbf{O} & \mathbf{O} & -\mu_3 \mathbf{I} \end{bmatrix} \quad (3.4)$$

であるから, $\mathbf{H}$ の最大特異値 $\|\mathbf{H}\|_{\text{op}}$ は

$$\begin{aligned}\|\mathbf{H}\|_{\text{op}} &= \sqrt{\rho(\mathbf{H}\mathbf{H}^*)} \\ &= \sqrt{\rho\left(\begin{bmatrix} \mu_1^2(\mathbf{L}\mathbf{L}^* + \mathbf{I}) & \mu_1\mu_2\mathbf{L}\mathbf{R}^* & \mathbf{O} \\ \mu_1\mu_2\mathbf{R}\mathbf{L}^* & \mu_2^2(\mathbf{R}\mathbf{R}^* + \mathbf{I}) & \mathbf{O} \\ \mathbf{O} & \mathbf{O} & \mu_3^2(\mathbf{D}\mathbf{D}^\top + \mathbf{I}) \end{bmatrix}\right)} \\ &= \max \left\{ \sqrt{\rho\left(\begin{bmatrix} \mu_1^2(\mathbf{L}\mathbf{L}^* + \mathbf{I}) & \mu_1\mu_2\mathbf{L}\mathbf{R}^* \\ \mu_1\mu_2\mathbf{R}\mathbf{L}^* & \mu_2^2(\mathbf{R}\mathbf{R}^* + \mathbf{I}) \end{bmatrix}\right)}, \frac{\sqrt{\rho(\mu_3^2(\mathbf{D}\mathbf{D}^\top + \mathbf{I}))}}{=\mu_3\sqrt{\|\mathbf{D}\|_{\text{op}}^2 + 1}} \right\}.\end{aligned}$$

よって, 線形拡張ラグランジュ法の最適解収束条件 (定理 A.2) より, LOP- ℓ_2/ℓ_1 ALT の最適解への収束条件は

$$\begin{cases} \rho\left(\begin{bmatrix} \mu_1^2(\mathbf{L}\mathbf{L}^* + \mathbf{I}) & \mu_1\mu_2\mathbf{L}\mathbf{R}^* \\ \mu_1\mu_2\mathbf{R}\mathbf{L}^* & \mu_2^2(\mathbf{R}\mathbf{R}^* + \mathbf{I}) \end{bmatrix}\right) \leq 1 \\ \mu_3^2(\|\mathbf{D}\|_{\text{op}}^2 + 1) \leq 1 \end{cases} \quad (3.5a)$$

$$\mu_3^2(\|\mathbf{D}\|_{\text{op}}^2 + 1) \leq 1 \quad (3.5b)$$

となる. μ_3 の満たすべき条件 (3.6c) は (3.5b) より直ちに求められる. 一方, (3.5a) を μ_1, μ_2 に関して解く必要がある. しかし, $\mathbf{L}\mathbf{R}^* = \mathbf{O}$ の場合を除き, この不等式を解析的に解くことは困難である. そこで, この困難を克服する方法の 1 つとして, $\mathbf{H}$ の部分行列 $\mathbf{L}, \mathbf{R}, \mathbf{D}$ の作用素ノルムを用いて最適解への収束を保証するアプローチを提案する. 他の保証アプローチとしては, ① $\mu_1 = \mu_2$ とおくことで解析的に得られた解を用いる方法や, ② μ_1, μ_2 に極めて小さい値を取る方法, が考えられる. ただし, ① は $\mathbf{L}$ と $\mathbf{R}$ のどちらかが極端に大きい最大特異値を持つ場合に収束性が悪化する可能性がある. また, ② は μ_1, μ_2 を求める手間が少ないものの, 変数の更新量が減少するため一般に収束性が悪化する.

① $\mu_1 = \mu_2$ の場合に, $\mathbf{L}$ と $\mathbf{R}$ のどちらかが極端に大きい最大特異値を持つとき, 収束性が悪化する可能性について考察する. このとき, (3.5a) を満たす $\mu_1 = \mu_2$ は

$$\mathbf{M} = \begin{bmatrix} \mu_1\mathbf{L} & \mathbf{O} & -\mu_1\mathbf{I} & \mathbf{O} \\ \mu_2\mathbf{R} & \mathbf{O} & \mathbf{O} & -\mu_2\mathbf{I} \end{bmatrix} \text{ の最大特異値 } \|\mathbf{M}\|_{\text{op}} \text{ を用いて}$$

$$\mu_1 = \mu_2 \leq \frac{1}{\sqrt{\|\mathbf{M}\|_{\text{op}}^2 + 1}}$$

と求められる. 次に $\mathbf{R} = \mathbf{O}$ の場合を考え, 提案手法と ① を比較する. 提案手法を用いる場合, $\mu_1 = \frac{1}{2\sqrt{\|\mathbf{L}\|_{\text{op}}^2 + 1}}$, $\mu_2 = \frac{1}{2\sqrt{0+1}} = \frac{1}{2}$ となる. 対して, ① を用いる場合,

$\mu_1 = \mu_2 = \frac{1}{\sqrt{\|\mathbf{L}\|_{\text{op}}^2 + 1}}$ となる． μ_1 は提案手法の方が小さく， μ_2 は提案手法の方が大きい．ただし， $\mathbf{L}$ が極端に大きい最大特異値を持つ場合， μ_2 が $\mathbf{L}$ に依存しない提案手法のほうが収束性が良いと予想される． $\mathbf{L} = \mathbf{O}$ の場合も，提案手法は①と異なり μ_1 が $\mathbf{R}$ に依存しないため，同様の結論が得られる．

提案する最適解収束条件は，最適解への収束を保証する手間と収束速度のトレードオフを両立する．これは $\mathbf{H}$ の作用素ノルムの代わりに， $\mathbf{H}$ の部分行列 $\mathbf{L}, \mathbf{R}, \mathbf{D}$ の作用素ノルムを用いて最適解への収束を保証するためである．LOP- ℓ_2/ℓ_1 ALT は

$$\left\{ \begin{array}{l} \mu_1 \leq \frac{1}{\sqrt{2\|\mathbf{L}\|_{\text{op}}^2 + 1}} \\ \mu_2 \leq \frac{1}{\sqrt{2\|\mathbf{R}\|_{\text{op}}^2 + 1}} \\ \mu_3 \leq \frac{1}{\sqrt{\|\mathbf{D}\|_{\text{op}}^2 + 1}} \end{array} \right. \quad (3.6a)$$

$$\mu_2 \leq \frac{1}{\sqrt{2\|\mathbf{R}\|_{\text{op}}^2 + 1}} \quad (3.6b)$$

$$\mu_3 \leq \frac{1}{\sqrt{\|\mathbf{D}\|_{\text{op}}^2 + 1}} \quad (3.6c)$$

を満たすように $\mu_1, \mu_2, \mu_3 > 0$ を選ぶことで最適解へ収束することが，数値実験 (図 7.13) によって経験的に確認された．ただし，この不等式は厳密な上限ではない．LOP- ℓ_2/ℓ_1 ALT をより効率的に収束させるために，厳密な上限を求めることは今後の課題である．

第 4 章

非凸関数を用いたブロックスパース正則化

LOP- ℓ_2/ℓ_1 [40] は、凸関数である混合 ℓ_2/ℓ_1 ノルムに基づく適応的ブロックスパース正則化であり、 ℓ_1 ノルムと同様に信号の大きさを過小評価する傾向がある。この問題を解決するために、対数関数を用いた適応的ブロックスパース正則化 ReLOP- ℓ_2/ℓ_1 を提案する。

4.1 対数関数を用いた LOP- ℓ_2/ℓ_1 のバイアス低減

LOP- ℓ_2/ℓ_1 は凸関数に基づく手法であるため、 ℓ_1 ノルムと同様に信号の振幅を過小評価する傾向にある。この問題を解決するアプローチの 1 つは、LOP- ℓ_2/ℓ_1 へ非凸性を導入することである [90]。本節では、RWL1 を利用した新たな適応的ブロック非凸スパース正則化：ReLOP- ℓ_2/ℓ_1 (Reweighted and LOP- ℓ_2/ℓ_1) を提案する。

LOP- ℓ_2/ℓ_1 において、 $|x| = \min_{\tau \in \mathbb{R}} \phi(x, \tau)$ となる関数 $\phi(x, \tau)$ (2.3) を導入した。これに倣い、提案手法では、 $\log(|x|/\epsilon + 1) = \min_{\tau \in \mathbb{R}} \tilde{\phi}(x, \tau)$ を満たす関数

$$\tilde{\phi}(x, \tau) = \begin{cases} \frac{1}{2\tau} \left(\frac{|x|}{\epsilon} + 1 \right)^2 + \frac{1}{2} \log \tau - \frac{1}{2} & \text{if } \tau > 0 \\ 0 & \text{if } x = 0 \text{ and } \tau = 0 \\ \infty & \text{otherwise} \end{cases}$$

を導入する。

補題 4.1 ($\tilde{\phi}(x, \tau)$ の下限). $\log(|x|/\epsilon + 1) = \min_{\tau \in \mathbb{R}} \tilde{\phi}(x, \tau)$ が成り立つ。 □

Proof. $\tau > 0$ のとき、次の不等式：

$$\log \left(\frac{|x|}{\epsilon} + 1 \right) = \frac{1}{2} \log \left(\frac{|x|}{\epsilon} + 1 \right)^2 \leq \frac{1}{2\tau} \left(\frac{|x|}{\epsilon} + 1 \right)^2 + \frac{1}{2} \log \tau - \frac{1}{2}$$

が成り立つ [91, Equation 9]. ここで $z = (|x|/\epsilon + 1)^2$ とおく. 最小となるのは $-\frac{z}{2\tau^2} + \frac{1}{2\tau} = 0$, すなわち $\tau = z$ のときであり, 最小値は $\log(z)$ である. $\square$

指数関数やキャップ付き ℓ_1 ノルムでの非凸性を導入することも考えられるが, 対数関数と異なり 補題 4.1 のような下限を導く関数は未知であるため, 同様の議論を行うことは難しい.

$\tilde{\phi}(x, \tau)$ を用いて, ReLOP- ℓ_2/ℓ_1 正則化項を次のように定義する.

$$\tilde{\psi}_\alpha(\mathbf{x}) = \min_{\substack{\boldsymbol{\sigma} \in \mathbb{R}^N \\ \|\mathbf{D}\boldsymbol{\sigma}\|_1 \leq \alpha}} \sum_{n=1}^N \tilde{\phi}(x_n, \sigma_n) \quad (4.1)$$

今回は, $\boldsymbol{\sigma} \in \mathbb{R}^K$ の不等式制約に LOP- ℓ_2/ℓ_1 の ℓ_1 ノルム球制約 $\|\mathbf{D}\boldsymbol{\sigma}\|_1 \leq \alpha$ を用いる. 凸緩和される前の ℓ_0 ノルム球制約 $\|\mathbf{D}\boldsymbol{\sigma}\|_0 \leq M$ (M は非負整数) を用いることも可能である. ただし, ℓ_0 ノルム球射影は, 計算にソートが必要なため $O(N \log N)$ の計算量を要する [92, Equation 11]. 対して, ℓ_1 ノルム球射影 (2.14) は $O(N)$ で計算できる [89].

定理 4.1 ($\alpha \rightarrow 0, \alpha \rightarrow \infty$ の場合に $\tilde{\psi}_\alpha(\mathbf{x})$ が導く正則化). $\tilde{\psi}_\alpha(\mathbf{x})$ は $\alpha \rightarrow \infty$ のとき再重み付き ℓ_1 ノルムに収束する. すなわち, $\lim_{\alpha \rightarrow \infty} \tilde{\psi}_\alpha(\mathbf{x}) = \sum_{n=1}^N \log\left(\frac{|x_n|}{\epsilon} + 1\right)$ である. また, $\alpha \rightarrow 0$ のとき, $\tilde{\psi}_0(\mathbf{x}) = N \log \sqrt{\frac{1}{N} \sum_{n=1}^N \left(\frac{|x_n|}{\epsilon} + 1\right)^2}$ であり, ℓ_2 ノルムを対数関数で非凸化したものに類似する. $\square$

Proof. $\tilde{\phi}(x, \tau)$ の τ に関する下限を用いる. $\alpha \rightarrow \infty$ のとき, 不等式制約 $\|\mathbf{D}\boldsymbol{\sigma}\|_1 \leq \alpha$ は無視できるから, $\sum_{n=1}^N \tilde{\phi}(x_n, \sigma_n)$ は, $\sigma_n = (|x_n|/\epsilon + 1)^2$ のとき最小値を取る. よって, 補題 4.1 より, $\tilde{\psi}_\alpha(\mathbf{x}) = \sum_{n=1}^N \log\left(\frac{|x_n|}{\epsilon} + 1\right)$ が成り立つ. また, $\alpha \rightarrow 0$ のとき, 不等式制約は $\|\mathbf{D}\boldsymbol{\sigma}\|_1 \leq 0$ となり, $\boldsymbol{\sigma}$ の各成分 σ_n の値は全て同じ値 $\tau \in \mathbb{R}_{\geq 0}$ となる. ゆえに,

$$\begin{aligned} \tilde{\psi}_0(\mathbf{x}) &= \min_{\tau \in \mathbb{R}_{\geq 0}} \sum_{n=1}^N \left\{ \frac{1}{2\tau} \left(\frac{|x_n|}{\epsilon} + 1 \right)^2 + \frac{1}{2} \log \tau - \frac{1}{2} \right\} \\ &= \min_{\tau \in \mathbb{R}_{\geq 0}} \frac{1}{2\tau} \sum_{n=1}^N \left(\frac{|x_n|}{\epsilon} + 1 \right)^2 + \frac{N}{2} \log \tau - \frac{N}{2} \\ &= \frac{N}{2} + N \log \sqrt{\frac{1}{N} \sum_{n=1}^N \left(\frac{|x_n|}{\epsilon} + 1 \right)^2} - \frac{N}{2} \\ &= N \log \sqrt{\frac{1}{N} \sum_{n=1}^N \left(\frac{|x_n|}{\epsilon} + 1 \right)^2} \end{aligned} \quad (4.2)$$

2 行目から 3 行目の変形では, 最小値を達成する $\tau = \frac{1}{N} \sum_{n=1}^N \left(\frac{|x_n|}{\epsilon} + 1 \right)^2$ を代入した. $\square$

また、あるブロック $\mathcal{B}_k$ において、それに対応する潜在ベクトル σ_n の値を全て同じ τ_k とするとき、

$$\min_{\tau_k \in \mathbb{R}} \sum_{n \in \mathcal{B}_k} \tilde{\phi}(x_n, \tau_k) = |\mathcal{B}_k| \log \sqrt{\frac{1}{|\mathcal{B}_k|} \sum_{n \in \mathcal{B}_k} \left(\frac{|x_n|}{\epsilon} + 1 \right)^2}$$

が成り立つ。この最小値は、(4.2) の 1 行目の式における $\sum_{n=1}^N$ を $\sum_{n \in \mathcal{B}_k}$ に置き換え、同様の議論を用いることで得られる。この性質や 定理 4.1 から、 $\tilde{\psi}_\alpha(\mathbf{x})$ は対数関数を用いることで過小評価バイアスを低減した、適応的ブロックスパース正則化として振る舞うことが期待される。すなわち、 $\tilde{\psi}_\alpha(\mathbf{x}) \approx \sum_{k=1}^K |\mathcal{B}_k^*| \log \sqrt{\frac{1}{|\mathcal{B}_k^*|} \sum_{n \in \mathcal{B}_k^*} \left(\frac{|x_n|}{\epsilon} + 1 \right)^2}$ である。 $(\mathcal{B}_k^*)_{k=1}^K$ は入力 $\mathbf{x}$ の真のブロック構造とする。ここでは、 $\|\mathbf{x}\|_{w,2,1}^{(\mathcal{B}_k)_{k=1}^j} = \sum_{k=1}^K |\mathcal{B}_k| \log \sqrt{\frac{1}{|\mathcal{B}_k|} \sum_{n \in \mathcal{B}_k} \left(\frac{|x_n|}{\epsilon} + 1 \right)^2}$ を再重み付き混合 ℓ_2/ℓ_1 ノルムと呼ぶ。

注意 4.1 (再重み付き混合 ℓ_2/ℓ_1 ノルムの重みの妥当性). 再重み付き混合 ℓ_2/ℓ_1 ノルムが混合 ℓ_2/ℓ_1 ノルムと同様 (注意 2.1) に、大きなブロックに対してより大きなペナルティを与えることを示す。そのためには、注意 2.1 と同様の仮定の上で

$$\begin{aligned} |\mathcal{B}| \log \sqrt{\frac{1}{|\mathcal{B}|} \sum_{n \in \mathcal{B}} \left(\frac{|x_n|}{\epsilon} + 1 \right)^2} &> |\mathcal{B}'| \log \sqrt{\frac{1}{|\mathcal{B}'|} \sum_{n \in \mathcal{B}'} \left(\frac{|x_n|}{\epsilon} + 1 \right)^2} \\ &\quad + |\mathcal{B}''| \log \sqrt{\frac{1}{|\mathcal{B}''|} \sum_{n \in \mathcal{B}''} \left(\frac{|x_n|}{\epsilon} + 1 \right)^2} \end{aligned} \quad (4.3)$$

が成り立つことを示せばよい。 $\mathbf{x}_{\mathcal{B}''} = \mathbf{0}$ であるから、右辺の第 2 項は 0 である。したがって、

$$|\mathcal{B}| \log \sqrt{\frac{1}{|\mathcal{B}|} \sum_{n \in \mathcal{B}} \left(\frac{|x_n|}{\epsilon} + 1 \right)^2} > |\mathcal{B}'| \log \sqrt{\frac{1}{|\mathcal{B}'|} \sum_{n \in \mathcal{B}'} \left(\frac{|x_n|}{\epsilon} + 1 \right)^2}$$

が成り立つ。また、 $|\mathcal{B}| > |\mathcal{B}'|$ 、そして $\|\mathbf{x}_{\mathcal{B}}\|_2 = \|\mathbf{x}_{\mathcal{B}'}\|_2$ 、かつ $|\mathcal{B}| \leq \sum_{n \in \mathcal{B}} \left(\frac{|x_n|}{\epsilon} + 1 \right)^2$ 、 $|\mathcal{B}'| \leq \sum_{n \in \mathcal{B}'} \left(\frac{|x_n|}{\epsilon} + 1 \right)^2$ であるから、次の命題を示すことで (4.3) が証明される。

命題 4.1. $f(x) = x^2 \log \frac{x+c}{x}$ は $x \in \mathbb{R}_{>0}$ において狭義単調増加関数である。 c は任意の非負実数とする。 $\square$

Proof. 任意の $x \in \mathbb{R}_{>0}$ において $f'(x) > 0$ であることを示せばよい。積の微分法則を用いて、

$$f'(x) = 2x \log \left(\frac{x+c}{x} \right) + x \left(\frac{1}{x+c} - \frac{1}{x} \right) = 2x \log \left(\frac{x+c}{x} \right) - \frac{cx}{c+x}$$

$$= x \left(2 \log \left(\frac{x+c}{x} \right) - \frac{c}{c+x} \right).$$

$x > 0$ であるから、次に $2 \log \left(\frac{x+c}{x} \right) - \frac{c}{c+x} > 0$ を示す. $t = \frac{c}{x+c}$ とおくと、 $x = c(1-t)/t$ であるから、

$$2 \log \left(\frac{x+c}{x} \right) - \frac{c}{c+x} = -2 \log(1-t) - t$$

となる. $h(t) = -2 \log(1-t) - t$ とおくことにすると、 $h(0) = -2 \log(1-0) - 0 = 0$ 、かつ t の定義より $0 < t < 1$ であるから、 $h'(t) = 2/(1-t) - 1 > 0$ が成り立つ. ゆえに、 $h(t) = 2 \log \left(\frac{x+c}{x} \right) - \frac{c}{c+x} > 0$ が示される. したがって、 $f'(x) > 0$ が成り立ち、 $f(x)$ は $x \in \mathbb{R}_{>0}$ において狭義単調増加関数である. $\square$

命題 4.1 において $x = \sqrt{|\mathcal{B}|}$, $c = \sqrt{\sum_{n \in \mathcal{B}} \left(\frac{|x_n|}{\epsilon} + 1 \right)^2} - \sqrt{|\mathcal{B}|}$ とおくことで、(4.3) が示される. 以上より、再重み付き混合 ℓ_2/ℓ_1 ノルムは、大きなブロックに対してより大きなペナルティを与えるという点で妥当である. $\square$

最適化アルゴリズムの導出 ReLOP- ℓ_2/ℓ_1 正則化項 $\tilde{\psi}_\alpha(\mathbf{x})$ を正則化項に用いる最適化問題を、交互方向乗数法 (ADMM) により解く. この正則化項は非凸関数であり、関数の凸性を収束保証の前提とする線形拡張ラグランジュ法を用いることが難しい. そこで、 ℓ_p ノルム ($0 < p < 1$) などの一部の非凸関数において、大域的な収束保証が得られている [93], ADMM (A.4) を最適化に用いる. ReLOP- ℓ_2/ℓ_1 正則化項においても、同様の収束保証が得られるかどうか調べることは今後の課題とする.

まず、等式制約 $\mathbf{u} = \mathbf{L}\mathbf{x}, \mathbf{v} = \mathbf{R}\mathbf{x}, \boldsymbol{\eta} = \mathbf{D}\boldsymbol{\sigma}, \boldsymbol{\xi} = \boldsymbol{\sigma}$ と、(4.1) の不等式制約 $\|\mathbf{D}\boldsymbol{\sigma}\|_1 \leq \alpha$ に対応する指示関数 $\iota_{\mathcal{B}_1^\alpha}(\boldsymbol{\eta})$ を用いて、 $\min_{\mathbf{x} \in \mathbb{R}^N} f(\mathbf{L}\mathbf{x}) + \lambda \tilde{\psi}_\alpha(\mathbf{R}\mathbf{x})$ を書き換えると

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^N} f(\mathbf{L}\mathbf{x}) + \lambda \tilde{\psi}_\alpha(\mathbf{R}\mathbf{x}) &= \min_{\substack{\mathbf{x} \in \mathbb{R}^N, \boldsymbol{\sigma} \in \mathbb{R}^K, \mathbf{u} \in \mathbb{R}^J, \\ \mathbf{v} \in \mathbb{R}^K, \boldsymbol{\eta} \in \mathbb{R}^{K-1}, \boldsymbol{\xi} \in \mathbb{R}^K}} f(\mathbf{u}) + \lambda \sum_{n=1}^N \tilde{\phi}(v_n, \sigma_n) + \iota_{\mathcal{B}_1^\alpha}(\boldsymbol{\eta}) \\ &= \min_{\substack{\mathbf{x} \in \mathbb{R}^N, \boldsymbol{\sigma} \in \mathbb{R}^K, \mathbf{u} \in \mathbb{R}^J, \\ \mathbf{v} \in \mathbb{R}^K, \boldsymbol{\eta} \in \mathbb{R}^{K-1}, \boldsymbol{\xi} \in \mathbb{R}^K}} f(\mathbf{u}) + \lambda \sum_{n=1}^N \left(\frac{1}{2\xi_n} \left(\frac{|v_n|}{\epsilon} + 1 \right)^2 + \frac{1}{2} \log \xi_n \right) + \iota_{\mathcal{B}_1^\alpha}(\boldsymbol{\eta}) \\ &\quad \text{s.t. } \mathbf{u} = \mathbf{L}\mathbf{x}, \mathbf{v} = \mathbf{R}\mathbf{x}, \boldsymbol{\eta} = \mathbf{D}\boldsymbol{\sigma}, \boldsymbol{\xi} = \boldsymbol{\sigma}, \boldsymbol{\xi} \geq 0 \end{aligned}$$

と表せる. 対応する拡張ラグランジュ関数は

$$\mathcal{L} = f(\mathbf{u}) + \lambda \sum_{n=1}^N \left(\frac{1}{2\xi_n} \left(\frac{|v_n|}{\epsilon} + 1 \right)^2 + \frac{1}{2} \log \xi_n \right) + \iota_{\mathcal{B}_1^\alpha}(\boldsymbol{\eta})$$

アルゴリズム 3 Solver for ReLOP- ℓ_2/ℓ_1

Input: $\mathbf{x}^0, \boldsymbol{\sigma}^0, \mathbf{u}^0, \mathbf{v}^0, \boldsymbol{\eta}^0, \boldsymbol{\xi}^0, \mathbf{r}_1^0, \mathbf{r}_2^0, \mathbf{r}_3^0, \mathbf{r}_4^0, \mathbf{L}, \mathbf{R}, \mathbf{D}, \epsilon, \lambda, K, \beta, \mu_1, \mu_2, \mu_3, \mu_4$

- 1: **for** $K \rightarrow 0, 1, \dots, L$ **do**
- 2: Updating $\mathbf{x}^k$ via (4.4)
- 3: Updating $\mathbf{u}^k$ via (4.5)
- 4: Updating $\mathbf{v}^k$ via (4.6)
- 5: Updating $\boldsymbol{\sigma}^k$ via (4.7)
- 6: Updating $\boldsymbol{\eta}^k$ via (4.8)
- 7: Updating $\boldsymbol{\xi}^k$ via ??
- 8: Updating $\mathbf{r}_1^k, \mathbf{r}_2^k, \mathbf{r}_3^k, \mathbf{r}_4^k$ via (4.9)

Output: $\mathbf{x}^{L+1} \in \mathbb{R}^N, \boldsymbol{\sigma}^{L+1} \in \mathbb{R}^K$

$$\begin{aligned}
& + \mathbf{r}_1^\top (\mathbf{u} - \mathbf{L}\mathbf{x}) + \frac{\mu_1}{2} \|\mathbf{u} - \mathbf{L}\mathbf{x}\|_2^2 + \mathbf{r}_2^\top (\mathbf{v} - \mathbf{R}\mathbf{x}) + \frac{\mu_2}{2} \|\mathbf{v} - \mathbf{R}\mathbf{x}\|_2^2 \\
& + \mathbf{r}_3^\top (\boldsymbol{\eta} - \mathbf{D}\boldsymbol{\sigma}) + \frac{\mu_3}{2} \|\boldsymbol{\eta} - \mathbf{D}\boldsymbol{\sigma}\|_2^2 + \mathbf{r}_4^\top (\boldsymbol{\xi} - \boldsymbol{\sigma}) + \frac{\mu_4}{2} \|\boldsymbol{\xi} - \boldsymbol{\sigma}\|_2^2
\end{aligned}$$

となる. $\mu_1, \mu_2, \mu_3, \mu_4$ は正の定数であり, $\mathbf{r}_1, \mathbf{r}_2, \mathbf{r}_3, \mathbf{r}_4$ はラグランジュ乗数である. ADMM の更新式は次で与えられる. ADMM の更新式をまとめた提案アルゴリズムを アルゴリズム 3 に示す.

1) $\mathbf{x}$ の更新: 拡張ラグランジュ関数 $\mathcal{L}$ の $\mathbf{x}$ に関する項を変形すると,

$$\begin{aligned}
\mathcal{L} &= \mathbf{r}_1^\top (\mathbf{u} - \mathbf{L}\mathbf{x}) + \frac{\mu_1}{2} \|\mathbf{u} - \mathbf{L}\mathbf{x}\|_2^2 + \mathbf{r}_2^\top (\mathbf{v} - \mathbf{R}\mathbf{x}) + \frac{\mu_2}{2} \|\mathbf{v} - \mathbf{R}\mathbf{x}\|_2^2 + \text{const.} \\
&= \frac{\mu_1}{2} \left\| \left(\mathbf{u} - \mathbf{L}\mathbf{x} \right) + \frac{\mathbf{r}_1}{\mu_1} \right\|_2^2 + \frac{\mu_2}{2} \left\| \left(\mathbf{v} - \mathbf{R}\mathbf{x} \right) + \frac{\mathbf{r}_2}{\mu_2} \right\|_2^2 + \text{const.} \\
&= \frac{\mu_1}{2} \left\| \mathbf{L}\mathbf{x} - \left(\mathbf{u} + \frac{\mathbf{r}_1}{\mu_1} \right) \right\|_2^2 + \frac{\mu_2}{2} \left\| \mathbf{R}\mathbf{x} - \left(\mathbf{v} + \frac{\mathbf{r}_2}{\mu_2} \right) \right\|_2^2 + \text{const.}
\end{aligned}$$

$\mathcal{L}$ は $\mathbf{x}$ に関して凸関数であるため, $\mathcal{L}$ を最小化するためには $\frac{\partial \mathcal{L}}{\partial \mathbf{x}} = 0$ となる必要があり,

$$\frac{\partial \mathcal{L}}{\partial \mathbf{x}} = \mu_1 \mathbf{L}^\top \left(\mathbf{L}\mathbf{x} - \mathbf{u} - \frac{\mathbf{r}_1}{\mu_1} \right) + \mu_2 \mathbf{R}^\top \left(\mathbf{R}\mathbf{x} - \mathbf{v} - \frac{\mathbf{r}_2}{\mu_2} \right) = 0$$

が得られる. よって, $\mathbf{x}$ の更新式は線形方程式

$$(\mu_1 \mathbf{L}^\top \mathbf{L} + \mu_2 \mathbf{R}^\top \mathbf{R}) \mathbf{x} = \mu_1 \mathbf{L}^\top \left(\mathbf{u} + \frac{\mathbf{r}_1}{\mu_1} \right) + \mu_2 \mathbf{R}^\top \left(\mathbf{v} + \frac{\mathbf{r}_2}{\mu_2} \right) \quad (4.4)$$

の解として与えられる.

2) $\mathbf{u}$ の更新：拡張ラグランジュ関数 $\mathcal{L}$ の $\mathbf{u}$ に関する項を変形すると

$$\begin{aligned}\mathcal{L} &= f(\mathbf{u}) + \mathbf{r}_1^\top (\mathbf{u} - \mathbf{L}\mathbf{x}) + \frac{\mu_1}{2} \|\mathbf{u} - \mathbf{L}\mathbf{x}\|_2^2 + \text{const.} \\ &= f(\mathbf{u}) + \frac{\mu_1}{2} \left\| \mathbf{u} - \mathbf{L}\mathbf{x} + \frac{\mathbf{r}_1}{\mu_1} \right\|_2^2 + \text{const.}\end{aligned}$$

これを最小化する演算は f の近接写像で表せる．よって， $\mathbf{u}$ の更新式は，

$$\mathbf{u} \leftarrow \text{prox}_{f/\mu_1} \left(\mathbf{L}\mathbf{x} - \frac{\mathbf{r}_1}{\mu_1} \right). \quad (4.5)$$

3) $\mathbf{v}$ の更新：拡張ラグランジュ関数 $\mathcal{L}$ の $\mathbf{v}$ に関する項を変形すると

$$\begin{aligned}\mathcal{L} &= \lambda \sum_{n=1}^K \frac{1}{2\xi_n} \left(\frac{|v_n|}{\epsilon} + 1 \right)^2 + \mathbf{r}_2^\top (\mathbf{v} - \mathbf{R}\mathbf{x}) + \frac{\mu_2}{2} \|\mathbf{v} - \mathbf{R}\mathbf{x}\|_2^2 + \text{const.} \\ &= \lambda \sum_{n=1}^K \frac{1}{2\xi_n} \left(\frac{v_n^2}{\epsilon^2} + \frac{2|v_n|}{\epsilon} \right) + \frac{\mu_2}{2} \left\| \mathbf{v} - \mathbf{R}\mathbf{x} + \frac{\mathbf{r}_2}{\mu_2} \right\|_2^2 + \text{const.}\end{aligned}$$

が得られる．Elastic net の近接写像 (例 1.2) を用いると， $\mathbf{v}$ の更新式は

$$\mathbf{v} \leftarrow \text{prox}_{\lambda_1 \|\cdot\|_1 + \lambda_2 \|\cdot\|_2^2} \left(\mathbf{R}\mathbf{x} - \frac{\mathbf{r}_2}{\mu_2} \right) \quad (4.6)$$

のように表せる．ここで， $\lambda_1 = \frac{\lambda}{\mu_2 \xi_n \epsilon}$ ， $\lambda_2 = \frac{\lambda v_n^2}{2 \mu_2 \xi_n \epsilon^2}$ である．

4) σ の更新：拡張ラグランジュ関数 $\mathcal{L}$ の σ に関する項を変形すると

$$\begin{aligned}\mathcal{L} &= \mathbf{r}_3^\top (\boldsymbol{\eta} - \mathbf{D}\boldsymbol{\sigma}) + \frac{\mu_3}{2} \|\boldsymbol{\eta} - \mathbf{D}\boldsymbol{\sigma}\|_2^2 + \mathbf{r}_4^\top (\boldsymbol{\xi} - \boldsymbol{\sigma}) + \frac{\mu_4}{2} \|\boldsymbol{\xi} - \boldsymbol{\sigma}\|_2^2 + \text{const.} \\ &= \frac{\mu_3}{2} \left\| \boldsymbol{\eta} - \mathbf{D}\boldsymbol{\sigma} + \frac{\mathbf{r}_3}{\mu_3} \right\|_2^2 + \frac{\mu_4}{2} \left\| \boldsymbol{\xi} - \boldsymbol{\sigma} + \frac{\mathbf{r}_4}{\mu_4} \right\|_2^2 + \text{const.} \\ &= \frac{\mu_3}{2} \left\| \mathbf{D}\boldsymbol{\sigma} - \left(\boldsymbol{\eta} + \frac{\mathbf{r}_3}{\mu_3} \right) \right\|_2^2 + \frac{\mu_4}{2} \left\| \boldsymbol{\sigma} - \left(\boldsymbol{\xi} + \frac{\mathbf{r}_4}{\mu_4} \right) \right\|_2^2 + \text{const.}\end{aligned}$$

が得られる． $\mathcal{L}$ は $\boldsymbol{\sigma}$ に関して凸関数であるため， $\frac{\partial \mathcal{L}}{\partial \boldsymbol{\sigma}} = 0$ となる必要がある．ゆえに

$$\frac{\partial \mathcal{L}}{\partial \boldsymbol{\sigma}} = \mu_3 \mathbf{D}^\top \left(\mathbf{D}\boldsymbol{\sigma} - \boldsymbol{\eta} - \frac{\mathbf{r}_3}{\mu_3} \right) + \mu_4 \left(\boldsymbol{\sigma} - \boldsymbol{\xi} - \frac{\mathbf{r}_4}{\mu_4} \right) = 0$$

となる．よって， $\boldsymbol{\sigma}$ の更新式は線形方程式

$$(\mu_3 \mathbf{D}^\top \mathbf{D} + \mu_4 \mathbf{I}) \boldsymbol{\sigma} = \mu_3 \mathbf{D}^\top \left(\boldsymbol{\eta} + \frac{\mathbf{r}_3}{\mu_3} \right) + \mu_4 \left(\boldsymbol{\xi} + \frac{\mathbf{r}_4}{\mu_4} \right) \quad (4.7)$$

の解として与えられる．

5) $\boldsymbol{\eta}$ の更新：拡張ラグランジュ関数 $\mathcal{L}$ の $\boldsymbol{\eta}$ に関する項を変形すると,

$$\begin{aligned}\mathcal{L} &= \mathbf{r}_3^\top (\boldsymbol{\eta} - \mathbf{D}\boldsymbol{\sigma}) + \frac{\mu_3}{2} \|\boldsymbol{\eta} - \mathbf{D}\boldsymbol{\sigma}\|_2^2 + \iota_{\mathcal{B}_1^\alpha}(\boldsymbol{\eta}) + \text{const.} \\ &= \frac{\mu_3}{2} \left\| \boldsymbol{\eta} - \mathbf{D}\boldsymbol{\sigma} + \frac{\mathbf{r}_3}{\mu_3} \right\|_2^2 + \iota_{\mathcal{B}_1^\alpha}(\boldsymbol{\eta}) + \text{const.}\end{aligned}$$

この式は $\iota_{\mathcal{B}_1^\alpha}(\boldsymbol{\eta})$ の近接写像 $P_{\mathcal{B}_1^\alpha}$ を用いて

$$\boldsymbol{\eta} \leftarrow P_{\mathcal{B}_1^\alpha} \left(\mathbf{D}\boldsymbol{\sigma} - \frac{\mathbf{r}_3}{\mu_3} \right) \quad (4.8)$$

のように与えられる.

6) $\boldsymbol{\xi}$ の更新：拡張ラグランジュ関数 $\mathcal{L}$ の $\boldsymbol{\xi}$ に関する項を変形すると,

$$\begin{aligned}\mathcal{L} &= \lambda \sum_{n=1}^K \left\{ \frac{1}{2\xi_n} \left(\frac{|v_n|}{\epsilon} + 1 \right)^2 + \frac{1}{2} \log \xi_n \right\} + \mathbf{r}_4^\top (\boldsymbol{\xi} - \boldsymbol{\sigma}) + \frac{\mu_4}{2} \|\boldsymbol{\xi} - \boldsymbol{\sigma}\|_2^2 + \text{const.} \\ &= \lambda \sum_{n=1}^K \left\{ \frac{1}{2\xi_n} \left(\frac{|v_n|}{\epsilon} + 1 \right)^2 + \frac{1}{2} \log \xi_n \right\} + \frac{\mu_4}{2} \left\| \boldsymbol{\xi} - \boldsymbol{\sigma} + \frac{\mathbf{r}_4}{\mu_4} \right\|_2^2 + \text{const.} \\ &= \sum_{n=1}^K \left\{ \frac{\lambda}{2\xi_n} \left(\frac{|v_n|}{\epsilon} + 1 \right)^2 + \frac{\lambda}{2} \log \xi_n + \frac{\mu_4}{2} \left(\xi_n - \sigma_n + \frac{r_{4,n}}{\mu_4} \right)^2 \right\} + \text{const. s.t. } \xi_n \geq 0\end{aligned}$$

が得られる. $\mathcal{L}$ は $\forall n, \xi_n \geq 0$ に関して微分可能である. 更に $\mu_4 \geq \lambda/54$ を満たすとき, $\mathcal{L}$ は $\forall n, \xi_n \geq 0$ に関して凸関数である. ゆえに, 二分法やニュートン法などの勾配法によって勾配が 0 となる点を探索することで, $\boldsymbol{\xi}$ の更新式を得られる. 二分法は 2 次収束するニュートン法よりも収束が遅いものの, 初期値を適切に設定することで, ニュートン法と異なり $\xi_n \geq 0$ が保証される. ξ_n の初期値は, $a = (|v_n|/\epsilon + 1)^2$, $b = \sigma_n - r_{4,n}/\mu_4$ に対して, 最小値を $\max\{0, \min\{a, b\}\}$, 最大値を $\max\{a, b\}$ と設定すれば良い. 画像ノイズ除去の数値実験 (7.2 節) においては, 10~20 回程度の更新で十分に収束することが確認された.

7) $\mathbf{r}_1, \mathbf{r}_2, \mathbf{r}_3, \mathbf{r}_4$ の更新：各変数の線形制約を考慮すると,

$$\begin{aligned}\mathbf{r}_1 &\leftarrow \mathbf{r}_1 + \mu_1(\mathbf{u} - \mathbf{L}\mathbf{x}), \\ \mathbf{r}_2 &\leftarrow \mathbf{r}_2 + \mu_2(\mathbf{v} - \mathbf{R}\mathbf{x}), \\ \mathbf{r}_3 &\leftarrow \mathbf{r}_3 + \mu_3(\boldsymbol{\eta} - \mathbf{D}\boldsymbol{\sigma}), \\ \mathbf{r}_4 &\leftarrow \mathbf{r}_4 + \mu_4(\boldsymbol{\xi} - \boldsymbol{\sigma}),\end{aligned} \quad (4.9)$$

のように更新される.

4.2 一般化逆順序重み付き損失 (GROWL)

ROWL の絶対値関数を, 対数関数や指数関数などの一般の関数 g に拡張することを提案する. この拡張は, 絶対値関数によるスパース性の過小評価を解消するために有効と期待される. そのような拡張を行った関数として, 一般化逆順序重み付き損失 (Generalized Reverse Ordered Weighted Loss, GROWL) と呼ばれる関数を

$$\Omega_w^g(\mathbf{x}) = \sum_{n=1}^N w_n g(|x|_{[n]}) \quad (4.10)$$

と定義する. ここで $g: \mathbb{R} \rightarrow \mathbb{R}_{\geq 0}$ は非負値を出力する関数である. 非凸関数 g を導入することで, スパース性の過小評価を解消する. 任意の $x \in \mathbb{R}_{\geq 0}$ に対して, $\text{prox}_{wg}(x)$ が $w \in \mathbb{R}_{\geq 0}$ に対して単調減少であるならば, GROWL の近接写像は g の近接写像に帰着する. また, GROWL の等高線図を図 4.1 に示す. ROWL (図 1.11 の (e), (f)) では絶対値の大きい要素に対して大きな値を取るが, GROWL では絶対値の大きい要素に対しても適切な値を取ることが確認できる.

定理 4.2 (一般化逆順序重み付き損失の近接写像). 任意の $x \in \mathbb{R}_{\geq 0}$ に対して, $\text{prox}_{wg}(x)$ が $w \in \mathbb{R}_{\geq 0}$ について単調減少であるならば,

$$\text{prox}_{\Omega_w^g}(\mathbf{x}) = \text{sign}(\mathbf{x}) \boxtimes \left(\mathbf{P}(|\mathbf{x}|)^\top \text{prox}_{\mathbf{w} \boxtimes g}(|\mathbf{x}|_\downarrow) \right)$$

が成り立つ. ここで, $\mathbf{w} \boxtimes g$ は関数であり, $\mathbf{x} \in \mathbb{R}^N$ に対して $(\mathbf{w} \boxtimes g)(\mathbf{x}) := (w_1g(x_1), w_2g(x_2), \dots, w_Ng(x_N))^\top$ と定義する. $\square$

次の 4 つの補題を示すことで, この定理は直ちに証明される.

補題 4.2. $\text{prox}_{\Omega_w^g}(\mathbf{x})$ の符号は $\mathbf{x}$ と一致する. すなわち,

$$\text{prox}_{\Omega_w^g}(\mathbf{x}) = \text{sign}(\mathbf{x}) \boxtimes \text{prox}_{\Omega_w^g}(|\mathbf{x}|)$$

が成り立つ. $\square$

Proof. $\Omega_w^g(\mathbf{x}) = \Omega_w^g(|\mathbf{x}|)$ と $\|\mathbf{x} - \text{sign}(\mathbf{x}) \boxtimes |\mathbf{y}|\|_2^2 \leq \|\mathbf{x} - \mathbf{y}\|_2^2$ から導かれる [94]. $\square$

補題 4.3. $\text{prox}_{\Omega_w^g}(\mathbf{x}) = \text{sign}(\mathbf{x}) \boxtimes \left(\mathbf{P}(|\mathbf{x}|)^\top \text{prox}_{\Omega_w^g}(|\mathbf{x}|_\downarrow) \right)$ が成り立つ. $\square$

Proof. 補題 4.2 より, 一般性を失わずに $\mathbf{x} \in \mathbb{R}_{\geq 0}$ と仮定する. すると, 任意の置換行列 $\mathbf{P}$ に対して $\Omega_w^g(\mathbf{x}) = \Omega_w^g(\mathbf{P}\mathbf{x})$ と $\|\mathbf{P}(\mathbf{x} - \mathbf{y})\|_2^2 = \|\mathbf{x} - \mathbf{y}\|_2^2$ が成り立ち, 直ちに補題の主張が示される. $\square$




図 4.1: GROWL の等高線図 (上段 $w_1 = 0, w_2 \geq 0$, 下段 $0 < w_1 < w_2$)

補題 4.4. $\mathbf{x} \in \mathcal{K}_{m+}$ ならば, $\text{prox}_{\Omega_w^g}(\mathbf{x}) \in \mathcal{K}_{m+}$ が成り立つ. $\mathcal{K}_{m+}$ は単調非負円錐

$$\mathcal{K}_{m+} = \{\mathbf{x} \in \mathbb{R}^N \mid x_1 \geq x_2 \geq \cdots \geq x_m \geq 0\}$$

である. □

Proof. 近接写像 $\text{prox}_{\Omega_w^g}(\mathbf{x})$ の目的関数は

$$\frac{1}{2}\|\mathbf{x} - \mathbf{y}\|_2^2 + \Omega_w^g(\mathbf{y}) = \frac{1}{2}\|\mathbf{x}\|_2^2 + \frac{1}{2}\|\mathbf{y}\|_2^2 - \mathbf{x}^\top \mathbf{y} + \Omega_w^g(\mathbf{y}) \quad (4.11)$$

と表せる. $\mathbf{x}^\top \mathbf{y}$ の除く全ての項は, 符号反転と置換に対して不変である. HLP 不等式 $\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^N, \mathbf{x}_\downarrow^\top \mathbf{y}_\downarrow \geq \mathbf{x}^\top \mathbf{y}$ [95] より, $\mathbf{x} \in \mathcal{K}_{m+}$ ならば $\mathbf{x}^\top \mathbf{y}_\downarrow \geq \mathbf{x}^\top \mathbf{y}$ が成り立つから, (4.11) を最小化する $\mathbf{y}$ は $\mathcal{K}_{m+}$ に属さなければならない. □

補題 4.5. 任意の $\mathbf{x} \in \mathbb{R}_{\geq 0}$ に対して, $\text{prox}_{wg}(\mathbf{x})$ が $w \in \mathbb{R}_{\geq 0}$ に対して単調減少であるならば, $\text{prox}_{\Omega_w^g}(|\mathbf{x}|_\downarrow) = \text{prox}_{w \square g}(|\mathbf{x}|_\downarrow)$ が成り立つ. □

Proof. $|\mathbf{x}|_{\downarrow} \in \mathcal{K}_{m+}$ であるから, $\text{prox}_{\Omega_w^g}(|\mathbf{x}|_{\downarrow}) \in \mathcal{K}_{m+}$ が成り立つ. 加えて, $w_1 \leq w_2 \leq \dots \leq w_N$ かつ prox_{wg} が w に対して単調減少であるから $\text{prox}_{w \square g}(|\mathbf{x}|_{\downarrow}) \in \mathcal{K}_{m+}$ である. ゆえに, 求めたい近接写像において

$$\begin{aligned} \text{prox}_{\Omega_w^g}(|\mathbf{x}|_{\downarrow}) &= \arg \min_{\mathbf{y} \in \mathcal{K}_{m+}} \frac{1}{2} \left\| |\mathbf{x}|_{\downarrow} - \mathbf{y} \right\|_2^2 + \Omega_w^g(\mathbf{y}) \\ &= \arg \min_{\mathbf{y} \in \mathcal{K}_{m+}} \frac{1}{2} \left\| |\mathbf{x}|_{\downarrow} - \mathbf{y} \right\|_2^2 + (w \square g)(\mathbf{y}) \\ &= \text{prox}_{w \square g}(|\mathbf{x}|_{\downarrow}). \end{aligned}$$

が成り立つ. □

定理 4.2 により, 補題 4.5 の仮定を満たせば, ℓ_0 ノルム, 再重み付き ℓ_1 ノルム, 指数ノルム, キャップ付き ℓ_1 ノルムを用いた GROWL の近接写像は容易に計算できる. まず, ℓ_0 ノルムの近接写像はハード閾値関数 (1.3) であるため, 単調減少性を満たす. ゆえに, その近接写像は閉形式で与えられる.

定理 4.3 (ℓ_0 ノルムを用いる場合の GROWL の近接写像).

$$\text{prox}_{\Omega_w^{\|\cdot\|_0}}(\mathbf{x}) = \text{sign}(\mathbf{x}) \square \left(\mathbf{P}(|\mathbf{x}|)^{\top} \text{prox}_{w \square \|\cdot\|_0}(|\mathbf{x}|_{\downarrow}) \right).$$

□

対して, 他の正則化項が仮定を満たすかどうか確かめることは現状困難である.*¹. しかし, 再重み付き ℓ_1 ノルム, 指数ノルム, キャップ付き ℓ_1 ノルムを用いる場合については, 次の予想が成り立つと考えられる.

予想 4.1 (再重み付き ℓ_1 ノルム・指数ノルム・キャップ付き ℓ_1 ノルムを用いる場合の GROWL の近接写像).

$$\begin{aligned} \text{prox}_{\Omega_w^{\|\cdot\|_{w,1}}}(\mathbf{x}) &= \text{sign}(\mathbf{x}) \square \left(\mathbf{P}(|\mathbf{x}|)^{\top} \text{prox}_{w \square \|\cdot\|_{w,1}}(|\mathbf{x}|_{\downarrow}) \right), \\ \text{prox}_{\Omega_w^{\|\cdot\|_{\sigma,e}}}(\mathbf{x}) &= \text{sign}(\mathbf{x}) \square \left(\mathbf{P}(|\mathbf{x}|)^{\top} \text{prox}_{w \square \|\cdot\|_{\sigma,e}}(|\mathbf{x}|_{\downarrow}) \right), \\ \text{prox}_{\Omega_w^{\|\cdot\|_{\text{cap},1}}}(\mathbf{x}) &= \text{sign}(\mathbf{x}) \square \left(\mathbf{P}(|\mathbf{x}|)^{\top} \text{prox}_{w \square \|\cdot\|_{\text{cap},1}}(|\mathbf{x}|_{\downarrow}) \right). \end{aligned}$$

□

この近接写像を用いる妥当性は, 画像ノイズ除去の数値実験 (7.2 節) において示唆される.

*¹ 凸で微分可能な場合は, 正則化項が単調増加であることを確認すればよい (A.2).

第 5 章

微分可能な適応的ブロックスパース正則化

本章では、微分可能な適応的ブロックスパース正則化を提案する。これにより、従来の微分不可能な $\text{LOP-}\ell_2/\ell_1$ では成し得なかった、ニューラルネットワーク (NN) などの非線形なモデルに対する適応的ブロックスパース正則化が可能となる。そのためにまず、微分可能な非凸スパース損失を提案し、その性質を調査する。この手法は、既存手法 [96, 97] と異なり、特徴量に対する非凸なスパース正則化が可能である。この性質を利用して、微分可能な適応的ブロックスパース正則化を実現する。更に、深層学習における構造的なモデル圧縮、敵対的攻撃などへの応用を議論する。

5.1 微分可能なスパース正則化

微分可能な正則化項を用いることの重要な利点は、勾配に基づく最適化手法の適用が可能となることである。深層学習をはじめとする現代の機械学習では、確率的勾配降下法 (SGD) やその発展手法が主要な最適化アルゴリズムとして用いられている。これらの手法は目的関数の勾配情報を必要とするため、正則化項の微分可能性は学習アルゴリズムの設計において重要な役割を果たす。例えば、 ℓ_p 正則化は原点において微分不可能であり、最適化を困難にする要因となっていた。

理論的な観点からも、正則化項の微分可能性は重要な意味を持つ。最適化アルゴリズムの収束解析において、目的関数の滑らかさは本質的な役割を果たす。特に、勾配のリプシッツ連続性は収束速度の理論的保証を導出する際の重要な要件となる [98]。

しかし、微分可能な非凸スパース正則化の適用範囲は現状限られている。例えば、[96, 97] は ℓ_0 正則化の微分可能な代理関数を提案している。ただし、損失関数内のパラメータの性質が変わる影響で、特徴ベクトルに対するスパース性を評価する方法は明らかでない。そこで次に、特徴ベクトルに対するスパース性を評価できる、より汎用的かつ微分可能な ℓ_0 ノ

ルムの代替関数を提案する.

5.2 微分可能な非凸スパース正則化

本項では, 指数ノルムに変更を加えた微分可能な 2 つの ℓ_0 ノルムの代替関数 (図 5.1)

$$\Omega_c(\mathbf{x}) := \sum_{n=1}^N \left\{ 1 - \exp\left(-\frac{x_n^2}{c}\right) \right\} \quad (c \in \mathbb{R}_{>0}), \quad (5.1)$$

$$\Omega_{c,p}(\mathbf{x}) := \sum_{n=1}^N \left\{ 1 - \exp\left(\frac{1 - \cosh(x_n)^p}{c}\right) \right\} \quad (c, p \in \mathbb{R}_{>0}), \quad (5.2)$$

を提案する. 代替関数のグラフを 図 5.1 に示す. この関数は, 指数ノルムと同様に信号の大きさに対する過小評価を行わない, 微分可能なスパース正則化として機能する. そのため, この正則化は ℓ_0 ノルムや指数ノルムと異なり, 微分可能な適応的ブロックスパース正則化を実現するために用いることができる (5.4 節). また, ニューラルネットワークの枝刈りや特徴選択, 敵対的攻撃などのスパース性を要求する様々な問題への適用も期待される.

また, (5.1), (5.2) の近接写像をプロットすることで, 本正則化の性質を調べる. 図 5.2 に近接写像のグラフを示す. その結果, 原点付近では極めて傾きの小さい ℓ_2 ノルムのように, それ以外の領域ではハード閾値処理のように振る舞うことが確認された. 加えて, (5.2) は p を大きくするほど, よりハード閾値処理に近づくことが確認された. したがって, (5.1), (5.2) は, ℓ_0 ノルムの代替関数として有効と分かる. 特に, (5.2) は, p を高く設定することで, (5.1) よりも ℓ_0 ノルムに近い振る舞いを示す.

5.3 微分可能なブロックスパース正則化

微分可能な損失関数 $\mathcal{L}(\boldsymbol{\eta}, \boldsymbol{\theta})$ の ℓ_1 正則化付き最小化問題は

$$\min_{\boldsymbol{\theta} \in \mathbb{R}^N, \boldsymbol{\eta}} \mathcal{L}(\boldsymbol{\eta}, \boldsymbol{\theta}) + \lambda \sum_{j=1}^d |\theta_j| \quad (5.3)$$

と表される. ここで, $\boldsymbol{\eta}$ は正則化の対象としないパラメータ, $\boldsymbol{\theta}$ は正則化するパラメータ, λ は正則化係数である. ただし, この問題は ℓ_1 ノルムのため微分不可能である. そこで, $\boldsymbol{\theta} = \mathbf{u} \boxtimes \boldsymbol{\sigma} = (u_n \sigma_n)_{n=1}^N$ とおくことで, 微分可能な最小化問題

$$\min_{\mathbf{u} \in \mathbb{R}^N, \boldsymbol{\sigma} \in \mathbb{R}^N, \boldsymbol{\eta}} \mathcal{L}(\boldsymbol{\eta}, \mathbf{u} \boxtimes \boldsymbol{\sigma}) + \frac{\lambda}{2} (\|\mathbf{u}\|_2^2 + \|\boldsymbol{\sigma}\|_2^2) \quad (5.4)$$




図 5.1: $\ell_0 \cdot \ell_1$ ノルムと、微分可能な非凸スパース正則化項 (5.1), (5.2) の比較 ($c = 0.2$ のとき).




図 5.2: ハード・ソフト閾値関数と、微分可能な非凸スパース正則化項 (5.1), (5.2) の近接写像 ($\lambda = 0.1, c = 0.01$ のとき).

は、大域的および局所的な最適解が (5.3) と一致する [99]. (5.4) の正則化項は ℓ_2 ノルムであるため微分可能で、(5.3) の微分不可能性を解消する. 次に、混合 ℓ_2/ℓ_1 ノルム付きの最小化問題を考える.

$$\min_{\theta \in \mathbb{R}^N, \eta} \mathcal{L}(\eta, \theta) + \lambda \sum_{j=1}^K \sqrt{|\mathcal{B}_j|} \|\theta_{\mathcal{B}_j}\|_2, \quad (5.5)$$

ここで、 $\mathcal{B}_j$ はブロック j のインデックス集合であり、 $\mathcal{B} = (\mathcal{B}_j)_{j=1}^K$ をブロック構造と呼ぶ. この問題は、パラメータ θ をブロックに応じた成分ごとの積、すなわち

$$\theta = \mathbf{u} \boxtimes_{\mathcal{B}} \mathbf{v} := \begin{pmatrix} \mathbf{u}_1 \\ \vdots \\ \mathbf{u}_K \end{pmatrix} \boxtimes \begin{pmatrix} \nu_1 \mathbf{1}_{|\mathcal{B}_1|} \\ \vdots \\ \nu_K \mathbf{1}_{|\mathcal{B}_K|} \end{pmatrix}$$

とおくことで、 ℓ_2 ノルムを正則化項に用いた微分可能な最小化問題

$$\min_{\mathbf{u} \in \mathbb{R}^N, \mathbf{v} \in \mathbb{R}^K, \eta} \mathcal{L}(\eta, \mathbf{u} \boxtimes_{\mathcal{B}} \mathbf{v}) + \frac{\lambda}{2} \sum_{j=1}^K (\|\mathbf{u}_j\|_2^2 + |\mathcal{B}_j| \nu_j^2). \quad (5.6)$$

に帰着される [99].

5.4 平滑化による真のブロック構造推定

適応的ブロックスパース正則化項 $\psi_K(\theta)$ [40, Equation 2] を加えた損失関数の最小化問題 (5.7) を微分可能にする手法を提案する. まず、適応的ブロックスパース正則化項 $\psi_K(\theta)$

を加えた損失関数の最小化問題

$$\begin{aligned}
\min_{\boldsymbol{\theta} \in \mathbb{R}^N, \boldsymbol{\eta}} \mathcal{L}(\boldsymbol{\eta}, \boldsymbol{\theta}) + \lambda \psi_K(\boldsymbol{\theta}) &= \min_{\boldsymbol{\theta} \in \mathbb{R}^N, \boldsymbol{\eta}} \mathcal{L}(\boldsymbol{\eta}, \boldsymbol{\theta}) + \lambda \min_{j \in \{1, \dots, K\}} \left[\min_{(\mathcal{B}_k)_{k=1}^j \in \mathcal{P}_j} \sum_{k=1}^j \sqrt{|\mathcal{B}_k|} \|\boldsymbol{\theta}_{\mathcal{B}_k}\|_2 \right] \\
&= \min_{j \in \{1, \dots, K\}} \min_{(\mathcal{B}_k)_{k=1}^j \in \mathcal{P}_j} \left[\min_{\boldsymbol{\theta} \in \mathbb{R}^N, \boldsymbol{\eta}} \mathcal{L}(\boldsymbol{\eta}, \boldsymbol{\theta}) + \lambda \sum_{k=1}^j \sqrt{|\mathcal{B}_k|} \|\boldsymbol{\theta}_{\mathcal{B}_k}\|_2 \right]
\end{aligned} \tag{5.7}$$

を考える．ここで， $(\mathcal{B}_k)_{k=1}^K$ が重ならないブロック構造から成る集合族 $\mathcal{P}_j$ (定義 2.1) に含まれるとする．このとき，

$$\min_{\mathbf{u} \in \mathbb{R}^N, \boldsymbol{\sigma} \in \mathbb{R}^N, \boldsymbol{\eta}} \mathcal{L}(\boldsymbol{\eta}, \mathbf{u} \boxplus \boldsymbol{\sigma}) + \frac{\lambda}{2} (\|\mathbf{u}\|_2^2 + \|\boldsymbol{\sigma}\|_2^2) \quad \text{s.t.} \quad \|\mathbf{D}\boldsymbol{\sigma}\|_0 \leq K-1 \tag{5.8}$$

の大域的最適解は (5.7) のものと一致する．ただし，(5.6) と異なり局所最適解の一致は保証されない．この正則化は LOP- ℓ_2/ℓ_1 と同じ大域的最適解を導く，適応的ブロックスパース正則化の新たな定式化である．また，この LOP- ℓ_2/ℓ_1 の定式化を用いることで，LOP- ℓ_2/ℓ_1 を低ランク正則化や TV 正則化などの他の正則化と組み合わせる際の計算コストを削減することができる．6.4 節に LOP- ℓ_2/ℓ_1 と低ランク正則化と組み合わせる場合の応用例を示す．

Proof. (5.7) から (5.8) への変換は以下の通りである．

$$\begin{aligned}
\min_{\boldsymbol{\theta} \in \mathbb{R}^N, \boldsymbol{\eta}} \mathcal{L}(\boldsymbol{\eta}, \boldsymbol{\theta}) + \lambda \psi_K(\boldsymbol{\theta}) &= \min_{\boldsymbol{\theta} \in \mathbb{R}^N, \boldsymbol{\eta}} \mathcal{L}(\boldsymbol{\eta}, \boldsymbol{\theta}) + \lambda \min_{j \in \{1, \dots, K\}} \left[\min_{(\mathcal{B}_k)_{k=1}^j \in \mathcal{P}_j} \sum_{k=1}^j \sqrt{|\mathcal{B}_k|} \|\boldsymbol{\theta}_{\mathcal{B}_k}\|_2 \right] \\
&= \min_{j \in \{1, \dots, K\}} \min_{(\mathcal{B}_k)_{k=1}^j \in \mathcal{P}_j} \left[\min_{\boldsymbol{\theta} \in \mathbb{R}^N, \boldsymbol{\eta}} \mathcal{L}(\boldsymbol{\eta}, \boldsymbol{\theta}) + \lambda \sum_{k=1}^j \sqrt{|\mathcal{B}_k|} \|\boldsymbol{\theta}_{\mathcal{B}_k}\|_2 \right] \\
&= \min_{j \in \{1, \dots, K\}} \min_{(\mathcal{B}_k)_{k=1}^j \in \mathcal{P}_j} \left[\min_{\mathbf{u} \in \mathbb{R}^N, \boldsymbol{\tau} \in \mathbb{R}^j, \boldsymbol{\eta}} \mathcal{L}(\boldsymbol{\eta}, \mathbf{u} \boxplus_{\mathcal{B}} \boldsymbol{\tau}) + \frac{\lambda}{2} \sum_{k=1}^j (\|\mathbf{u}_{\mathcal{B}_k}\|_2^2 + |\mathcal{B}_k| \tau_k^2) \right] \\
&= \min_{j \in \{1, \dots, K\}} \min_{\substack{\mathbf{u} \in \mathbb{R}^N, \boldsymbol{\sigma} \in \mathbb{R}^N, \boldsymbol{\eta} \\ \|\mathbf{D}\boldsymbol{\sigma}\|_0 = j-1}} \left[\mathcal{L}(\boldsymbol{\eta}, \mathbf{u} \boxplus \boldsymbol{\sigma}) + \frac{\lambda}{2} (\|\mathbf{u}\|_2^2 + \|\boldsymbol{\sigma}\|_2^2) \right] \\
&= \min_{\mathbf{u} \in \mathbb{R}^N, \boldsymbol{\sigma} \in \mathbb{R}^N, \boldsymbol{\eta}} \mathcal{L}(\boldsymbol{\eta}, \mathbf{u} \boxplus \boldsymbol{\sigma}) + \frac{\lambda}{2} (\|\mathbf{u}\|_2^2 + \|\boldsymbol{\sigma}\|_2^2) \quad \text{s.t.} \quad \|\mathbf{D}\boldsymbol{\sigma}\|_0 \leq K-1
\end{aligned}$$

第 3 式から第 4 式への変形は (5.5) の最適解が (5.6) に等しいことから導かれる．第 4 式から第 5 式への変形は， $\sigma_n = \tau_k$ ($n \in \mathcal{B}_k$) とおき，ブロック数の制約を LOP- ℓ_2/ℓ_1 と同様に置き換えることで成り立つ． $\square$

$\mathbf{D}$ は微分作用素である．加えて，この微分作用素を信号の構造に応じて取り替えることで，テンソルやグラフ信号に対する適応的ブロックスパース正則化も可能である．ただし，

σ の平滑性制約 $\|D\sigma\|_0 \leq K - 1$ を微分不可能であるため、微分可能な最小化問題

$$\min_{\mathbf{u} \in \mathbb{R}^N, \sigma \in \mathbb{R}^N, \eta} \mathcal{L}(\eta, \mathbf{u} \boxplus \sigma) + \frac{\lambda}{2} (\|\mathbf{u}\|_2^2 + \|\sigma\|_2^2) + \alpha \cdot \Omega(D\sigma) \quad (5.9)$$

を代わりに解くことで近似解を得る。 $\Omega(\mathbf{x})$ は (5.2) のような ℓ_0 ノルム $\|\mathbf{x}\|_0$ を近似する微分可能なスパース正則化項とする。 (5.9) の正則化項を微分可能な LOP- ℓ_2/ℓ_1 と呼ぶ。

5.5 深層学習への応用

前節で提案した微分可能な適応的ブロックスパース正則化は深層学習に応用できる。例えば、NN における全結合層や畳み込み層の重みパラメータに対して提案手法を適用すると、構造的な枝刈りが可能となる。重みパラメータに適応的ブロックスパース正則化を行う手法は、私の知る限り初めてであり、NN のスパース化に新たな可能性を提供する。

更に、大規模言語モデル (LLM) の密-疎量子化 [100] への応用も期待される。[101] は、注意機構を近似的にロバスト主成分分析することで、推論精度を 1% 犠牲にするのみで Vision Transformer (ViT) の 1 つである T2T-ViT のメモリ消費量を 98% 削減している。加えて、[100] は LLM の重み行列を非外れ値テンソルと外れ値テンソルの和に分解し、前者のみを量子化することで、推論精度を保持したままメモリ消費量を削減することに成功している。この手法は、密-疎量子化と呼ばれている。また、外れ値テンソルがブロック構造のようなある種の構造を持つことが [100, Figure 4] で示唆されているため、提案手法を適用することで、更なるメモリ消費量の削減が期待される。

そして、敵対的攻撃への応用も期待される。敵対的攻撃は、ニューラルネットワークの入力に微小な摂動を加えることで、誤認識を引き起こす手法である。その手法の 1 つとして、ブロックスパースな摂動を加える手法が存在する [102]。このような摂動を生成することで、敵対的攻撃の解釈性（入力のどの箇所が誤認識を引き起こすのか）が向上する。提案手法を応用することで、事前にブロック構造を仮定することなく、かつ勾配法に基づく最適化手法 [103–105] を用いて、ブロックスパースな摂動を生成することが可能となる。これは、ブロック構造を事前に仮定しており、摂動の生成に ADMM などの方法を用いる従来手法 [102] と比較して、より汎用的で効率的な手法である。

第 6 章

テンソル分解への応用

6.1 テンソル分解

テンソル分解は、テンソル（多次元配列）を低ランクテンソルで近似する手法である．この操作は、行列における切り捨て特異値分解（ $\mathbf{X} = \mathbf{U}\mathbf{S}\mathbf{V}^\top = \sum_{r=1}^R s_r \mathbf{u}_r \mathbf{v}_r^\top$ ）に相当する．テンソル分解は、画像処理、グラフ信号処理、機械学習、深層学習などに応用される [47, 71, 74, 106–131]．ただし、テンソルにおいては、行列のように最良なランク R 近似が存在するという保証 (Eckart-Young の定理) がいないため、様々なテンソル分解手法が提案されている [73, 132–137]．本論文では CP 分解 [138, 139] とテンソルロバスト主成分分析 [140–143] に注目する．

CP 分解はテンソル分解を行う手法の 1 つである．CP 分解のイメージを図 6.1 に示す．テンソル $\mathcal{X} \in \mathbb{R}^{I_1 \times \cdots \times I_N}$ に対する CP 分解は

$$\mathcal{X} \approx \mathbf{U}_1 \circ \mathbf{U}_2 \circ \cdots \circ \mathbf{U}_N := \sum_{r=1}^R \mathbf{u}_1^r \circ \mathbf{u}_2^r \circ \cdots \circ \mathbf{u}_N^r.$$

のように表される．ここで、 $\mathbf{U}_n \in \mathbb{R}^{I_n \times R}$ ($n = 1, \dots, N$) は因子行列、 $\mathbf{u}_n^r \in \mathbb{R}^{I_n}$ ($r = 1, \dots, R$) は $\mathbf{U}_n$ の r 番目の列ベクトル、 R は CP ランク、 $\circ$ はベクトル外積演算子である．つまり、ランク 1 テンソル $\mathcal{X}^r = \mathbf{u}_1^r \circ \mathbf{u}_2^r \circ \cdots \circ \mathbf{u}_N^r$ の各要素が $x_{i_1, \dots, i_N}^r = u_{1, i_1}^r u_{2, i_2}^r \cdots u_{N, i_N}^r$ のように対応する．テンソルの CP ランクを低くすることで、CP 分解はテンソルの低ランク近似を行える．

CP 分解は、テンソル補完などに応用される．テンソル補完は、テンソルの一部の要素が欠損している場合に、欠損している要素を補完する手法である．画像補完や知識グラフ補完、メタ学習に利用される [47, 66, 126, 129, 144–146]．CP 分解によるテンソル補完は、欠





図 6.2: テンソル主成分分析 ($\mathcal{X}$ は低ランクテンソル, $\mathcal{S}$ はスパーステンソル)

損テンソル $\mathcal{Y} \in \mathbb{R}^{I_1 \times \dots \times I_N}$ に対して, 以下の最適化問題

$$\min_{\mathcal{X}, U_1, \dots, U_N} \|\mathcal{X} - U_1 \circ U_2 \circ \dots \circ U_N\|_F^2 + h(U_1, \dots, U_N) \text{ s.t. } \mathcal{X}_\Omega = \mathcal{Y}_\Omega$$

を解くことで行われる. $\mathcal{X} \in \mathbb{R}^{I_1 \times \dots \times I_N}$ は補完テンソル, Ω は欠損インデックス集合, $\|\cdot\|_F$ はフロベニウスノルム, $h(U_1, \dots, U_N)$ は正則化項である. 正則化の導入はテンソル補完においても重要である [25, 47, 65, 66, 146–152]. 本研究はテンソル補完における新たなスパース正則化手法を提案する.

また, テンソルロバスト主成分分析 (TRPCA) は, 観測テンソルを低ランクテンソルとスパーステンソルの和の形でモデリングすることで, 外れ値にロバストなテンソル分解を行う手法である. 移動物体検出や前景背景分離などに応用される [15, 17]. TRPCA の最適化問題は, スパース正則化に ℓ_1 ノルムを用いる場合,

$$\min_{\mathcal{X}, \mathcal{S}} \|\mathcal{S}\|_1 \text{ s.t. } \mathcal{Y} = \mathcal{X} + \mathcal{S}, \text{rank}(\mathcal{X}) \leq r,$$

と定式化される. $\mathcal{Y}$ は観測テンソル, $\mathcal{X}$ は低ランクテンソル, $\mathcal{S}$ はスパーステンソル, r はテンソルのランクである.




図 6.3: 多層スパース性の解析 [25, Fig.3]. (a) 3 階テンソル. (b) CP 分解の因子行列 U_1, U_2, U_3 . (c) 因子行列の微分 $\nabla_1 U_1, \nabla_2 U_2, \nabla_3 U_3$. (d) V_1, V_2, V_3 による線形変換で得られる行列 $\nabla_1 U_1 V_1, \nabla_2 U_2 V_2, \nabla_3 U_3 V_3$. (e) 因子行列の微分のスパース性の分布. (f) 線形変換で得られた行列のスパース性の分布. (e) よりも (f) の方がスパースである.

6.2 多層スパース CP 分解 (MLSCP)

因子行列 $U_1, \dots, U_N$ の縦方向に関する微分 $\nabla_n U_n$ のスパース性（滑らかさ）による正則化は、テンソル分解に有効である [152–154]. ∇_n ($n = 1, \dots, N$) は微分作用素 (1.6) である. 対して、多層スパース性は、直交行列 V_n によって線形変換された因子行列の微分 $W_n = \nabla_n U_n V_n \in \mathbb{R}^{I_n \times r_n}$ のスパース性を指す. 多層スパース性のイメージを図 6.3 に示す. 多層スパース性による正則化は、滑らかさによる正則化よりも、テンソル補完の性能を向上させることが知られている [25]. $V_n \in \mathbb{R}^{R \times r_n}$ は最適化アルゴリズムを通じて適応的に学習される線形変換行列である. この性質を制約として加えた CP 分解を Multi-layer Sparsity-based CP Decomposition (MLSCP)[25] と呼ぶ. 以下、特に断りが無い限り、行列 $(A_n)_{n=1}^N$ を A_n と略記する. MLSCP の最適化問題は

$$\begin{aligned} \min_{\mathcal{X}, U_n, W_n, V_n} \quad & \frac{\mu \mathcal{X}}{2} \|\mathcal{X} - U_1 \circ U_2 \circ \dots \circ U_N\|_F^2 + \sum_{n=1}^N \lambda_n \|W_n\|_{w,1} \\ \text{s.t.} \quad & \nabla_n U_n = W_n V_n^\top, V_n^\top V_n = I, \mathcal{X}_\Omega = \mathcal{Y}_\Omega \end{aligned} \quad (6.1)$$

と定式化される．目的関数の第 1 項は補完テンソル $\mathcal{X}$ と CP 分解を近づける項であり，第 2 項と 1 つ目の制約式によって，CP 分解に多層スパース性を導入する．2 つ目の制約式は， V_n が直交行列であることを保証し，定数倍による V_n の非一意性を解消する．3 つ目の制約式によって，テンソルの欠損値のみを最適化の対象とする．

(6.1) の最適化問題は，ADMM によって解くことができる．はじめに，補助変数 $Z_n = U_n (n = 1, \dots, N)$ を導入することで，拡張ラグランジュ関数を

$$\begin{aligned} \mathcal{L}(\mathcal{X}, U_n, W_n, V_n, Z_n, M_n, P_n) &= \frac{\mu_{\mathcal{X}}}{2} \|\mathcal{X} - Z_1 \circ Z_2 \circ \dots \circ Z_N\|_F^2 + \sum_{n=1}^N \lambda_n \|W_n\|_{w,1} \\ &+ \langle M_n, \nabla_n U_n - W_n V_n^\top \rangle + \frac{\mu_M}{2} \|\nabla_n U_n - W_n V_n^\top\|_F^2 \\ &+ \langle P_n, U_n - Z_n \rangle + \frac{\mu_U}{2} \|U_n - Z_n\|_F^2 \end{aligned} \quad (6.2)$$

と定める．ここで， $M_n, P_n (n = 1, \dots, N)$ はラグランジュ乗数行列である．(6.2) を $\mathcal{X}, U_n, W_n, V_n, Z_n, M_n, P_n$ について $V_n^\top V_n = I, \mathcal{X}_\Omega = \mathcal{Y}_\Omega$ の制約付きで最小化，すなわち

$$\begin{aligned} \min_{\mathcal{X}, U_n, W_n, V_n, Z_n, M_n, P_n} \mathcal{L}(\mathcal{X}, U_n, W_n, V_n, Z_n, M_n, P_n) \\ \text{s.t. } V_n^\top V_n = I, \mathcal{X}_\Omega = \mathcal{Y}_\Omega \end{aligned} \quad (6.3)$$

を各変数について交互に解くことで，(6.1) の最適化アルゴリズム (アルゴリズム 4) が得られる．各変数の更新手続きを以下に示す．

1) $W_n (n = 1, \dots, N)$ の更新：(6.3) を W_n について最小化する問題は

$$\min_{W_n} \lambda_n \|W_n\|_{w,1} + \langle M_n, \nabla_n U_n - W_n V_n^\top \rangle + \frac{\mu_M}{2} \|\nabla_n U_n - W_n V_n^\top\|_F^2 \quad (6.4)$$

のように与えられる．この問題は，再重み付きソフト閾値処理によって最適解が得られる．具体的には，

$$W_n = S_{\lambda_n/\mu_M} \left(\left(\nabla_n U_n + \frac{M_n}{\mu_M} \right) V_n \right)$$

となる．ここで， $S_\delta(x)$ は [69] で提案された再重み付きソフト閾値関数で， $\delta \in \mathbb{R}_{>0}$ は閾値を定めるパラメータである．

2) $V_n (n = 1, \dots, N)$ の更新：(6.3) を V_n について最小化する問題は

$$\min_{V_n} \langle M_n, \nabla_n U_n - W_n V_n^\top \rangle + \frac{\mu_M}{2} \|\nabla_n U_n - W_n V_n^\top\|_F^2 \quad \text{s.t. } V_n^\top V_n = I \quad (6.5)$$

アルゴリズム 4 MLSCP for Tensor Completion [25, Algorithm 1]

Input: Observation $\mathcal{Y}$, the indices Ω of the available elements;

Initialize: $\mathcal{X}_\Omega^{(0)} = \mathcal{Y}_\Omega$, $\mathcal{X}_{\Omega^+}^{(0)} = \text{mean}(\mathcal{Y}_\Omega)$, $\mathbf{U}_1^{(0)}, \dots, \mathbf{U}_N^{(0)}$ by CP of $\mathcal{X}^{(0)}$, $\rho > 1$, $\epsilon = 10^{-7}$, $\alpha_n, \mathbf{M}_n = \mathbf{P}_n = 0$,

TV factor matrix rank: $r_n (n = 1, 2, \dots, N)$;

for $k = 1, 2, \dots, K$ **do**

for $n = 1, 2, \dots, N$ **do**

 Updating $\mathbf{W}_n^{(k)}$ via (6.4);

 Updating $\mathbf{U}_n^{(k)}$ via (6.6);

 Updating $\mathbf{V}_n^{(k)}$ via (6.5);

 Updating $\mathbf{Z}_n^{(k)}$ via (6.7);

 Updating $\mathcal{X}^{(k)}$ via (6.8);

 Updating the multipliers $\mathbf{M}_n$ and $\mathbf{P}_n$ via (6.9);

$\mu_{\mathcal{X}}^{(k)} = \rho \mu_{\mathcal{X}}^{(k-1)}$, $\mu_M^{(k)} = \rho \mu_M^{(k-1)}$, $\mu_U^{(k)} = \rho \mu_U^{(k-1)}$;

while $\|\mathcal{X}^{(K+1)} - \mathcal{X}^{(K)}\|_F^2 < \epsilon$ **do**

Output: Completed tensor $\mathcal{X} = \mathcal{X}^{K+1}$

のように与えられる．特異値分解 (SVD) によって，この問題の最適解は

$$\begin{cases} [\mathbf{B}, \mathbf{D}, \mathbf{C}] = \text{SVD} \left(\left(\nabla_n \mathbf{U}_n + \frac{\mathbf{M}_n}{\mu_M} \right)^\top \mathbf{W}_n \right) \\ \mathbf{V}_n = \mathbf{B} \mathbf{C}^\top, \end{cases}$$

で与えられる．

3) $\mathbf{U}_n$ ($n = 1, \dots, N$) の更新：(6.3) を $\mathbf{U}_n$ について最小化する問題は

$$\min_{\mathbf{U}_n} \frac{\mu_M}{2} \left\| \nabla_n \mathbf{U}_n - \left(\mathbf{W}_n \mathbf{V}_n^\top - \frac{\mathbf{M}_n}{\mu_M} \right) \right\|_F^2 + \frac{\mu_U}{2} \left\| \mathbf{U}_n - \left(\mathbf{Z}_n - \frac{\mathbf{P}_n}{\mu_U} \right) \right\|_F^2 \quad (6.6)$$

のように与えられる．この問題は二次形式の最小化問題であり，解析的に解くことができる．具体的には，線形方程式

$$(\nabla_n^\top (\mu_M \mathbf{W}_n \mathbf{V}_n^\top - \mathbf{M}_n) + (\mu_U \mathbf{Z}_n - \mathbf{P}_n)) \mathbf{U}_n = \mu_U \mathbf{I} + \mu_M \nabla_n^\top \nabla_n$$

を解くことで，更新式が得られる．

4) $\mathbf{Z}_n$ ($n = 1, \dots, N$) の更新：(6.3) を $\mathbf{Z}_n$ について最小化する問題は

$$\min_{\mathbf{Z}_n} \frac{\mu_{\mathcal{X}}}{2} \|\mathcal{X} - \mathbf{Z}_1 \circ \mathbf{Z}_2 \circ \dots \circ \mathbf{Z}_N\|_F^2 + \langle \mathbf{P}_n, \mathbf{U}_n - \mathbf{Z}_n \rangle + \frac{\mu_U}{2} \|\mathbf{U}_n - \mathbf{Z}_n\|_F^2 \quad (6.7)$$

のように与えられる．この問題は，(6.6) と同様に解くことができる．具体的には，

$$(\mu_U U_n + P_n + \mu_{\mathcal{X}} X_{(n)} E_n) Z_n = \mu_{\mathcal{X}} E_n E_n^\top + \mu_U I$$

を解くことで，更新式が得られる．ここで， $X_{(n)}$ は $\mathcal{X}$ の n モードの行列化であり， $E_n = (Z_N \circ Z_{N-1} \circ \cdots \circ Z_{n+1} \circ Z_{n-1} \circ \cdots \circ Z_1)^\top$ である．

5) $\mathcal{X}$ の更新：(6.3) を $\mathcal{X}$ について最小化すると，次のような更新式が得られる：

$$\begin{cases} \mathcal{X}_{\Omega^\perp} = \mathcal{L}_{\Omega^\perp} \\ \mathcal{X}_\Omega = \mathcal{Y}_\Omega \end{cases}. \quad (6.8)$$

ここで， $\mathcal{L} = Z_1 \circ Z_2 \circ \cdots \circ Z_N$ ， $\Omega^\perp$ は Ω の補集合である．

6) M_n, P_n ($n = 1, \dots, N$) の更新：ADMM の更新式に従い，次のように更新する：

$$\begin{aligned} M_n &\leftarrow M_n + \mu_M (\nabla_n U_n - W_n V_n^\top), \\ P_n &\leftarrow P_n + \mu_U (U_n - Z_n). \end{aligned} \quad (6.9)$$

6.3 多層ブロックスパース性を利用した MLSCP

多層スパース性 ($W_n = \nabla_n U_n V_n^\top$ のスパース性) のブロック構造を事前に知ることは困難である．その理由は，多層スパース性が，欠損テンソル $\mathcal{Y}$ に依存して変化する V_n を評価に用いるためである．そこで，適応的ブロックスパース正則化を導入することで，多層スパース性のブロック構造を推定し，より優れた CP 分解を実現する．この方法を Adaptive Block MLSCP (ABMLSCP) と呼ぶ．再重み付き ℓ_1 正則化を LOP- ℓ_2/ℓ_1 正則化に置き換えることで，ABMLSCP の最適化問題を

$$\begin{aligned} \min_{\mathcal{X}, U_n, W_n, V_n} & \frac{\mu_{\mathcal{X}}}{2} \|\mathcal{X} - U_1 \circ U_2 \circ \cdots \circ U_N\|_F^2 + \sum_{n=1}^N \lambda_n \Phi_{\alpha_n}(W_n) \\ \text{s.t. } & \nabla_n U_n = W_n V_n^\top, V_n^\top V_n = I, \mathcal{X}_\Omega = \mathcal{Y}_\Omega \end{aligned} \quad (6.10)$$

と定式化する． α_n は W_n のブロック構造を調整するハイパーパラメータである．この最適化問題は，MLSCP と同様，ADMM によって解くことができる． W_n 以外の変数については，MLSCP と同様の更新式 (アルゴリズム 4) が得られる． W_n は

$$\min_{W_n} \lambda_n \Phi_{\alpha_n}(W_n) + \langle M_n, \nabla_n U_n - W_n V_n^\top \rangle + \frac{\mu_M}{2} \|\nabla_n U_n - W_n V_n^\top\|_F^2$$

を解くことで更新できる．ただし，MLSCP で用いられた再重み付き ℓ_1 ノルムと異なり，この最小化問題は LOP- ℓ_2/ℓ_1 正則化項を含むため閉形式解を持たず，更新法 (アルゴリズム 1) で解く必要がある．よって，計算コストが高いことに注意が必要である．




図 6.4: 動画画像テンソルにおける時空間的なブロックスパース性 [41, Fig.1]

6.4 外れ値テンソルのブロック構造を利用した TRPCA

ブロックスパース性を利用したテンソルロバスト主成分分析は、画像中の移動物体検出や前景背景分離に有効である [15, 17, 41, 155]. これは移動物体や前景成分が画像中でブロック構造を持つためである. 更に、動画画像においては、画像の空間的なブロックスパース性だけでなく、時間的なブロックスパース性も存在する (図 6.4).

Adaptive Block TRPCA (ABTRPCA) は、TRPCA の ℓ_1 ノルムを $\text{LOP-}\ell_2/\ell_1$ 正則化項に置き換え、ブロック構造を適応的に推定することで、外れ値テンソルのスパース性だけでなくブロック構造も利用する. ABTRPCA の最適化問題は、次のように定式化される:

$$\min_{\mathcal{X}, \mathcal{S}} \Psi_{\alpha}(\mathcal{S}) \text{ s.t. } \mathcal{Y} = \mathcal{X} + \mathcal{S}, \text{rank}(\mathcal{X}) \leq r \quad (6.11)$$

$\mathcal{Y}$ は観測テンソル, $\mathcal{X}$ は低ランクテンソル, $\mathcal{S}$ はブロックスパースなテンソルである. ここでは、低ランク制約 $\text{rank}(\mathcal{L}) \leq r$ をテンソル核ノルム (Tensor Nuclear Norm, TNN) による正則化項 $\|\mathcal{L}\|_*$ に緩和することで、(6.11) の最適化問題を近似的に解くことを目指す. $\lambda > 0$ は正則化パラメータである.

$$\min_{\mathcal{X}, \mathcal{S}} \|\mathcal{X}\|_* + \lambda \Psi_{\alpha}(\mathcal{S}) \text{ s.t. } \mathcal{Y} = \mathcal{X} + \mathcal{S} \quad (6.12)$$

しかし、従来の $\text{LOP-}\ell_2/\ell_1$ 正則化項 (2.9) を用いて、(6.12) を解くことは容易でない. これは、等式制約 $\mathcal{Y} = \mathcal{L} + \mathcal{S}$ の影響で、線形拡張ラグランジュ法によって解ける最適化問題のクラスに属さないためである (注: 実は属するのでこの文章は誤り. よって、ABTRPCA

アルゴリズム 5 Adaptive Block TRPCA (ABTRPCA)

Input: Observation $\mathcal{Y}$, hyperparameters $\lambda, \rho, \mu, \alpha$
Initialize: $\mathcal{X}^{(0)}, \mathcal{T}^{(0)}, \mathcal{U}^{(0)}, \mathcal{H}^{(0)}, \mathcal{M}^{(0)}, \mathcal{P}^{(0)}$
for $k = 1, 2, \dots, K$ **do**

 Updating $\mathcal{X}^{(k)}$ via (6.16)

 Updating $\mathcal{T}^{(k)}$ via (6.17)

 Updating $\mathcal{U}^{(k)}$ via (6.18)

 Updating $\mathcal{H}^{(k)}$ via (6.19)

 Updating $\mathcal{M}^{(k)}, \mathcal{P}^{(k)}$ via (6.20)

Output: $\mathcal{X}^{(K)}, \mathcal{T}^{(K)} \boxtimes \mathcal{U}^{(K)} (= \mathcal{S}^{(K)})$

は線形拡張ラグランジュ法を用いて解くことができる。) この問題を, ADMM で解くことは容易ではない. ADMM で解くためには, $\text{LOP-}\ell_2/\ell_1$ において導入したパラメータ $\mathbf{u} = \mathbf{L}\mathbf{x}, \boldsymbol{\eta} = \mathbf{D}\boldsymbol{\sigma}$ に加えて, $\text{ReLOP-}\ell_2/\ell_1$ のように $\boldsymbol{\xi} = \boldsymbol{\sigma}$ を新たな最適化パラメータとして導入する必要がある. 最適化パラメータの追加は, 最適化アルゴリズムの計算コストや収束性に悪影響を与える. 他には, $\|\mathcal{X}\|_*$ と $\Psi_\alpha(\mathcal{S})$ の近接写像を交互に最適化するアプローチも考えられるが, 後者の近接写像は閉形式で解くことができないため, 計算コストが高い. 一方, (5.8) に示した $\text{LOP-}\ell_2/\ell_1$ 正則化の別表現を用いることで, 上記の欠点を解消した ADMM による (6.12) の最適化アルゴリズム (アルゴリズム 5) を導出することができる. 提案するアルゴリズムは, 最適化パラメータの追加を回避でき, 閉形式解の計算を繰り返すのみで (6.12) を効率的に解くことができる^{*1}

$\text{LOP-}\ell_2/\ell_1$ 正則化の別表現を用いると, (6.12) は次のように定式化される:

$$\min_{\mathcal{X}, \mathcal{T}, \mathcal{U}} \|\mathcal{X}\|_* + \frac{\lambda}{2} \|\mathcal{T}\|_F^2 + \frac{\lambda}{2} \|\mathcal{U}\|_F^2 \text{ s.t. } \mathcal{Y} = \mathcal{X} + \mathcal{T} \boxtimes \mathcal{U}, \|\mathcal{D}(\mathcal{U})\|_1 \leq \alpha. \quad (6.13)$$

ここで, $\mathcal{T}, \mathcal{U}$ はテンソルであり, $\mathcal{S} = \mathcal{T} \boxtimes \mathcal{U}$ を満たす. $\mathcal{D}(\mathcal{U})$ は, N 階テンソル $\mathcal{U}$ の全方向 (第 1 モード方向, 第 2 モード方向, $\dots$, 第 N モード方向) に対する微分を第 1 モード方向に並べたテンソルである. つまり, $\mathcal{U} \in \mathbb{R}^{J_1 \times \dots \times J_N}$ に対して

$$\mathcal{D}(\mathcal{U}) = \begin{bmatrix} \mathcal{U} \times_1 \mathbf{D}_{J_1} \\ \mathcal{U} \times_2 \mathbf{D}_{J_2} \\ \vdots \\ \mathcal{U} \times_N \mathbf{D}_{J_N} \end{bmatrix}$$

^{*1} 部分最適化を閉形式解で行えない ABMLSCP (6.10) のようなテンソル分解においても, 閉形式解の計算のみで解を求められるようになる.

を満たす. $\mathbf{D}_{J_n}$ ($n = 1, \dots, N$) は, 要素数 J_n のベクトルに対する微分作用素である. 2 項演算子 $\times_N$ は, テンソルの N モード積を表す. この演算子は, テンソル $\mathbf{Y}, \mathbf{X}$, 行列 $\mathbf{A}$ に対して, $\mathbf{Y} = \mathbf{X} \times_N \mathbf{A}$ が成り立つとき, $\mathbf{Y}$ の第 N モード方向における行列化が $\mathbf{Y}_{(n)} = \mathbf{A} \mathbf{X}_{(n)}$ を満たす. $\mathbf{X}_{(n)}, \mathbf{Y}_{(n)}$ は $\mathbf{X}, \mathbf{Y}$ の n モードに対する行列化である. また, 微分作用素 $\mathcal{D}$ に対して

$$\mathbf{D}_{\text{Nd}} = \begin{bmatrix} \mathbf{D}_{J_1} \otimes \mathbf{I}_{J_2} \otimes \cdots \otimes \mathbf{I}_{J_N} \\ \mathbf{I}_{J_1} \otimes \mathbf{D}_{J_2} \otimes \cdots \otimes \mathbf{I}_{J_N} \\ \vdots \\ \mathbf{I}_{J_1} \otimes \mathbf{I}_{J_2} \otimes \cdots \otimes \mathbf{D}_{J_N} \end{bmatrix}$$

と定義される行列を用いるとき, $\text{vec}(\mathcal{D}(\mathbf{U})) = \mathbf{D}_{\text{Nd}} \text{vec}(\mathbf{U})$ を満たす. (6.13) は最適化パラメータ $\mathcal{H} = \mathcal{D}(\mathbf{U})$ を導入すると,

$$\min_{\mathbf{X}, \mathcal{T}, \mathbf{U}, \mathcal{H}} \|\mathbf{X}\|_* + \frac{\lambda}{2} \|\mathcal{T}\|_F^2 + \frac{\lambda}{2} \|\mathbf{U}\|_F^2 + \iota_{B_1^\alpha}(\mathcal{H}) \text{ s.t. } \mathbf{Y} = \mathbf{X} + \mathcal{T} \boxplus \mathbf{U}, \mathcal{H} = \mathcal{D}(\mathbf{U}) \quad (6.14)$$

と書き換えられる. 対応する拡張ラグランジュ関数 $\mathcal{L}(\mathbf{X}, \mathcal{T}, \mathbf{U}, \mathcal{H}, \mathcal{M}, \mathcal{P})$ は

$$\begin{aligned} \mathcal{L}(\mathbf{X}, \mathcal{T}, \mathbf{U}, \mathcal{H}, \mathcal{M}, \mathcal{P}) &= \|\mathbf{X}\|_* + \frac{\lambda}{2} \|\mathcal{T}\|_F^2 + \frac{\lambda}{2} \|\mathbf{U}\|_F^2 + \iota_{B_1^\alpha}(\mathcal{H}) \\ &+ \langle \mathcal{M}, \mathbf{Y} - \mathbf{X} - \mathcal{T} \boxplus \mathbf{U} \rangle + \frac{\rho}{2} \|\mathbf{Y} - \mathbf{X} - \mathcal{T} \boxplus \mathbf{U}\|_F^2 \\ &+ \langle \mathcal{P}, \mathcal{H} - \mathcal{D}(\mathbf{U}) \rangle + \frac{\mu}{2} \|\mathcal{H} - \mathcal{D}(\mathbf{U})\|_F^2. \end{aligned} \quad (6.15)$$

ここで, $\mathcal{M}, \mathcal{P}$ はラグランジュ乗数テンソルである. (6.15) を $\mathbf{X}, \mathcal{T}, \mathbf{U}, \mathcal{H}, \mathcal{M}, \mathcal{P}$ について ADMM によって最小化することで, (6.14) の最適化アルゴリズムが得られる. 各変数の更新手続きを以下に示す.

1) $\mathbf{X}$ の更新: (6.14) を $\mathbf{X}$ について最小化する問題は

$$\min_{\mathbf{X}} \|\mathbf{X}\|_* + \langle \mathcal{M}, \mathbf{Y} - \mathbf{X} - \mathcal{T} \boxplus \mathbf{U} \rangle + \frac{\rho}{2} \|\mathbf{Y} - \mathbf{X} - \mathcal{T} \boxplus \mathbf{U}\|_F^2 \quad (6.16)$$

のように与えられる. これを解くためには, テンソル特異値ソフト閾値処理 (T-SVT) を用いる.

$$\mathbf{X} = \text{T-SVT}_{1/\rho}(\mathbf{Y} - \mathcal{T} \boxplus \mathbf{U} + \mathcal{M}/\rho)$$

T-SVT $_\delta$ は直感的には, テンソルにおける特異値分解を行い, その特異値を δ によってソフト閾値処理する演算である. 例えば, テンソルが行列 $\mathbf{A}$ に対応する場合, T-SVT $_\delta$ は行列の特異値分解 $\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top$ を行い, $\mathbf{\Sigma}$ の対角成分 σ_i に対して $\sigma_i \leftarrow \max\{\sigma_i - \delta, 0\}$ を適用する. T-SVT はテンソル核ノルムの定義によって様々に変化する. テンソル核ノルムを Order-d TNN [156, Definition 3.9] とすると, T-SVT は Order-d T-SVT [156, Definition

3.10] と呼ばれる演算に対応する．この T-SVT は，高階テンソルに対する特異値分解の手法として近年注目されている [68, 157]．

2) $\mathcal{T}$ の更新：(6.14) を $\mathcal{T}$ について最小化する問題は

$$\begin{aligned} & \min_{\mathcal{T}} \frac{\lambda}{2} \|\mathcal{T}\|_F^2 + \langle \mathcal{M}, \mathcal{Y} - \mathcal{X} - \mathcal{T} \boxdot \mathcal{U} \rangle + \frac{\rho}{2} \|\mathcal{Y} - \mathcal{X} - \mathcal{T} \boxdot \mathcal{U}\|_F^2 \\ & = \min_{\mathcal{T}} \frac{\lambda}{2} \|\mathcal{T}\|_F^2 + \frac{\rho}{2} \|\mathcal{T} \boxdot \mathcal{U} - (\mathcal{Y} - \mathcal{X}) - \mathcal{M}/\rho\|_F^2 \end{aligned} \quad (6.17)$$

のように与えられる．拡張ラグランジュ関数は， $\mathcal{T}$ について二次形式の最小化問題である．ゆえに， $\mathcal{T}$ の更新式を閉形式で表せる．具体的には，拡張ラグランジュ関数を $\mathcal{T}$ について微分し，その微分が零テンソル $\mathcal{O}$ となるような $\mathcal{T}$ を求める．

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial \mathcal{T}} &= \lambda \mathcal{T} + \rho \mathcal{U} \boxdot \{\mathcal{T} \boxdot \mathcal{U} - (\mathcal{Y} - \mathcal{X} + \mathcal{M}/\rho)\} \\ &= \lambda \mathcal{T} + \rho \mathcal{U}^{\boxdot 2} \boxdot \mathcal{T} - \rho \mathcal{U} \boxdot (\mathcal{Y} - \mathcal{X} + \mathcal{M}/\rho) \\ &= (\lambda \mathcal{I} + \rho \mathcal{U}^{\boxdot 2}) \boxdot \mathcal{T} - \rho \mathcal{U} \boxdot (\mathcal{Y} - \mathcal{X} + \mathcal{M}/\rho) \end{aligned}$$

ここで， $\mathcal{U}^{\boxdot 2}$ はテンソル $\mathcal{U}$ の要素ごとの 2 乗を返すテンソル， $\mathcal{I}$ は全ての要素が 1 のテンソルである．よって， $\mathcal{T}$ は

$$\mathcal{T} = \rho \mathcal{U} \boxdot (\mathcal{Y} - \mathcal{X} + \mathcal{M}/\rho) \boxtimes (\lambda \mathcal{I} + \rho \mathcal{U}^{\boxdot 2})$$

と更新できる． $\boxtimes$ はテンソルの要素ごとの除算を表す．

3) $\mathcal{U}$ の更新：(6.14) を $\mathcal{U}$ について最小化する問題は

$$\begin{aligned} & \min_{\mathcal{U}} \frac{\lambda}{2} \|\mathcal{U}\|_F^2 + \langle \mathcal{M}, \mathcal{Y} - \mathcal{X} - \mathcal{T} \boxdot \mathcal{U} \rangle + \frac{\rho}{2} \|\mathcal{Y} - \mathcal{X} - \mathcal{T} \boxdot \mathcal{U}\|_F^2 \\ & \quad + \langle \mathcal{P}, \mathcal{H} - \mathcal{D}(\mathcal{U}) \rangle + \frac{\mu}{2} \|\mathcal{H} - \mathcal{D}(\mathcal{U})\|_F^2 \\ & = \min_{\mathcal{U}} \frac{\lambda}{2} \|\mathcal{U}\|_F^2 + \frac{\rho}{2} \|\mathcal{T} \boxdot \mathcal{U} - (\mathcal{Y} - \mathcal{X} + \mathcal{M}/\rho)\|_F^2 + \frac{\mu}{2} \|\mathcal{D}(\mathcal{U}) - \mathcal{H} - \mathcal{P}/\mu\|_F^2 \end{aligned} \quad (6.18)$$

のように与えられる．フロベニウスノルムの中のテンソルをベクトル化すると，

$$\min_{\mathbf{u}} \frac{\lambda}{2} \|\mathbf{u}\|_2^2 + \frac{\rho}{2} \|\mathbf{t} \boxdot \mathbf{u} - (\mathbf{y} - \mathbf{x} + \mathbf{m}/\rho)\|_2^2 + \frac{\mu}{2} \|\mathbf{D}_{Nd} \mathbf{u} - \boldsymbol{\eta} - \mathbf{p}/\mu\|_2^2$$

となる． $\boldsymbol{\eta}, \mathbf{m}, \mathbf{p}, \mathbf{t}, \mathbf{u}, \mathbf{x}, \mathbf{y}$ はそれぞれ $\mathcal{H}, \mathcal{M}, \mathcal{P}, \mathcal{T}, \mathcal{U}, \mathcal{X}, \mathcal{Y}$ のベクトル化である．この問題は， $\mathbf{u}$ について二次形式の最小化問題である．よって，拡張ラグランジュ関数を $\mathbf{u}$ について微分し，その微分が零ベクトル $\mathbf{0}$ となるような $\mathbf{u}$ を求める．

$$\frac{\partial \mathcal{L}}{\partial \mathbf{u}} = \lambda \mathbf{u} + \rho \mathbf{t} \boxdot (\mathbf{t} \boxdot \mathbf{u} - (\mathbf{y} - \mathbf{x} + \mathbf{m}/\rho)) + \mu \mathbf{D}_{Nd}^\top (\mathbf{D}_{Nd} \mathbf{u} - (\boldsymbol{\eta} + \mathbf{p}/\mu))$$

$$\begin{aligned}
&= \lambda \mathbf{u} + \rho \mathbf{t}^{\square 2} \square \mathbf{u} + \mu \mathbf{D}_{N_d}^\top \mathbf{D}_{N_d} \mathbf{u} - \rho \mathbf{t} \square (\mathbf{y} - \mathbf{x} + \mathbf{m}/\rho) - \mu \mathbf{D}_{N_d}^\top (\boldsymbol{\eta} + \mathbf{p}/\mu) \\
&= (\lambda \mathbf{I} + \rho \text{diag}(\mathbf{t}^{\square 2}) + \mu \mathbf{D}_{N_d}^\top \mathbf{D}_{N_d}) \mathbf{u} - \rho \mathbf{t} \square (\mathbf{y} - \mathbf{x} + \mathbf{m}/\rho) - \mu \mathbf{D}_{N_d}^\top (\boldsymbol{\eta} + \mathbf{p}/\mu)
\end{aligned}$$

ここで、同じサイズのベクトル $\mathbf{a}, \mathbf{b}$ に対して、 $\mathbf{a} \square \mathbf{b} = \text{diag}(\mathbf{a})\mathbf{b}$ が成り立つことを用いた。
よって、 $\mathbf{u}$ は線形方程式

$$(\lambda \mathbf{I} + \rho \text{diag}(\mathbf{t}^{\square 2}) + \mu \mathbf{D}_{N_d}^\top \mathbf{D}_{N_d}) \mathbf{u} = \rho \mathbf{t} \square (\mathbf{y} - \mathbf{x} + \mathbf{m}/\rho) + \mu \mathbf{D}_{N_d}^\top (\boldsymbol{\eta} + \mathbf{p}/\mu)$$

を解くことで更新できる。

4) $\boldsymbol{\varepsilon}$ の更新：(6.14) を $\boldsymbol{\varepsilon}$ について最小化する問題は

$$\begin{aligned}
&\min_{\boldsymbol{\mathcal{H}}} \iota_{B_1^\alpha}(\boldsymbol{\mathcal{H}}) + \langle \boldsymbol{\mathcal{P}}, \boldsymbol{\mathcal{H}} - \mathcal{D}(\mathbf{u}) \rangle + \frac{\mu}{2} \|\boldsymbol{\mathcal{H}} - \mathcal{D}(\mathbf{u})\|_F^2 \\
&= \min_{\boldsymbol{\mathcal{H}}} \iota_{B_1^\alpha}(\boldsymbol{\mathcal{H}}) + \frac{\mu}{2} \|\boldsymbol{\mathcal{H}} - \mathcal{D}(\mathbf{u}) + \boldsymbol{\mathcal{P}}/\mu\|_F^2
\end{aligned} \tag{6.19}$$

のように与えられる。 $\boldsymbol{\mathcal{H}}$ は ℓ_1 球射影 $P_{B_1^\alpha}$ (2.14) を用いて更新できる：

$$\boldsymbol{\mathcal{H}} \leftarrow P_{B_1^\alpha}(\mathcal{D}(\mathbf{u}) - \boldsymbol{\mathcal{P}}/\mu)$$

5) $\boldsymbol{\mathcal{M}}, \boldsymbol{\mathcal{P}}$ の更新：ADMM の更新式に従い、次のように更新する：

$$\begin{aligned}
\boldsymbol{\mathcal{M}} &\leftarrow \boldsymbol{\mathcal{M}} + \rho(\mathbf{y} - \mathbf{x} - \boldsymbol{\mathcal{T}} \square \mathbf{u}), \\
\boldsymbol{\mathcal{P}} &\leftarrow \boldsymbol{\mathcal{P}} + \mu(\boldsymbol{\mathcal{H}} - \mathcal{D}(\mathbf{u})).
\end{aligned} \tag{6.20}$$

第 7 章

数値実験

7.1 時系列信号のノイズ除去

7.1.1 矩形波ノイズ除去

LOP- ℓ_2/ℓ_1 と LOP- ℓ_2/ℓ_1 ALT の比較 図 7.1a 左の矩形波 $\mathbf{x}^*$ へ、標準正規分布に従うノイズ ε を SNR (signal-noise ratio) が 20 となるように加えたノイズ付き信号 (図 7.1a 右)

$$\mathbf{y} = \mathbf{x}^* + \varepsilon$$

を LOP- ℓ_2/ℓ_1 と LOP- ℓ_2/ℓ_1 ALT により復元する. SNR ($:= 20 \log_{10} \|\mathbf{x}^*\|_2 / \|\mathbf{x}^* - \hat{\mathbf{x}}\|_2$) は大きいほど信号成分が強く、ノイズ成分が弱いことを示す指標である.

LOP- ℓ_2/ℓ_1 と LOP- ℓ_2/ℓ_1 ALT の復元結果 $\hat{\mathbf{x}}$ とブロックの推定結果 $\hat{\sigma}$ を図 7.2, 7.3 にそれぞれ示す. 図 7.2 より, LOP- ℓ_2/ℓ_1 は矩形波 (図 7.1a 左) の真のブロック構造を正しく推定できておらず, 矩形波の復元が不十分であることがわかる. 一方, 図 7.3 を見ると, LOP- ℓ_2/ℓ_1 ALT は, LOP- ℓ_2/ℓ_1 と比較して, 矩形波の微分 (図 7.1b 左) のブロック推定を正しく行えており, 復元信号がより正確であることがわかる.





図 7.1: 矩形波とその微分 (左列：真値, 右列：観測値 (SNR = 20))



(a) 復元結果



(b) ブロックの推定結果 σ

図 7.2: LOP- ℓ_2/ℓ_1 による復元結果とブロックの推定結果. パラメータは $\lambda = 0.1$, かつ列の左から $\alpha = 10^{-4}, 1.0, 10^4$ とする.



(a) 復元結果


(b) ブロックの推定結果 σ

図 7.3: LOP- ℓ_2/ℓ_1 ALT による復元結果とブロックの推定結果. パラメータは $\lambda = 1.0$, かつ列の左から $\alpha = 10^{-4}, 1.0, 10^4$ とする.




図 7.4: イオン電流に対するノイズ除去の結果の比較. 赤, 緑, 青の線はそれぞれ $\lambda = 1, 5, 10$ の場合の推定値を表す.

7.1.2 イオン電流の実ノイズ除去

提案手法 $\text{LOP-}l_2/l_1\text{ALT}$ を用いて, 実世界のイオン電流に含まれるノイズを除去する. このイオン電流は, ナノポアシーケンサーによって測定される生物学的な信号であり, 多様なノイズを含む [158]. この実験により, $\text{LOP-}l_2/l_1\text{ALT}$ が実世界のノイズ除去に有効であることを示す. また, $\text{LOP-}l_2/l_1\text{ALT}$ がブロック構造を推定することによって, l_1 ノルムを用いた TV 正則化と異なり, 過剰な正則化による過平滑化を回避できることを示す. 人工データにおける実験と同様の設定のもとでノイズ付き観測信号 $\mathbf{y} \in \mathbb{R}^{750}$ から, 信号 $\mathbf{x} \in \mathbb{R}^{750}$ を推定する. ノイズ除去の結果を図 7.4, 提案手法が推定したブロックを図 7.5 にそれぞれ示す. 結果から, $\text{LOP-}l_2/l_1\text{ALT}$ は, TV 正則化と比較して, 大きな λ , ここでは $\lambda \in \{5, 10\}$ による過剰な正則化から生じる過平滑化が起こりにくいとわかる. 過平滑化への耐性は, ブロック構造の推定 (図 7.5) による恩恵だと考えられる. これは, ブロック構造を正しく推定している $\alpha = 0.1$ のときの提案手法で, 他と比べて過平滑化が起こっていないことからわかる.




図 7.5: 提案手法で推定したイオン電流の微分のブロック構造の比較

7.2 画像ノイズ除去

LOP- ℓ_2/ℓ_1 ALT (提案手法) と TV 正則化の比較 画像のノイズ除去を例にして、ノイズを除去する性能の高さと、提案手法 LOP- ℓ_2/ℓ_1 ALT でブロック構造を推定することによる復元結果への影響について示す。後者の結果により、TV 正則化における適切な正則化パラメータを元に、提案手法の正則化パラメータ λ を選択する方針を得ることができる。また、時系列信号とは異なるドメインの信号である画像において、提案手法が有効であることを示す。TV 正則化の適切な正則化パラメータを選択する研究は既に多く存在する [57, 159, 160] ため、これらを利用することで、提案手法の誤った正則化パラメータを選ぶリスクを下げることができる。この目的のために、5dB となるようにガウシアンノイズとごま塩ノイズを付加した、大きさが 256×256 の画像を、TV 正則化と提案手法でノイズ除去した結果図 7.6 を比較する。そして、画像の TV 正則化に用いる微分作用素 D_{2d} は、 $M \times N$ の画像に対して、

$$D_{2d} = \begin{bmatrix} D_M \otimes I_N \\ I_M \otimes D_N \end{bmatrix}$$

と定義する. $\mathbf{D}_M$ と $\mathbf{D}_N$ は, それぞれ要素数 M と N のベクトルに対する微分作用素である. $\mathbf{I}_M$ と $\mathbf{I}_N$ は, それぞれ大きさが $M \times M$ と $N \times N$ の単位行列である. $\mathbf{D}_{2d}$ は, 画像の各ピクセルに対して, そのピクセルの上下左右の隣接ピクセルとの差を取る作用を表す. つまり, 画像の縦方向の差分を取る作用素 $\mathbf{D}_v$ と横方向の差分を取る作用素 $\mathbf{D}_h$ を用いるとき, $\mathbf{D}_{2d}\mathbf{x} = \begin{bmatrix} \mathbf{D}_v\mathbf{x} \\ \mathbf{D}_h\mathbf{x} \end{bmatrix}$ を満たす.

図 7.6 の (a) と (e) は, TV 正則化による平滑化が不十分な場合 ($\lambda = 0.15$) である. このとき, 提案手法 (c), (g) はブロック構造を推定することによって, ノイズ除去を改善している事がわかる. (c) では (b) における階段状のアーティファクトがなくなり, (g) については (f) における不自然なエッジの復元が改善されている. 対して, 図 7.6 の (b), (f) は, TV 正則化で十分に平滑化を行った場合 ($\lambda = 0.22$) である. 先程と異なり, 提案手法 (d), (h) は, TV 正則化よりも低い SNR を示し, 画像をぼかしていることがわかる. したがって, 提案手法の正則化パラメータ λ は, TV 正則化で十分なノイズ除去を得るものよりも小さく設定することが望ましいと予想される.

提案手法 (LOP- ℓ_2/ℓ_1 ALT, ReLOP- ℓ_2/ℓ_1 , GROWL) と既存手法の比較 5dB となるようにガウシアンノイズを付加した, 大きさが 256×256 の 10 種類の自然画像に対してノイズ除去を行う. その結果を, 提案手法 (LOP- ℓ_2/ℓ_1 ALT, ReLOP- ℓ_2/ℓ_1 , GROWL) と既存手法 (① TV ノルム, ②再重み付き TV ノルム, ③ ℓ_0 -Grad, ④ ROWL) で比較する. 実験に用いる自然画像の一覧を図 7.7 に示す. 損失関数には, 二乗誤差 $f(\mathbf{x}) = \frac{1}{2}\|\mathbf{y} - \mathbf{x}\|_2^2$ と正則化項 $\lambda \cdot \Omega(\mathbf{x})$ の和を用いる. 正則化項 $\Omega(\mathbf{x})$ は, 表 7.1 に示すものを用い, 正則化パラメータ λ は $\{10^{-5}, 10^{-4}, 10^{-3}, 10^{-2}, 10^{-1}, 1\}$ の中から, 各手法において最も良い結果を示すものを選択する. また, GROWL においては, 対数関数 $\log(\frac{\cdot}{\epsilon} + 1)$ を用いて推定バイアスの抑制を試みる.

表 7.2 に, 提案手法と既存手法から得られる復元画像の SNR を示す. 全ての画像について, 適応的ブロックスパース正則化である提案法②と提案法③のどちらかが最も高い SNR を示している. また, 提案法①も, 多くの画像 (10 画像中 6 画像) で既存手法よりも高い SNR を示している. ゆえに, 画像ノイズ除去において, 適応的ブロックスパース正則化は, そうでない正則化よりも高い性能を示すことがわかる. ただし, 提案法②と提案法③のどちらがより良い結果を示すかは, 画像によって異なる. これは, 正則化項の凸性と画像の視覚的な特性に関連していると考えられる. 例えば, テクスチャの細かい画像 (babara, bark, mandril) においては, 凸正則化である提案法②が最も高い SNR を示している. 一方で, エッジの数が少ない画像 (house, jetplane, cameraman) においては, 非凸正則化である提案法③が最も高い SNR を示している. この傾向は, ①と② (TV ノルムと再重み付き TV




図 7.6: (a)～(d): 自然画像に対するガウシアンノイズ除去の結果. (e)～(h): 自然画像に対するごま塩ノイズ除去の結果. (a), (b), (e), (f): TV 正則化による結果. (c), (d), (g), (h): 提案手法 (LOP- ℓ_2/ℓ_1 ALT) による結果. LOP- ℓ_2/ℓ_1 ALT のハイパーパラメータ α は 1000 とおいた.



図 7.7: ノイズ除去の比較実験で用いる元画像の一覧 (1 行目) とガウシアンノイズを付加した画像の一覧 (2 行目). 本章では, 画像を左から順に barbara, bark, cameraman, house, jetplane, lake, livingroom, mandril, peppers と呼ぶ.

	正則化項 $\Omega(\mathbf{x})$
① TV ノルム (例 1.3)	$\ \mathbf{D}_{2d}\mathbf{x}\ _1$
② 再重み付き TV ノルム (1.11)	$\ \mathbf{D}_{2d}\mathbf{x}\ _{w,1}$
③ ℓ_0 -Grad [161]	$\iota_{B_0^K}(\mathbf{D}_{2d}\mathbf{x})$
④ ROWL (1.9)	$\Omega_w(\mathbf{D}_{2d}\mathbf{x})$
(提案法①) GROWL (4.10)	$\Omega_w^{\log(\frac{\cdot}{\epsilon}+1)}(\mathbf{D}_{2d}\mathbf{x})$
(提案法②) LOP- ℓ_2/ℓ_1 ALT (3.1)	$\Phi_\alpha(\mathbf{D}_{2d}\mathbf{x})$
(提案法③) ReLOP- ℓ_2/ℓ_1 (4.1)	$\tilde{\psi}_\alpha(\mathbf{D}_{2d}\mathbf{x})$

表 7.1: 画像ノイズ除去の性能比較で用いる正則化項の一覧. ハイパーパラメータは ③, ④ と提案法①においては $K \in \{0, 1310, 2621, 5242, 10485\}$, 提案法②と提案法③においては $\alpha \in \{10, 10^3, 10^5\}$ の中から, 最も良い結果を示すものを選択する. また, ④と提案法①においては $w_0 = \dots = w_K = 0, w_{K+1} = \dots = w_N = \lambda$, 提案法②と提案法③においては $\epsilon = 0.01$ と設定する.

ノルム), ④と提案法① (ROWL と GROWL) の間でも見られる.

ABTRPCA と TRPCA の比較 ABTRPCA と TRPCA の性能を比較することで, 外れ値テンソルのブロック構造推定がノイズ除去に与える影響を調べる. ここでは, 3 階以上のテンソルではなく, 2 階のテンソル (グレースケール画像) に対して, ABTRPCA と TRPCA を直接適用した場合のノイズ除去の結果を比較する. ABTRPCA (6.13) における低ランク正則化には, 行列の核ノルム $\|\mathbf{X}\|_* = \sum_{i=1}^{\min\{M,N\}} \sigma_i(\mathbf{X})$ を用いる. $\sigma_i(\mathbf{X})$ は行列 $\mathbf{X} \in \mathbb{R}^{M \times N}$ の第 i 番目に大きな特異値を表す. そのために, 大きさが 256×256 の starfish 画像 (図 7.8 (a)) に, ブロックスパースな外れ値行列 (図 7.8 (b)) を付加した画像 (図 7.8 (c)) に対し, ABTRPCA によるノイズ除去とブロック構造推定を行う. 外れ値行

	①	②	③	④	提案法①	提案法②	提案法③
barbara	13.12	12.83	14.21	14.21	14.12	16.55	<u>15.99</u>
bark	10.40	7.22	8.90	10.31	8.87	11.34	9.33
brickwall	10.90	8.69	10.58	10.80	10.57	11.99	10.68
cameraman	13.90	14.57	15.81	15.81	15.79	<u>16.32</u>	17.26
house	15.52	16.34	17.14	17.14	<u>17.17</u>	<u>18.14</u>	19.88
jetplane	16.04	16.64	16.77	16.74	<u>16.82</u>	<u>17.99</u>	19.09
lake	12.61	13.06	14.03	14.03	<u>14.11</u>	<u>15.10</u>	15.90
livingroom	13.33	13.77	14.51	14.51	<u>14.54</u>	<u>16.09</u>	16.12
mandril	13.76	14.20	14.32	14.32	<u>14.40</u>	15.78	<u>15.67</u>
peppers	13.08	13.38	14.72	14.72	<u>14.77</u>	<u>16.80</u>	17.29

表 7.2: 画像ノイズ除去の性能比較. SNR が最も高い結果を太字で示す. 提案法の SNR が既存法を上回る場合はその SNR を下線で示す.

列は, 各要素が $[0, 1]$ の一様乱数で生成した 5×5 のブロック行列を, 行列中のランダムな位置に挿入することで作成した. そして, ABTROCA によるノイズ除去の結果を, 図 7.8 と図 7.9 に $\alpha = 10^3, 10^4, 10^5$ と $\lambda = 0.06, 0.08$ の組み合わせで示す. $\text{LOP-}l_2/l_1$ の挙動は $\alpha \rightarrow \infty$ に近づくほど l_1 ノルム (TRPCA) へ近づく. そのため, ABTRPCA は $\alpha = 10^5$ において単にスパースな外れ値行列, $\alpha = 10^3, 10^4$ において, よりブロックスパースな外れ値行列を推定する. よって, α の減少に伴う外れ値テンソルのブロック構造と復元画像の変化を観察することで, ブロック構造の推定が与えるノイズ除去への影響を調べることができる. 更に, λ を減少させる ($0.08 \rightarrow 0.06$) とき, つまり真の画像の一部を過度に外れ値として扱うとき, ABTRPCA によるブロック構造推定がノイズ除去に与える影響についても調べる.

まず, α の増減に伴う復元画像の変化を観察する. ここでは図 7.9 に示す画像を用いる. 結果として, α が小さいほど, ABTRPCA がブロックスパースなノイズを推定しており, 真の画像の一部をノイズとして扱わないことがわかる. これは, 推定されたノイズのブロック構造 (i) が (f) と比べて, 真の画像のエッジをノイズとして保持しないことから確認できる. ただし, α を過度に小さくすると, (l) のようにノイズさえも外れ値行列から無視してしまうため, ノイズ除去を十分に行うことができない. 加えて, 復元画像 (d) と (g) を見ても, その復元結果に大差がないことから, ABTRPCA においてブロック構造推定がグレースケール画像のノイズ除去に与える影響は限定的であることがわかる. 図 7.8 においても同

様の傾向が見られる。

次に λ を小さく ($0.08 \rightarrow 0.06$), つまり真の画像の一部を過度に外れ値として扱う場合の, ABTRPCA によるノイズ除去の結果を観察する. そのために $\lambda = 0.06$ の場合 (図 7.8) における, 推定されたノイズのブロック構造 (f), (i), (l) に注目する. 結果として, α を小さくした場合であっても真の画像におけるエッジ情報をブロックスパースなノイズとして扱ってしまうことがわかる. したがって, 自然画像のブロックスパースなノイズ除去に ABTRPCA を直接適用することは, 自然画像の持つエッジ情報を損なうため, 適切ではないことが示された. このことから, 自然画像の持つエッジ情報とブロックスパースな外れ値を分離する技術を ABTRPCA と組み合わせることが, ABTRPCA のノイズ除去性能を向上させると予想される. 例えば, 動画画像テンソルの場合, 顕著性マップ [15, 41] を共に用いることで, ABTRPCA の外れ値除去の性能が向上すると考えられる.

7.3 テンソル補完

提案手法: Adaptive Block MLSCP (ABMLSCP) のテンソル補完の性能を示すために, RGB 画像のテンソル補完実験を行う. RGB 画像には, barbara, house, parrot, jetplane, facade の 5 種類の画像を用いる (図 7.10 1 列目). RGB 画像のサイズは $256 \times 256 \times 3$ である. それぞれの画像は, ベルヌーイ分布に従って画像中の 90% の画素値がランダムに欠損している (図 7.10 2 列目). 図 7.10 の 3~5 列目に, 提案手法と既存手法である ℓ_1 ノルム と 再重み付き ℓ_1 ノルムによるテンソル補完の結果と Relative Squared Error (RSE, $\|\mathbf{X}^* - \hat{\mathbf{X}}\|_F / \|\mathbf{X}^*\|_F$) を示す. $\mathbf{X}^*$ は真のテンソルであり, $\hat{\mathbf{X}}$ は補完されたテンソルを表す. これらの補完結果より, 提案手法が ℓ_1 ノルムよりも優れた RSE を示すことがわかる. また, LOP- ℓ_2/ℓ_1 は凸正則化であるにも関わらず, 非凸正則化である再重み付き ℓ_1 ノルムに匹敵する性能を示している. よって, 多層スパース性のブロック構造の利用が RGB 画像のテンソル補完に有効であることが示された.




図 7.8: ABTRPCA ($\lambda = 0.06$) によるブロックスパースノイズ除去の結果. α を $10^3, 10^4, 10^5$ と変化させた結果を示す.




図 7.9: ABTRPCA ($\lambda = 0.08$) によるブロックスパースノイズ除去の結果. α を $10^3, 10^4, 10^5$ と変化させた結果を示す.




図 7.10: テンソル補完結果の比較. 各画像下の数値は RSE (Relative Squared Error) を示す. 正則化パラメータは [25] に倣い, $\lambda_1=4.8, \lambda_2=4.8, \lambda_3=0.4$ とした.




図 7.11: 微分可能な LOP- ℓ_2/ℓ_1 を適用した第 2 層の重みのヒストグラム (縦軸は対数軸). 横軸の値は重みの値を, 縦軸の値はその重みの出現頻度を示す. よって, 0 付近の重みが多く現れるほど, つまり λ が大きいとき重み行列がスパースになることがわかる.

7.4 MNIST における 3 層 MLP の枝刈り

微分可能な LOP- ℓ_2/ℓ_1 (5.9) を, 3 層の多層パーセプトロン (MLP) を用いた MNIST の 10 クラス分類問題に適用する. MLP の計算は, $\mathbf{y} = \text{softmax}(\mathbf{W}_3(\mathbf{W}_2(\mathbf{W}_1\mathbf{x} + \mathbf{b}_1)_+ + \mathbf{b}_2)_+ + \mathbf{b}_3)$ によって行う. $\mathbf{y} \in \mathbb{R}^{10}$ は MLP の出力である. 重み行列 $\mathbf{W}_1 \in \mathbb{R}^{100 \times 784}$, $\mathbf{W}_2 \in \mathbb{R}^{1024 \times 1024}$, $\mathbf{W}_3 \in \mathbb{R}^{10 \times 1024}$ とバイアスベクトル $\mathbf{b}_1 \in \mathbb{R}^{100}$, $\mathbf{b}_2 \in \mathbb{R}^{1024}$, $\mathbf{b}_3 \in \mathbb{R}^{10}$ は, それぞれ全結合層の最適化パラメータである. $\mathbf{x} \in \mathbb{R}^{784}$ は MNIST の入力画像 (28×28) をベクトル化したものである. $(z)_+ = \max(z, 0)$ は ReLU 活性化関数である. また, 出力 $\mathbf{y}$ は 10 クラス分類問題のため, ソフトマックス関数 $\text{softmax}(\mathbf{z})_i = \exp(z_i) / \sum_{i=1}^{10} \exp(z_i)$ を用いる. また, 10 クラス分類のための損失関数には交差エントロピー誤差を用いる.

本実験では, MLP の第 2 層の重み行列 $\mathbf{W}_2$ に微分可能な LOP- ℓ_2/ℓ_1 を適用し, 構造的な枝刈りがどのように行われるかを調べる. 微分可能な LOP- ℓ_2/ℓ_1 で用いる正則化項 $\Omega(\mathbf{D}\boldsymbol{\sigma})$ としては, TV ノルム $\|\mathbf{D}\boldsymbol{\sigma}\|_1$ を採用する. また, MLP のオプティマイザーには Adam を用い, 学習率は 0.001, エポック数は 100 とした. 以上の条件のもとで, $\lambda \in \{0, 0.01\}$ と $\alpha \in \{0, 1\}$ の組み合わせに対して, テストデータに対する正答率と, 微分可能な LOP- ℓ_2/ℓ_1 を適用した第 2 層の重み行列の値のヒートマップとヒストグラムを図 7.11 と図 7.12 にそれぞれ示す. 結果として, λ の増加に伴い, 重み行列がスパースになり, 更に α の増加に伴い, 重み行列がブロックスパースになることがわかる. 図 7.11 (a) と (b), (c) と (d) を比較すると, λ の増加に伴い, 重み行列がよりスパースになることがわかる. また, 図 7.12 (a) と (c), (b) と (d) を比較すると, α の増加に伴い, テスト正答率をほぼ犠牲にすることなく, 重み行列がよりブロックスパースになることがわかる.




図 7.12: 微分可能な $\text{LOP-}\ell_2/\ell_1$ を適用した第 2 層の重み行列の絶対値のヒートマップ. 重み行列が非ゼロなブロック成分を持つ主要な箇所を赤い四角で囲んでいる.

7.5 最適解収束条件の検証

提案した $\text{LOP-}\ell_2/\ell_1\text{ALT}$ の最適解収束条件 (3.6) が, 線形拡張ラグランジュ法の最適解収束条件 $\|\mathbf{H}\|_{\text{op}} \leq 1$ を十分に満たすことを示す. まず, 行列 $\mathbf{H}$ には, $\mathbf{D}$ の最大特異値による影響を排除するため, 代わりに $\text{LOP-}\ell_2/\ell_1\text{ALT}$ における行列 $\mathbf{H}$ (3.4) の 2×4 の部分ブロック行列

$$\tilde{\mathbf{H}} = \begin{bmatrix} \mu_1 \mathbf{L} & \mathbf{O} & -\mu_1 \mathbf{I} & \mathbf{O} \\ \mu_2 \mathbf{R} & \mathbf{O} & \mathbf{O} & -\mu_2 \mathbf{I} \end{bmatrix},$$



(a) $J = 50, K = 50, N = 100$ (b) $J = 150, K = 150, N = 100$

図 7.13: 最適解収束条件を満たす頻度を示すヒストグラム．横軸の値が負であれば，線形拡張ラグランジュ法の最適解収束条件 $\|\mathbf{H}\|_{\text{op}} \leq 1$ を満たしている．

を用いる．また， $\mathbf{L} \in [0, 1]^{J \times N}$ と $\mathbf{R} \in [0, 1]^{K \times N}$ は各成分が独立に一様分布に従うランダム行列とする．この設定のもとで， $\|\tilde{\mathbf{H}}\|_{\text{op}} - 1$ の計算を 1000 回繰り返した．図 7.13 に， $J = 50, K = 50, N = 100$ (左) と $J = 150, K = 150, N = 100$ (右) のそれぞれの場合における値の頻度を示す．縦軸の値を見ると，横軸の値が 0 に近づく頻度が高く，提案する収束条件が $\|\mathbf{H}\|_{\text{op}} \leq 1$ を十分に満たすことがわかる．

第 8 章

まとめ

本研究は、適応的ブロックスパース正則化の 1 つである $\text{LOP-}l_2/l_1$ [40] の性能向上と応用範囲の拡大、加えて、ブロックスパース正則化の 1 つである逆重み付き l_1 ノルム (ROWL, [31]) の性能向上を目指し、いくつかの新しい手法を提案した。まず、任意の線形変換で得られる特徴量の適応的ブロックスパース性を正則化に用いる手法 $\text{LOP-}l_2/l_1\text{ALT}$ を提案し、その最適化アルゴリズムと収束条件を示した。次に、対数関数を用いて $\text{LOP-}l_2/l_1$ の過小評価バイアスを低減し、真のブロック構造における混合 l_2/l_0 正則化により近い性能を達成する方法として $\text{ReLOP-}l_2/l_1$ を提案した。また、逆重み付き l_1 ノルム (ROWL) の推定バイアスを低減する手法として、一般化逆重み付き損失 (GROWL) を提案した。 $\text{LOP-}l_2/l_1\text{ALT}$ と $\text{ReLOP-}l_2/l_1$, GROWL の有効性は、画像のノイズ除去性能を既存手法と比較することで示された。特に、 $\text{LOP-}l_2/l_1\text{ALT}$ に関しては、ブロック構造推定の様子や復元結果への影響、収束性を詳細に調査した。加えて、 $\text{LOP-}l_2/l_1$ を深層学習へ応用するための、微分可能な $\text{LOP-}l_2/l_1$ の手法を提案した。そして、この手法を導出する過程で得られる $\text{LOP-}l_2/l_1$ の別表現は ADMM との親和性が高く、複数の正則化項を組み合わせる際に、従来よりも高速な最適化計算が可能であることを示した。最後に、 $\text{LOP-}l_2/l_1$ をテンソル分解へ応用するためのアプローチを提案した。まず、テンソルが持つ多層ブロックスパース性を CP 分解の正則化に用いる手法 ABMLSCP を提案し、その有効性をテンソル補完タスクにおいて示した。次に、外れ値テンソルのブロック構造推定を利用したテンソルロバスト主成分分析 (ABTRPCA) を提案した。

今後は、提案した手法の実用性を高めるための広範な実験を行いたい。例えば、ABTRPCA によるノイズ除去の精度が、行った実験においては不十分であったため、より発展的な手法 [15, 41] と組み合わせるなどして精度向上を図りたい。また、微分可能な $\text{LOP-}l_2/l_1$ を ResNet [162] などの大規模学習モデルにおける深層学習タスク（構造的なモデル圧縮や敵対的攻撃）に応用し、その有効性を検証したい。

謝辞

本研究は、横田達也准教授のもとで名古屋工業大学博士前期課程の2年間行われた研究成果をまとめたものです。本修士論文の完成にあたり、これまでご指導、ご支援いただいた多くの方々に心より感謝申し上げます。

まず、本研究の主旨導教員である横田達也准教授には、研究の着想段階から論文の執筆に至るまで、多岐にわたるご指導を賜りました。研究テーマの選定においては、私の漠然とした興味関心の中から、学術的な意義と実現可能性を兼ね備えた研究課題を見出していただきました。その過程では、私の拙いアイデアに対しても常に真摯に向き合ってください、多くの議論を重ねることで、研究の方向性を明確にすることができました。特に、提案手法の定式化においては、数理的側面だけでなく、その背景にある概念や応用可能性まで、多角的な視点からご指導いただきました。更に、本論文の草稿に対しては、構成、論理展開、表現の仕方など、細部にわたるまで丁寧な添削をしていただき、論文の質は大きく向上しました。先生のご指導と、常に学生を励まし、成長を促す温かいお人柄に、心から感謝申し上げます。

加えて、名古屋工業大学 - 本谷・横田研究室の先生方、先輩、同輩、後輩の皆様には、日頃から研究や勉強において多くの示唆や助言をいただきました。特に、横田研究室の先輩 OB である高山拓夢さん、本谷研究室の先輩である古賀諒一さんにはお世話になりました。高山さんには、勉強会（学習理論など）を通じて、機械学習に関する数理的概念の理解について多くの示唆をいただきました。更に高山さんは、私が横田研究室およびに博士後期課程を志す大きなきっかけとなった方であり、私の研究生活において多大な影響を与えてくださったことに感謝いたします。また、古賀さんには、研究計画書の作成や計算機セットアップなどの面で多大なる助力をいただきました。古賀さんの的確なアドバイスや、研究室学生を取りまとめるリーダーシップに、私の研究生活は大いに支えられました。

更に、修士2年の海外研究インターンシップでお世話になった、オーストラリア - ウーロンゴン大学のホスト指導教員である Dr. Hui Luo、名古屋工業大学 - 加藤研究室の同期である伊藤有生くんに感謝いたします。研究室の枠を超えた交流を通じて、異分野の研究に対する新たな視点を得ることができました。

最後に、私をこれまで温かく支えてくださった家族に心から感謝いたします。

付録 A

最適化アルゴリズム

A.1 近接写像の定義

$(U, \|\cdot\|)$ を有限次元のヒルベルト空間とする．有効領域 $\text{dom}(f) := \{\mathbf{u} \in U \mid f(\mathbf{u}) < \infty\}$ が空でないとき，関数 $f: U \rightarrow \mathbb{R} \cup \{\infty\}$ は真であるという．任意の $a \in \mathbb{R}$ に対して，その下位集合 $\{\mathbf{u} \in U \mid f(\mathbf{u}) \leq a\}$ が閉じているとき，関数 $f: U \rightarrow \mathbb{R} \cup \{\infty\}$ は下半連続であるという．任意の $\mathbf{u}, \mathbf{v} \in U$ と $\beta \in (0, 1)$ に対して， $f(\beta\mathbf{u} + (1-\beta)\mathbf{v}) \leq \beta f(\mathbf{u}) + (1-\beta)f(\mathbf{v})$ が成り立つならば，関数 $f: U \rightarrow \mathbb{R} \cup \{\infty\}$ は凸であるという．定義域が U ，値域が $\mathbb{R} \cup \{\infty\}$ である，全ての真下半連続凸関数から成る集合を $\Gamma_0(U)$ と表す． $f \in \Gamma_0(U)$ の近接写像を

$$\text{prox}_f(\mathbf{u}) := \arg \min_{\mathbf{v} \in U} \left[f(\mathbf{v}) + \frac{1}{2} \|\mathbf{u} - \mathbf{v}\|_2^2 \right]$$

と定義する．

A.2 近接写像の単調減少性

定理 A.1 (近接写像が λ に関して単調減少する関数の十分条件)．任意の $x \geq 0$ において関数 $f(x)$ が 2 階微分可能であり，単調増加かつ $f''(x) \geq -\lambda^{-1}$ であると仮定する．このとき，近接写像 $\text{prox}_{\lambda f}(x)$ は λ に関して単調減少である． $\square$

Proof. 関数 $\lambda f(x)$ に対する近接写像 $\text{prox}_{\lambda f}(x)$ は，次の最適化問題の解として定義される．

$$\text{prox}_{\lambda f}(x) = \arg \min_{y \in \mathbb{R}} \left(\lambda f(y) + \frac{1}{2} \|y - x\|^2 \right).$$

この最小化問題の最適性条件として，次の式が得られる．

$$0 = \lambda f'(y^*) + (y^* - x).$$

ここで, $y^* = \text{prox}_{\lambda f}(x)$ である. この式を整理すると,

$$\text{prox}_{\lambda f}(x) = x - \lambda f'(\text{prox}_{\lambda f}(x)).$$

次に, $\text{prox}_{\lambda f}(x)$ を λ で微分する. ここで, 両辺を λ で微分する. まず, λ に関して近接写像を微分すると,

$$\frac{d}{d\lambda} \text{prox}_{\lambda f}(x) = -f'(\text{prox}_{\lambda f}(x)) - \lambda f''(\text{prox}_{\lambda f}(x)) \cdot \frac{d}{d\lambda} \text{prox}_{\lambda f}(x).$$

この式を整理すると, 以下のようになる.

$$\frac{d}{d\lambda} \text{prox}_{\lambda f}(x) = -\frac{f'(\text{prox}_{\lambda f}(x))}{1 + \lambda f''(\text{prox}_{\lambda f}(x))} = -\frac{f'(y^*)}{1 + \lambda f''(y^*)}.$$

ここで, $f(x)$ は単調増加であるため, $f'(x) \geq 0$ である. また, $f(x)$ が凸であれば $f''(x) \geq 0$ である. したがって, 右辺の $-f'(x)$ が非正であることから,

$$\frac{d}{d\lambda} \text{prox}_{\lambda f}(x) \leq 0.$$

すなわち, λ に関して $\text{prox}_{\lambda f}(x)$ は単調減少する.

□

A.3 線形拡張ラグランジュ法

$\mathbf{H} \in \mathbb{R}^{J \times N}, G \in \Gamma_0(\mathbb{R}^N)$ とするとき,

$$\min_{\mathbf{w} \in \mathbb{R}^N} G(\mathbf{w}) \text{ s.t. } \mathbf{H}\mathbf{w} = \mathbf{0} \quad (\text{A.1})$$

で与えられる問題を最適化する方法として, 線形拡張ラグランジュ法 (アルゴリズム 6) が提案されている [163, 164]. アルゴリズム 6 は緩い条件のもとで必ず最適解へ収束する [165, Theorem 5.3].

定理 A.2 (線形拡張ラグランジュ法の最適解収束条件). 任意の $\gamma > 0$ に対して $\|\mathbf{H}\|_{\text{op}} \leq 1$ を仮定する. このとき, 線形拡張ラグランジュ法 (アルゴリズム 6) は (A.1) の最適解へ収束する.

□

アルゴリズム 6 線形拡張ラグランジュ法

Input: $\gamma > 0, \mathbf{w}^0 \in \mathbb{R}^N, \mathbf{r}^0 \in \mathbb{R}^J$
Output: $\mathbf{w} \in \mathbb{R}^N$

```

for  $i = 0, 1, 2, \dots$  do
     $\tilde{\mathbf{w}}^{i+1} = \mathbf{w}^i + \mathbf{H}^*(\mathbf{r}^i - \mathbf{H}\mathbf{w}^i)$ 
     $\mathbf{w}^{i+1} = \text{prox}_{\gamma G}(\tilde{\mathbf{w}}^{i+1})$ 
     $\mathbf{r}^{i+1} = \mathbf{r}^i - \mathbf{H}\mathbf{w}^{i+1}$ 
  
```

A.4 交互方向乗数法

交互方向乗数法 (Alternating Direction Method of Multipliers, ADMM) は、正則化付き最適化問題を解くための反復アルゴリズムである。(1.2) の最適化問題は、以下の最適化問題

$$\min_{\mathbf{y}, \mathbf{z}} f(\mathbf{y}) + h(\mathbf{z}) \text{ s.t. } \mathbf{y} = \mathbf{L}\mathbf{x}, \mathbf{z} = \mathbf{R}\mathbf{x} \quad (\text{A.2})$$

に変換できる。この最適化問題に対応する拡張ラグランジュ関数

$$\begin{aligned} \mathcal{L}(\mathbf{x}, \mathbf{y}, \mathbf{z}, \mathbf{p}, \mathbf{m}) = & f(\mathbf{y}) + h(\mathbf{z}) + \langle \mathbf{p}, \mathbf{y} - \mathbf{L}\mathbf{x} \rangle + \frac{\mu_y}{2} \|\mathbf{y} - \mathbf{L}\mathbf{x}\|_2^2 \\ & + \langle \mathbf{m}, \mathbf{z} - \mathbf{R}\mathbf{x} \rangle + \frac{\mu_z}{2} \|\mathbf{z} - \mathbf{R}\mathbf{x}\|_2^2 \end{aligned}$$

を各変数について交互に最小化、すなわち

$$\begin{aligned} \mathbf{x}^{(k+1)} &= \arg \min_{\mathbf{x}} \mathcal{L}_\rho(\mathbf{x}, \mathbf{y}^{(k)}, \mathbf{z}^{(k)}, \mathbf{p}^{(k)}, \mathbf{m}^{(k)}) \\ \mathbf{y}^{(k+1)} &= \arg \min_{\mathbf{y}} \mathcal{L}_\rho(\mathbf{x}^{(k+1)}, \mathbf{y}, \mathbf{z}^{(k)}, \mathbf{p}^{(k)}, \mathbf{m}^{(k)}) \\ \mathbf{z}^{(k+1)} &= \arg \min_{\mathbf{z}} \mathcal{L}_\rho(\mathbf{x}^{(k+1)}, \mathbf{y}^{(k+1)}, \mathbf{z}, \mathbf{p}^{(k)}, \mathbf{m}^{(k)}) \\ \mathbf{p}^{(k+1)} &= \mathbf{p}^{(k)} + \mu_y(\mathbf{y}^{(k+1)} - \mathbf{L}\mathbf{x}^{(k+1)}) \\ \mathbf{m}^{(k+1)} &= \mathbf{m}^{(k)} + \mu_z(\mathbf{z}^{(k+1)} - \mathbf{R}\mathbf{x}^{(k+1)}) \end{aligned}$$

と更新することで、(A.2) の最適解を求める方法を ADMM という。 f や h がよい性質を持つ場合、 $\mathbf{t}$ と $\mathbf{z}$ についての最適化問題は解析的に解け、ADMM の収束は保証される [93, 166].

参考文献

- [1] Fei Wen, Lei Chu, Peilin Liu, and Robert C. Qiu. “A Survey on Nonconvex Regularization-Based Sparse and Low-Rank Recovery in Signal Processing, Statistics, and Machine Learning”, *IEEE Access* 6 (2018), pp. 69883–69906.
- [2] Zhanxuan Hu, Feiping Nie, Rong Wang, and Xuelong Li. “Low Rank Regularization: A Review”, *Neural Networks* 136 (Apr. 1, 2021), pp. 218–232.
- [3] Yingjie Tian and Yuqi Zhang. “A Comprehensive Survey on Regularization Strategies in Machine Learning”, *Information Fusion* 80 (Apr. 1, 2022), pp. 146–166.
- [4] Mittapalle Kiran Reddy and Paavo Alku. “Exemplar-Based Sparse Representations for Detection of Parkinson’s Disease From Speech”, *IEEE/ACM Transactions on Audio, Speech, and Language Processing* 31 (2023), pp. 1386–1396.
- [5] Jasin Machkour, Arnaud Breloy, Michael Muma, Daniel P. Palomar, and Frédéric Pascal. “Sparse PCA with False Discovery Rate Controlled Variable Selection”, In *Proceedings of International Conference on Acoustics, Speech and Signal Processing*. Apr. 2024, pp. 9716–9720.
- [6] Makoto Yamada, Takeuchi Koh, Tomoharu Iwata, John Shawe-Taylor, and Samuel Kaski. “Localized Lasso for High-Dimensional Regression”, In *Proceedings of International Conference on Artificial Intelligence and Statistics*. PMLR, Apr. 10, 2017, pp. 325–333.
- [7] Huaqing Zhang, Jian Wang, Zhanquan Sun, Jacek M. Zurada, and Nikhil R. Pal. “Feature Selection for Neural Networks Using Group Lasso Regularization”, *IEEE Transactions on Knowledge and Data Engineering* 32.4 (Apr. 1, 2020), pp. 659–673.
- [8] Ismael Lemhadri, Feng Ruan, Louis Abraham, and Robert Tibshirani. “LassoNet: A Neural Network with Feature Sparsity”, *Journal of Machine Learning Research* 22.127 (2021), pp. 1–29.
- [9] James Enouen and Yan Liu. “Sparse Interaction Additive Networks via Feature Interaction Detection and Sparse Selection”, In *Proceedings of International Conference on Advances in Neural Information Processing Systems*. May 16, 2022.
- [10] Ghada Sokar, Zahra Atashgahi, Mykola Pechenizkiy, and Decebal Constantin Mocanu. “Where to Pay Attention in Sparse Training for Feature Selection?”, In *Proceedings of International Conference on Advances in Neural Information Processing Systems*. May 16, 2022.
- [11] Gholamreza Hesamian, Arne Johannssen, and Nataliya Chukhrova. “An Explainable Fused Lasso Regression Model for Handling High-Dimensional Fuzzy Data”, *Journal of Computational and Applied Mathematics* 441 (May 15, 2024), p. 115721.
- [12] Kostadin Dabov, Alessandro Foi, Vladimir Katkovnik, and Karen Egiazarian. “Image Denoising by Sparse 3-D Transform-Domain Collaborative Filtering”, *IEEE Transactions on Image Processing* 16.8 (Aug. 2007), pp. 2080–2095.
- [13] Julien Mairal, Francis Bach, Jean Ponce, Guillermo Sapiro, and Andrew Zisserman. “Non-Local Sparse Models for Image Restoration”, In *Proceedings of International Conference on Computer Vision*. IEEE, Sept. 2009, pp. 2272–2279.

- [14] Jun Liu, Ting-Zhu Huang, Ivan W. Selesnick, Xiao-Guang Lv, and Po-Yu Chen. “Image Restoration Using Total Variation with Overlapping Group Sparsity”, *Information Sciences* 295 (Feb. 20, 2015), pp. 232–246.
- [15] Xin Liu, Guoying Zhao, Jiawen Yao, and Chun Qi. “Background Subtraction Based on Low-Rank and Structured Sparse Decomposition”, *IEEE Transactions on Image Processing* 24.8 (Aug. 2015), pp. 2502–2514.
- [16] Renwei Dian, Leyuan Fang, and Shutao Li. “Hyperspectral Image Super-Resolution via Non-local Sparse Tensor Factorization”, In *Proceedings of International Conference on Computer Vision and Pattern Recognition*. IEEE, July 2017, pp. 3862–3871.
- [17] Sajid Javed, Arif Mahmood, Somaya Al-Maadeed, Thierry Bouwmans, and Soon Ki Jung. “Moving Object Detection in Complex Scene Using Spatiotemporal Structured-Sparse RPCA”, *IEEE Transactions on Image Processing* 28.2 (Feb. 2019), pp. 1007–1022.
- [18] Alessandro Lanza, Serena Morigi, Ivan W. Selesnick, and Fiorella Sgallari. “Sparsity-Inducing Nonconvex Nonseparable Regularization for Convex Image Processing”, *SIAM Journal on Imaging Sciences* 12.2 (Jan. 2019), pp. 1099–1134.
- [19] Yong Chen, Wei He, Naoto Yokoya, and Ting-Zhu Huang. “Hyperspectral Image Restoration Using Weighted Group Sparsity-Regularized Low-Rank Tensor Decomposition”, *IEEE Transactions on Cybernetics* 50.8 (Aug. 2020), pp. 3556–3570.
- [20] Zhiyuan Zha, Xin Yuan, Bihan Wen, Jiantao Zhou, and Ce Zhu. “Group Sparsity Residual Constraint With Non-Local Priors for Image Restoration”, *IEEE Transactions on Image Processing* 29 (2020), pp. 8960–8975.
- [21] Yiqun Mei, Yuchen Fan, and Yuqian Zhou. “Image Super-Resolution with Non-Local Sparse Attention”, In *Proceedings of International Conference on Computer Vision and Pattern Recognition*. June 2021, pp. 3516–3525.
- [22] Zhiyuan Zha, Xin Yuan, Bihan Wen, Jiachao Zhang, and Ce Zhu. “Nonconvex Structural Sparsity Residual Constraint for Image Restoration”, *IEEE Transactions on Cybernetics* 52.11 (Nov. 2022), pp. 12440–12453.
- [23] Mansu Kim, Eun Jeong Min, Kefei Liu, Jingwen Yan, Andrew J. Saykin, Jason H. Moore, Qi Long, and Li Shen. “Multi-Task Learning Based Structured Sparse Canonical Correlation Analysis for Brain Imaging Genetics”, *Medical Image Analysis* 76 (Feb. 1, 2022), p. 102297.
- [24] Yong Chen, Ting-Zhu Huang, Wei He, Xi-Le Zhao, Hongyan Zhang, and Jinshan Zeng. “Hyperspectral Image Denoising Using Factor Group Sparsity-Regularized Nonconvex Low-Rank Approximation”, *IEEE Transactions on Geoscience and Remote Sensing* 60 (2022), pp. 1–16.
- [25] Jize Xue, Yongqiang Zhao, Shaoguang Huang, Wenzhi Liao, Jonathan Cheung-Wai Chan, and Seong G. Kong. “Multilayer Sparsity-Based Tensor Decomposition for Low-Rank Tensor Completion”, *IEEE Transactions on Neural Networks and Learning Systems* 33.11 (Nov. 2022), pp. 6916–6930.
- [26] Assia El Mahdaoui, Abdeldjalil Ouahabi, and Mohamed Said Moulay. “Image Denoising Using a Compressive Sensing Approach Based on Regularization Constraints”, *Sensors* 22.6 (Mar. 11, 2022), p. 2199.
- [27] Zhiyuan Zha, Bihan Wen, Xin Yuan, Saiprasad Ravishankar, Jiantao Zhou, and Ce Zhu. “Learning Nonlocal Sparse and Low-Rank Models for Image Compressive Sensing: Nonlocal Sparse and Low-Rank Modeling”, *IEEE Signal Processing Magazine* 40.1 (Jan. 2023), pp. 32–44.
- [28] Xin Deng, Enpeng Liu, Shengxi Li, Yiping Duan, and Mai Xu. “Interpretable Multi-Modal Image Registration Network Based on Disentangled Convolutional Sparse Coding”, *IEEE Transactions on Image Processing* 32 (2023), pp. 1078–1091.
- [29] Zhiyuan Zha, Bihan Wen, Xin Yuan, Jiachao Zhang, Jiantao Zhou, Yilong Lu, and Ce Zhu. “Nonlocal Structured Sparsity Regularization Modeling for Hyperspectral Image Denoising”, *IEEE Transactions on Geoscience and Remote Sensing* 61 (2023), pp. 1–16.

- [30] Zhiyuan Zha, Bihan Wen, Xin Yuan, Jiantao Zhou, Ce Zhu, and Alex Chichung Kot. “Low-Rankness Guided Group Sparse Representation for Image Restoration”, *IEEE Transactions on Neural Networks and Learning Systems* 34.10 (Oct. 2023), pp. 7593–7607.
- [31] Takayuki Sasaki, Yukihiro Bandoh, and Masaki Kitahara. “Sparse Regularization Based on Reverse Ordered Weighted L1-Norm and Its Application to Edge-Preserving Smoothing”, In *Proceedings of International Conference on Acoustics, Speech and Signal Processing*. Apr. 2024, pp. 9531–9535.
- [32] Steven L. Brunton and J. Nathan Kutz. *Data-Driven Science and Engineering: Machine Learning, Dynamical Systems, and Control*. Cambridge University Press, 2019. 472 pp.
- [33] Emmanuel J. Candès, Justin K. Romberg, and Terence Tao. “Stable Signal Recovery from Incomplete and Inaccurate Measurements”, *Communications on Pure and Applied Mathematics* 59.8 (2006), pp. 1207–1223.
- [34] D.L. Donoho. “Compressed Sensing”, *IEEE Transactions on Information Theory* 52.4 (Apr. 2006), pp. 1289–1306.
- [35] Yonina C. Eldar, Patrick Kuppinger, and Helmut Bölcskei. *Compressed Sensing of Block-Sparse Signals: Uncertainty Relations and Efficient Recovery*. June 18, 2009. arXiv: 0906.3173 [cs, math]. Pre-published.
- [36] Richard G. Baraniuk, Volkan Cevher, Marco F. Duarte, and Chinmay Hegde. “Model-Based Compressive Sensing”, *IEEE Transactions on Information Theory* 56.4 (Apr. 2010), pp. 1982–2001.
- [37] Weiyu Xu, Enrique Mallada, and Ao Tang. “Compressive Sensing over Graphs”, In *Proceedings of International Conference on IEEE INFOCOM*. Apr. 2011, pp. 2087–2095.
- [38] Joseph Woodworth and Rick Chartrand. “Compressed Sensing Recovery via Nonconvex Shrinkage Penalties”, *Inverse Problems* 32.7 (July 1, 2016), p. 075004.
- [39] Claire Boyer, Jérémie Bigot, and Pierre Weiss. “Compressed Sensing with Structured Sparsity and Structured Acquisition”, *Applied and Computational Harmonic Analysis* 46.2 (Mar. 1, 2019), pp. 312–350.
- [40] Hiroki Kuroda and Daichi Kitahara. “Block-Sparse Recovery with Optimal Block Partition”, *IEEE Transactions on Signal Processing* 70 (2022), pp. 1506–1520.
- [41] Xin Liu, Jiawen Yao, Xiaopeng Hong, Xiaohua Huang, Ziheng Zhou, Chun Qi, and Guoying Zhao. “Background Subtraction Using Spatio-Temporal Group Sparsity Recovery”, *IEEE Transactions on Circuits and Systems for Video Technology* 28.8 (Aug. 2018), pp. 1737–1751.
- [42] B. K. Natarajan. “Sparse Approximate Solutions to Linear Systems”, *SIAM Journal on Computing* 24.2 (Apr. 1995), pp. 227–234.
- [43] Scott Shaobing Chen, David L. Donoho, and Michael A. Saunders. “Atomic Decomposition by Basis Pursuit”, *SIAM Journal on Scientific Computing* 20.1 (Jan. 1998), pp. 33–61.
- [44] Robert Tibshirani. “Regression Shrinkage and Selection via the Lasso”, *Journal of the Royal Statistical Society. Series B (Methodological)* 58.1 (1996), pp. 267–288. JSTOR: 2346178.
- [45] Leonid I. Rudin, Stanley Osher, and Emad Fatemi. “Nonlinear Total Variation Based Noise Removal Algorithms”, *Physica D: Nonlinear Phenomena* 60.1 (Nov. 1, 1992), pp. 259–268.
- [46] Ivan W. Selesnick and Po-Yu Chen. “Total Variation Denoising with Overlapping Group Sparsity”, In *Proceedings of International Conference on Acoustics, Speech and Signal Processing*. IEEE, May 2013, pp. 5696–5700.
- [47] Tatsuya Yokota and Hidekata Hontani. “Simultaneous Visual Data Completion and Denoising Based on Tensor Rank and Total Variation Minimization and Its Primal-Dual Splitting Algorithm”, In *Proceedings of International Conference on Computer Vision and Pattern Recognition*. IEEE, July 2017, pp. 3843–3851.
- [48] Tatsuya Yokota and Hidekata Hontani. “An Efficient Method for Adapting Step-Size Parameters of Primal-Dual Hybrid Gradient Method in Application to Total Variation Regularization”, In *Proceedings of Asia-Pacific Signal and Information Processing Association Annual Summit and Conference*. IEEE, Dec. 2017, pp. 973–979.

- [49] Aditya Sant, Markus Leinonen, and Bhaskar D. Rao. “Block-Sparse Signal Recovery via General Total Variation Regularized Sparse Bayesian Learning”, *IEEE Transactions on Signal Processing* 70 (2022), pp. 1056–1071.
- [50] Aditya Sant, Markus Leinonen, and Bhaskar D. Rao. “General Total Variation Regularized Sparse Bayesian Learning for Robust Block-Sparse Signal Recovery”, In *Proceedings of International Conference on Acoustics, Speech and Signal Processing*. June 2021, pp. 5604–5608.
- [51] Wei He, Hongyan Zhang, Liangpei Zhang, and Huanfeng Shen. “Total-Variation-Regularized Low-Rank Matrix Factorization for Hyperspectral Image Restoration”, *IEEE Transactions on Geoscience and Remote Sensing* 54.1 (Jan. 2016), pp. 178–188.
- [52] Akifumi Okuno. *A Stochastic Optimization Approach to Train Non-Linear Neural Networks with Regularization of Higher-Order Total Variation*. Aug. 4, 2023. arXiv: 2308.02293 [cs, stat]. Pre-published.
- [53] Raymond A. Yeh, Yuan-Ting Hu, Zhongzheng Ren, and Alexander G. Schwing. “Total Variation Optimization Layers for Computer Vision”, In *Proceedings of International Conference on Computer Vision and Pattern Recognition*. June 2022, pp. 701–711.
- [54] Stamatis Lefkimmiatis, Anastasios Roussos, Petros Maragos, and Michael Unser. “Structure Tensor Total Variation”, *SIAM Journal on Imaging Sciences* 8.2 (Jan. 2015), pp. 1090–1122.
- [55] Ivan Selesnick, Alessandro Lanza, Serena Morigi, and Fiorella Sgallari. “Non-Convex Total Variation Regularization for Convex Denoising of Signals”, *Journal of Mathematical Imaging and Vision* 62.6–7 (July 2020), pp. 825–841.
- [56] Ivan W. Selesnick, Ankit Parekh, and Ilker Bayram. “Convex 1-D Total Variation Denoising with Non-convex Regularization”, *IEEE Signal Processing Letters* 22.2 (Feb. 2015), pp. 141–144.
- [57] Manasavee Lohvithee, Ander Biguri, and Manuchehr Soleimani. “Parameter Selection in Limited Data Cone-Beam CT Reconstruction Using Edge-Preserving Total Variation Algorithms”, *Physics in Medicine & Biology* 62.24 (Nov. 21, 2017), pp. 9295–9321.
- [58] Kai Deng, Youwei Wen, Kexin Li, and Juan Zhang. “Hybrid Model of Tensor Sparse Representation and Total Variation Regularization for Image Denoising”, *Signal Processing* 217 (Apr. 1, 2024), p. 109352.
- [59] Jonas Hansen and F. Bianchi. “Total Variation Graph Neural Networks”, In *Proceedings of International Conference on Machine Learning*. Nov. 11, 2022.
- [60] Kristian Bredies, Karl Kunisch, and Thomas Pock. “Total Generalized Variation”, *SIAM Journal on Imaging Sciences* 3.3 (Jan. 2010), pp. 492–526.
- [61] Shunsuke Ono, Isao Yamada, and Itsuo Kumazawa. “Total Generalized Variation for Graph Signals”, In *Proceedings of International Conference on Acoustics, Speech and Signal Processing*. Apr. 2015, pp. 5456–5460.
- [62] Ganzhao Yuan and Bernard Ghanem. “l0TV: A New Method for Image Restoration in the Presence of Impulse Noise”, In *Proceedings of International Conference on Computer Vision and Pattern Recognition*. IEEE, June 2015, pp. 5369–5377.
- [63] Hui Zou and Trevor Hastie. “Regularization and Variable Selection Via the Elastic Net”, *Journal of the Royal Statistical Society Series B: Statistical Methodology* 67.2 (Apr. 1, 2005), pp. 301–320.
- [64] Tatsuya Yokota, Burak Erem, Seyhmus Guler, Simon K. Warfield, and Hidekata Hontani. “Missing Slice Recovery for Tensors Using a Low-Rank Model in Embedded Space”, In *Proceedings of International Conference on Computer Vision and Pattern Recognition*. IEEE, June 2018, pp. 8251–8259.
- [65] Tai-Xiang Jiang, Michael K. Ng, Xi-Le Zhao, and Ting-Zhu Huang. “Framelet Representation of Tensor Nuclear Norm for Third-Order Tensor Completion”, *IEEE Transactions on Image Processing* 29 (2020), pp. 7233–7244. arXiv: 1909.06982 [cs, eess].

- [66] Jian-Li Wang, Ting-Zhu Huang, Xi-Le Zhao, Tai-Xiang Jiang, and Michael K. Ng. “Multi-Dimensional Visual Data Completion via Low-Rank Tensor Representation Under Coupled Transform”, *IEEE Transactions on Image Processing* 30 (2021), pp. 3581–3596.
- [67] Chao Li, Wei He, Longhao Yuan, Zhun Sun, and Qibin Zhao. “Guaranteed Matrix Completion Under Multiple Linear Transformations”, In *Proceedings of International Conference on Computer Vision and Pattern Recognition*. IEEE, June 2019, pp. 11128–11137.
- [68] Lanlan Feng, Ce Zhu, Zhen Long, Jiani Liu, and Yipeng Liu. “Multiplex Transformed Tensor Decomposition for Multidimensional Image Recovery”, *IEEE Transactions on Image Processing* 32 (2023), pp. 3397–3412.
- [69] Emmanuel J. Candès, Michael B. Wakin, and Stephen P. Boyd. “Enhancing Sparsity by Reweighted L1 Minimization”, *Journal of Fourier Analysis and Applications* 14.5 (Dec. 1, 2008), pp. 877–905.
- [70] Marina Danilova, Pavel Dvurechensky, Alexander Gasnikov, Eduard Gorbunov, Sergey Guminov, Dmitry Kamzolov, and Innokentiy Shibaev. *Recent Theoretical Advances in Non-Convex Optimization*. Nov. 26, 2021. arXiv: 2012.06188 [cs, math]. Pre-published.
- [71] Jose Henrique De Moraes Goulart, Pedro Marinho Ramos De Oliveira, Rodrigo Cabral Farias, Vicente Zarzoso, and Pierre Comon. “Alternating Group Lasso for Block-Term Tensor Decomposition and Application to ECG Source Separation”, *IEEE Transactions on Signal Processing* 68 (2020), pp. 2682–2696.
- [72] Athanasios A. Rontogiannis, Eleftherios Kofidis, and Paris V. Giampouras. “Block-Term Tensor Decomposition: Model Selection and Computation”, *IEEE Journal of Selected Topics in Signal Processing* 15.3 (Apr. 2021), pp. 464–475.
- [73] Lieven De Lathauwer. “Decompositions of a Higher-Order Tensor in Block Terms—Part II: Definitions and Uniqueness”, *SIAM Journal on Matrix Analysis and Applications* 30.3 (Jan. 2008), pp. 1033–1066.
- [74] Michael Götte, Reinhold Schneider, and Philipp Trunschke. *A Block-Sparse Tensor Train Format for Sample-Efficient High-Dimensional Polynomial Regression*. Apr. 29, 2021. arXiv: 2104.14255 [cs, math]. Pre-published.
- [75] Nu Wen, Renzhong Guo, Biao He, Yong Fan, and Ding Ma. “Block-Sparse CNN: Towards a Fast and Memory-Efficient Framework for Convolutional Neural Networks”, *Applied Intelligence* 51.1 (Jan. 2021), pp. 441–452.
- [76] Sharan Narang, Eric Undersander, and Gregory Diamos. *Block-Sparse Recurrent Neural Networks*. Nov. 8, 2017. arXiv: 1711.02782 [cs]. Pre-published.
- [77] Liyang Lu, Zhaocheng Wang, Zhen Gao, Sheng Chen, and H. Vincent Poor. “Block-Sparse Tensor Recovery”, *IEEE Transactions on Information Theory* 70.12 (Dec. 1, 2024), pp. 9293–9326.
- [78] Yonina C. Eldar, Patrick Kuppinger, and Helmut Bolcskei. “Block-Sparse Signals: Uncertainty Relations and Efficient Recovery”, *IEEE Transactions on Signal Processing* 58.6 (2010), pp. 3042–3054.
- [79] Junzhou Huang, Tong Zhang, and Dimitris Metaxas. “Learning with Structured Sparsity”, In *Proceedings of the 26th Annual International Conference on Machine Learning*. June 14, 2009, pp. 417–424.
- [80] Jun Fang, Yanning Shen, Hongbin Li, and Pu Wang. “Pattern-Coupled Sparse Bayesian Learning for Recovery of Block-Sparse Signals”, *IEEE Transactions on Signal Processing* 63.2 (2015), pp. 360–372.
- [81] Lu Wang, Lifan Zhao, Susanto Rahardja, and Guoan Bi. “Alternative to Extended Block Sparse Bayesian Learning and Its Relation to Pattern-Coupled Sparse Bayesian Learning”, *IEEE Transactions on Signal Processing* 66.10 (May 2018), pp. 2759–2771.
- [82] Yanhao Zhang, Zhihan Zhu, and Yong Xia. *Block Sparse Bayesian Learning: A Diversified Scheme*. Oct. 30, 2024. arXiv: 2402.04646. Pre-published.
- [83] Laurent Jacob, G. Obozinski, and Jean-Philippe Vert. “Group Lasso with Overlap and Graph Lasso”, In *Proceedings of International Conference on Machine Learning*. 2009.

- [84] Guillaume Obozinski, Laurent Jacob, and Jean-Philippe Vert. *Group Lasso with Overlaps: The Latent Group Lasso Approach*. Oct. 3, 2011. arXiv: 1110.0413 [cs, stat]. Pre-published.
- [85] Hiroki Kuroda and Daichi Kitahara. “Graph-Structured Sparse Regularization Via Convex Optimization”, In *Proceedings of International Conference on Acoustics, Speech and Signal Processing*. IEEE, May 23, 2022, pp. 5538–5542.
- [86] Ashley Prater-Bennette, Lixin Shen, and Erin E. Tripp. “The Proximity Operator of the Log-Sum Penalty”, *Journal of Scientific Computing* 93.3 (Oct. 25, 2022), p. 67.
- [87] Yulan Liu, Yuyang Zhou, and Rongrong Lin. “The Proximal Operator of the Piece-Wise Exponential Function”, *IEEE Signal Processing Letters* 31 (2024), pp. 894–898.
- [88] Tong Zhang. “Multi-Stage Convex Relaxation for Learning with Sparse Regularization”, In *Proceedings of International Conference on Advances in Neural Information Processing Systems*. Vol. 21. Curran Associates, Inc., 2008.
- [89] Laurent Condat. “Fast Projection onto the Simplex and the L1 Ball”, *Mathematical Programming* 158.1–2 (July 2016), pp. 575–585.
- [90] Hiroki Kuroda. *A Convex-Nonconvex Framework for Enhancing Minimization Induced Penalties*. July 20, 2024. arXiv: 2407.14819 [eess, math]. Pre-published.
- [91] David Wipf and Srikantan Nagarajan. “Iterative Reweighted L1 and L2 Methods for Finding Sparse Solutions”, *IEEE Journal of Selected Topics in Signal Processing* 4.2 (Apr. 2010), pp. 317–329.
- [92] Hongqing Yu, Ziyi Wang, and Heng Qiao. “On Variational Block Sparse Recovery With Unknown Partition and L0-Norm Constraint”, *IEEE Signal Processing Letters* 31 (2024), pp. 96–100.
- [93] Yu Wang, Wotao Yin, and Jinshan Zeng. “Global Convergence of ADMM in Nonconvex Nonsmooth Optimization”, *Journal of Scientific Computing* 78.1 (Jan. 1, 2019), pp. 29–63.
- [94] Xiangrong Zeng and Mário A. T. Figueiredo. *The Ordered Weighted L1 Norm: Atomic Formulation, Projections, and Algorithms*. Apr. 10, 2015. arXiv: 1409.4271 [cs, math]. Pre-published.
- [95] Godfrey H. Hardy, John Edensor Littlewood, and George Pólya. *Inequalities*. 1. paperback ed., repr., transferred to digital printing. Cambridge Mathematical Library. Cambridge Univ. Press, 2001. 324 pp.
- [96] Christos Louizos, Max Welling, and Diederik P. Kingma. “Learning Sparse Neural Networks through L0 Regularization”, In *Proceedings of International Conference on Learning Representations*. 2018.
- [97] Kai Jia and Martin Rinard. *Effective Neural Network L0 Regularization With BinMask*. Apr. 21, 2023. arXiv: 2304.11237 [cs]. Pre-published.
- [98] Stephen P. Boyd and Lieven Vandenbergh. *Convex Optimization*. Version 29. Cambridge University Press, 2023. 716 pp.
- [99] Chris Kolb, Christian L. Müller, Bernd Bischl, and David Rügamer. *Smoothing the Edges: Smooth Optimization for Sparse Regularization Using Hadamard Overparametrization*. Apr. 26, 2024. arXiv: 2307.03571 [cs, math, stat]. Pre-published.
- [100] Sehoon Kim, Coleman Hooper, Amir Gholami, Zhen Dong, Xiuyu Li, Sheng Shen, Michael W. Mahoney, and Kurt Keutzer. “SqueezeLLM: Dense-and-Sparse Quantization”, In *Proceedings of International Conference on Machine Learning*. Vol. 235. ICML’24. JMLR.org, Jan. 3, 2025, pp. 23901–23923.
- [101] Beidi Chen, Tri Dao, Eric Winsor, Zhao Song, Atri Rudra, and Christopher Ré. “Scatterbrain: Unifying Sparse and Low-Rank Attention”, In *Proceedings of International Conference on Advances in Neural Information Processing Systems*. 2021.
- [102] Kaidi Xu, Sijia Liu, Pu Zhao, Pin-Yu Chen, Huan Zhang, Quanfu Fan, Deniz Erdogmus, Yanzhi Wang, and Xue Lin. “Structured Adversarial Attack: Towards General Implementation and Better Interpretability”, In *Proceedings of International Conference on Learning Representations*. 2019.

- [103] Nicholas Carlini and David Wagner. “Towards Evaluating the Robustness of Neural Networks”, In *Proceedings of IEEE Symposium on Security and Privacy*. IEEE Computer Society, May 1, 2017, pp. 39–57.
- [104] Chuan Guo, Alexandre Sablayrolles, Hervé Jégou, and Douwe Kiela. “Gradient-Based Adversarial Attacks against Text Transformers”, In *Proceedings of International Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, Nov. 2021, pp. 5747–5757.
- [105] Chen Wan, Fangjun Huang, and Xianfeng Zhao. “Average Gradient-Based Adversarial Attack”, *IEEE Transactions on Multimedia* 25 (2023), pp. 9572–9585.
- [106] Yipeng Liu. *Tensors for Data Processing : Theory, Methods and Applications*. Academic Press, 2022.
- [107] N. Sidiropoulos, L. Lathauwer, Xiao Fu, Kejun Huang, E. Papalexakis, and C. Faloutsos. “Tensor Decomposition for Signal Processing and Machine Learning”, *IEEE Transactions on Signal Processing* (2017).
- [108] Jinmian Ye, Guangxi Li, Di Chen, Haiqin Yang, Shandian Zhe, and Zenglin Xu. “Block-Term Tensor Neural Networks”, *Neural Networks* 130 (Oct. 2020), pp. 11–21.
- [109] Yannis Panagakis, Jean Kossaifi, Grigorios G. Chrysos, James Oldfield, Mihalís A. Nicolaou, Anima Anandkumar, and Stefanos Zafeiriou. “Tensor Methods in Computer Vision and Deep Learning”, *Proceedings of the IEEE* 109.5 (May 2021), pp. 863–890.
- [110] Ian Convy, William Huggins, Haoran Liao, and K. Birgitta Whaley. “Mutual Information Scaling for Tensor Network Machine Learning”, *Machine Learning: Science and Technology* 3.1 (Mar. 1, 2022), p. 015017. arXiv: 2103.00105 [quant-ph].
- [111] Anpei Chen, Zexiang Xu, Andreas Geiger, Jingyi Yu, and Hao Su. “TensorRF: Tensorial Radiance Fields”, In *Proceedings of European Conference on Computer Vision*. Mar. 17, 2022.
- [112] Nadav Cohen, Or Sharir, and Amnon Shashua. “On the Expressive Power of Deep Learning: A Tensor Analysis”, In *Proceedings of Machine Learning Research*. arXiv, May 27, 2016. arXiv: 1509.05009 [cs, stat].
- [113] Nadav Cohen and Amnon Shashua. “Convolutional Rectifier Networks as Generalized Tensor Decompositions”, In *Proceedings of International Conference on Machine Learning*. Vol. 48. Proceedings of Machine Learning Research. PMLR, June 20–22, 2016, pp. 955–963.
- [114] Yu-Bang Zheng, Ting-Zhu Huang, Xi-Le Zhao, Tai-Xiang Jiang, Teng-Yu Ji, and Tian-Hui Ma. “Tensor N-tubal Rank and Its Convex Relaxation for Low-Rank Tensor Recovery”, *Information Sciences* 532 (Sept. 1, 2020), pp. 170–189.
- [115] D. Bacciu and D. Mandic. “Tensor Decompositions in Deep Learning”, In. The European Symposium on Artificial Neural Networks. Feb. 26, 2020.
- [116] Jean Kossaifi, Zachary C. Lipton, Arinbjörn Kolbeinsson, Aran Khanna, Tommaso Furlanello, and Anima Anandkumar. “Tensor Regression Networks”, *J. Mach. Learn. Res.* 21.1 (Jan. 1, 2020), 123:4862–123:4882.
- [117] Giuseppe G. Calvi, Ahmad Moniri, Mahmoud Mahfouz, Qibin Zhao, and Danilo P. Mandic. *Compression and Interpretability of Deep Neural Networks via Tucker Tensor Layer: From First Principles to Tensor Valued Back-Propagation*. Jan. 6, 2020. arXiv: 1903.06133 [cs]. Pre-published.
- [118] Andrzej Cichocki, Namgil Lee, Ivan Oseledets, Anh-Huy Phan, Qibin Zhao, Masashi Sugiyama, and Danilo P. Mandic. “Tensor Networks for Dimensionality Reduction and Large-scale Optimization: Part 2 Applications and Future Perspectives”, *Foundations and Trends® in Machine Learning* 9.6 (2017), pp. 249–429.
- [119] Arinbjörn Kolbeinsson, Jean Kossaifi, Yannis Panagakis, Adrian Bulat, Animashree Anandkumar, Ioanna Tzoulaki, and Paul M. Matthews. “Tensor Dropout for Robust Learning”, *IEEE Journal of Selected Topics in Signal Processing* 15.3 (Apr. 2021), pp. 630–640.
- [120] Jean Kossaifi, Adrian Bulat, Georgios Tzimiropoulos, and Maja Pantic. “T-Net: Parametrizing Fully Convolutional Nets With a Single High-Order Tensor”, *Proceedings of Interna-*

- tional Conference on Computer Vision and Pattern Recognition (June 2019), pp. 7814–7823.
- [121] Bijiao Wu, Dingheng Wang, Guangshe Zhao, Lei Deng, and Guoqi Li. “Hybrid Tensor Decomposition in Neural Network Compression”, *Neural Networks* 132 (Dec. 1, 2020), pp. 309–320.
 - [122] Maolin Wang, Yu Pan, Zenglin Xu, Xiangli Yang, Guangxi Li, and Andrzej Cichocki. *Tensor Networks Meet Neural Networks: A Survey and Future Perspectives*. May 8, 2023. arXiv: 2302.09019 [cs]. Pre-published.
 - [123] Hua Zhou, Lexin Li, and Hongtu Zhu. “Tensor Regression with Applications in Neuroimaging Data Analysis”, *Journal of the American Statistical Association* 108.502 (June 2013), pp. 540–552.
 - [124] Alexander Novikov, D. Podoprikin, A. Osokin, and D. Vetrov. “Tensorizing Neural Networks”, In *Proceedings of International Conference on Neural Information Processing Systems*. Sept. 22, 2015.
 - [125] Cole Hawkins, Xing Liu, and Zheng Zhang. “Towards Compact Neural Networks via End-to-End Training: A Bayesian Tensor Approach with Automatic Rank Determination”, *SIAM Journal on Mathematics of Data Science* 4.1 (Mar. 2022), pp. 46–71.
 - [126] Liping Deng and Mingqing Xiao. “A New Automatic Hyperparameter Recommendation Approach Under Low-Rank Tensor Completion e Framework”, *IEEE Transactions on Pattern Analysis and Machine Intelligence* 45.4 (Apr. 2023), pp. 4038–4050. PMID: 35914040.
 - [127] Taewon Park, Inchul Choi, and Minhoo Lee. “Attention-Based Iterative Decomposition for Tensor Product Representation”, In *Proceedings of International Conference on Learning Representations*. Oct. 13, 2023.
 - [128] Karelia Pena-Pena, Daniel L. Lau, and Gonzalo R. Arce. “T-HGSP: Hypergraph Signal Processing Using t-Product Tensor Decompositions”, *IEEE Transactions on Signal and Information Processing over Networks* 9 (2023), pp. 329–345.
 - [129] Ivana Balažević, Carl Allen, and Timothy M. Hospedales. “Tucker: Tensor Factorization for Knowledge Graph Completion”, In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing*. 2019, pp. 5184–5193. arXiv: 1901.09590 [cs, stat].
 - [130] Michael T. Schaub, Yu Zhu, Jean-Baptiste Seby, T. Mitchell Roddenberry, and Santiago Segarra. “Signal Processing on Higher-Order Networks: Livin’ on the Edge... and Beyond”, *Signal Processing* 187 (Oct. 1, 2021), p. 108149.
 - [131] Hao Tian and Reza Zafarani. “Higher-Order Networks Representation and Learning: A Survey”, *SIGKDD Explor. Newsl.* 26.1 (July 25, 2024), pp. 1–18.
 - [132] Tamara G. Kolda and Brett W. Bader. “Tensor Decompositions and Applications”, *SIAM Review* 51.3 (Aug. 6, 2009), pp. 455–500.
 - [133] Qibin Zhao, Guoxu Zhou, Shengli Xie, Liqing Zhang, and Andrzej Cichocki. *Tensor Ring Decomposition*. June 17, 2016. arXiv: 1606.05535 [cs]. Pre-published.
 - [134] David Hong, Tamara G. Kolda, and Jed A. Duersch. “Generalized Canonical Polyadic Tensor Decomposition”, *SIAM Review* 62.1 (Jan. 2020), pp. 133–163. arXiv: 1808.07452 [cs, math].
 - [135] Zhong-Cheng Wu, Ting-Zhu Huang, Liang-Jian Deng, Hong-Xia Dou, and Deyu Meng. “Tensor Wheel Decomposition and Its Tensor Completion Application”, In *Proceedings of International Conference on Advances in Neural Information Processing Systems*. May 16, 2022.
 - [136] Kazu Ghalamkari, Mahito Sugiyama, and Yoshinobu Kawahara. “Many-Body Approximation for Non-Negative Tensors”, In *Proceedings of International Conference on Neural Information Processing Systems*. 2023.
 - [137] Chao Li, Junhua Zeng, Chunmei Li, Cesar Caiafa, and Qibin Zhao. “Alternating Local Enumeration (ThALE): Solving Tensor Network Structure Search with Fewer Evaluations”, In *Proceedings of International Conference on Machine Learning*. Vol. 202. ICML’23. JMLR.org, July 23, 2023, pp. 20384–20411.

- [138] J. Douglas Carroll and Jih-Jie Chang. “Analysis of Individual Differences in Multidimensional Scaling via an N-Way Generalization of “Eckart-Young” Decomposition”, *Psychometrika* 35.3 (Sept. 1, 1970), pp. 283–319.
- [139] Richard A Harshman. “Foundations of the PARAFAC Procedure: Models and Conditions for an “Explanatory” Multi-Modal Factor Analysis”, *UCLA Working Papers in Phonetics* 16 (1970), pp. 1–84.
- [140] Canyi Lu, Jiashi Feng, Yudong Chen, Wei Liu, Zhouchen Lin, and Shuicheng Yan. “Tensor Robust Principal Component Analysis: Exact Recovery of Corrupted Low-Rank Tensors via Convex Optimization”, In *Proceedings of International Conference on Computer Vision and Pattern Recognition*. IEEE, June 2016, pp. 5249–5257.
- [141] Canyi Lu, Jiashi Feng, Yudong Chen, Wei Liu, Zhouchen Lin, and Shuicheng Yan. “Tensor Robust Principal Component Analysis with a New Tensor Nuclear Norm”, *IEEE Transactions on Pattern Analysis and Machine Intelligence* 42.4 (Apr. 1, 2020), pp. 925–938.
- [142] Canyi Lu. “Transforms Based Tensor Robust PCA: Corrupted Low-Rank Tensors Recovery via Convex Optimization”, In *Proceedings of International Conference on Computer Vision*. IEEE, Oct. 2021, pp. 1125–1132.
- [143] Yuning Qiu, Guoxu Zhou, Zhenhao Huang, Qibin Zhao, and Shengli Xie. “Efficient Tensor Robust PCA Under Hybrid Model of Tucker and Tensor Train”, *IEEE Signal Processing Letters* 29 (2022), pp. 627–631.
- [144] Ji Liu, Przemyslaw Musialski, Peter Wonka, and Jieping Ye. “Tensor Completion for Estimating Missing Values in Visual Data”, In *Proceedings of International Conference on Computer Vision*. IEEE, Sept. 2009, pp. 2114–2121.
- [145] Johann A. Bengua, Ho N. Phien, Hoang Duong Tuan, and Minh N. Do. “Efficient Tensor Completion for Color Image and Video Recovery: Low-Rank Tensor Train”, *IEEE Transactions on Image Processing* 26.5 (May 2017), pp. 2466–2479.
- [146] Xi-Le Zhao, Jing-Hua Yang, Tian-Hui Ma, Tai-Xiang Jiang, Michael K. Ng, and Ting-Zhu Huang. “Tensor Completion via Complementary Global, Local, and Nonlocal Priors”, *IEEE Transactions on Image Processing* 31 (2022), pp. 984–999.
- [147] Caleb Xavier Bugg, Chen Chen, and Anil Aswani. “Nonnegative Tensor Completion via Integer Optimization”, In *Proceedings of International Conference on Advances in Neural Information Processing Systems*. 2022.
- [148] Yu-Bang Zheng, Ting-Zhu Huang, Xi-Le Zhao, and Qibin Zhao. “Tensor Completion via Fully-Connected Tensor Network Decomposition with Regularized Factors”, *Journal of Scientific Computing* 92.1 (July 2022), p. 8.
- [149] Ben-Zheng Li, Xi-Le Zhao, Teng-Yu Ji, Xiong-Jun Zhang, and Ting-Zhu Huang. “Nonlinear Transform Induced Tensor Nuclear Norm for Tensor Completion”, *Journal of Scientific Computing* 92.3 (Sept. 2022), p. 83.
- [150] Peng-Ling Wu, Xi-Le Zhao, Meng Ding, Yu-Bang Zheng, Lu-Bin Cui, and Ting-Zhu Huang. “Tensor Ring Decomposition-Based Model with Interpretable Gradient Factors Regularization for Tensor Completion”, *Knowledge-Based Systems* 259 (Jan. 2023), p. 110094.
- [151] Canyi Lu, Xi Peng, and Yunchao Wei. “Low-Rank Tensor Completion With a New Tensor Nuclear Norm Induced by Invertible Linear Transforms”, In *Proceedings of International Conference on Computer Vision and Pattern Recognition*. IEEE, June 2019, pp. 5989–5997.
- [152] Tatsuya Yokota, Qibin Zhao, and Andrzej Cichocki. “Smooth PARAFAC Decomposition for Tensor Completion”, *IEEE Transactions on Signal Processing* 64.20 (Oct. 15, 2016), pp. 5423–5436.
- [153] Masaaki Imaizumi and Kohei Hayashi. “Tensor Decomposition with Smoothness”, In *Proceedings of International Conference on Machine Learning*. PMLR, July 17, 2017, pp. 1597–1606.
- [154] Hiromu Takayama and Tatsuya Yokota. “A New Model for Tensor Completion: Smooth Convolutional Tensor Factorization”, *IEEE Access* 11 (2023), pp. 67526–67539.

- [155] Zhi Gao, Loong-Fah Cheong, and Mo Shan. “Block-Sparse RPCA for Consistent Foreground Detection”, In *Proceedings of European Conference on Computer Vision*. Vol. 7576. Springer Berlin Heidelberg, 2012, pp. 690–703.
- [156] Wenjin Qin, Hailin Wang, Feng Zhang, Jianjun Wang, Xin Luo, and Tingwen Huang. “Low-Rank High-Order Tensor Completion With Applications in Visual Data”, *IEEE Transactions on Image Processing* 31 (2022), pp. 2433–2448.
- [157] Hailin Wang, Jiangjun Peng, Wenjin Qin, Jianjun Wang, and Deyu Meng. “Guaranteed Tensor Recovery Fused Low-rankness and Smoothness”, *IEEE Transactions on Pattern Analysis and Machine Intelligence* 45.9 (Sept. 2023), pp. 10990–11007.
- [158] Shengfa Liang, Feibin Xiang, Zifan Tang, Reza Nouri, Xiaodong He, Ming Dong, and Weihua Guan. “Noise in Nanopore Sensors: Sources, Models, Reduction, and Benchmarking”, *Nanotechnology and Precision Engineering* 3.1 (Mar. 1, 2020), pp. 9–17.
- [159] J. Mead. “Chi2 Test for Total Variation Regularization Parameter Selection”, *Inverse Problems & Imaging* 14.3 (2020), pp. 401–421.
- [160] Babak Maboudi Afkham, Julianne Chung, and Matthias Chung. “Learning Regularization Parameters of Inverse Problems via Deep Neural Networks”, *Inverse Problems* 37.10 (Oct. 1, 2021), p. 105017.
- [161] Shunsuke Ono. “L0 Gradient Projection”, *IEEE Transactions on Image Processing* 26.4 (Apr. 2017), pp. 1554–1564.
- [162] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. “Deep Residual Learning for Image Recognition”, In *Proceedings of International Conference on Computer Vision and Pattern Recognition*. June 2016, pp. 770–778.
- [163] Junfeng Yang and Xiaoming Yuan. “Linearized Augmented Lagrangian and Alternating Direction Methods for Nuclear Norm Minimization”, *Mathematics of Computation* 82.281 (Jan. 2013), pp. 301–329.
- [164] Masao Yamagishi and Isao Yamada. “Nonexpansiveness of a Linearized Augmented Lagrangian Operator for Hierarchical Convex Optimization”, *Inverse Problems. An International Journal on the Theory and Practice of Inverse Problems, Inverse Methods and Computerized Inversion of Data* 33.4 (Mar. 2017), p. 044003.
- [165] Laurent Condat, Daichi Kitahara, Andrés Contreras, and Akira Hirabayashi. “Proximal Splitting Algorithms for Convex Optimization: A Tour of Recent Advances, with New Twists”, *SIAM Review* 65.2 (May 4, 2023), pp. 375–435.
- [166] Robert Nishihara, Laurent Lessard, Benjamin Recht, Andrew Packard, and Michael I. Jordan. “A General Analysis of the Convergence of ADMM”, In *Proceedings of International Conference on Machine Learning*. ICML’15. JMLR.org, July 6, 2015, pp. 343–352.